

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»
Факультет информатики, математики и компьютерных наук

Канделов Дамир Русланович

**КЛАССИФИКАЦИЯ ВЫРАЖЕНИЙ ЛИЦ
С ДЕТЕКТИРОВАНИЕМ ЭМОЦИЙ В РЕЧИ**

Выпускная квалификационная работа
по направлению подготовки 09.03.04 Программная инженерия
образовательная программа
«Программная инженерия»

Рецензент
приглашенный преподаватель
базовой кафедры группы
компаний «MERA»,
Е.А. Лемайкина

Руководитель
к.т.н., доцент, кафедра
информационных систем и
технологий НИУ ВШЭ - НН
Л.В. Савченко

Нижний Новгород, 2026

Содержание

Введение	4
1. Постановка задачи	6
2. Аналитический обзор литературы	11
2.1. Ранние исследования в области распознавания эмоций	11
2.2. Методы распознавания эмоций по речевому сигналу (SER)	13
2.2.1. Фундаментальные подходы: MFCC, метод опорных векторов (SVM) и лог-мел-спектограммы	14
2.2.2. Трансформерные энкодеры Wav2Vec 2.0 и DistilHuBERT	16
2.2.3. Сверточные нейронные сети на основе спектральных представлений	19
2.3. Методы распознавания эмоций по выражению лица (FER)	21
2.3.1. Детекция лиц MediaPipe BlazeFace	22
2.3.2. Легкие бэкбоны для видеокадров: MobileNetV3-Small и EmotiEffNet	23
2.3.3. Темпоральные агрегаторы для последовательности кадров: BiGRU, BiLSTM, TCN	25
2.4. Мультимодальное распознавание эмоций (MER)	28
2.4.1. Классические стратегии слияния модальностей	29
2.4.2. Современные мультимодальные архитектуры для IEMOCAP	30
3. Обзор датасетов для задачи мультимодальной классификации эмоций	34
3.1. RAVDESS (Ryerson Audio-Visual Database of Emotional Speech and Song)	35

3.2. CREMA-D (Crowd-sourced Emotional Multimodal Actors Dataset)	36
3.3. IEMOCAP (Interactive emotional dyadic motion capture database)	36
3.4. Другие датасеты для мультимодального распознавания эмоций	38
3.5. Стратегия использования датасетов для обучения	41
3.5.1. Предобучение на RAVDESS и CREMA-D	42
3.5.2. Оффлайн аугментация данных	42
3.5.3. Разделение ролей датасетов.....	45
3.5.4. Обоснование эффективности выбранной стратегии	45
4. Методология предлагаемой системы	47
4.1. Общая архитектура двухстадийного каскада	47
4.2. Аудио модель: бинарная классификация	49
4.2.1. Подготовка данных и спикеро-независимое разбиение.	50
4.2.2. Сравниваемые архитектуры аудиомоделей	51
4.2.3. DistilHuBERT + Linear.....	51
4.2.4. Log-Mel + CNN (MelCNN)	52
4.2.5. MFCC + SVM	53
4.2.6. Wav2Vec 2.0 + MLP	53
4.2.7. Оценка баланса качества и производительности и выбор оптимального аудиогейта	54
5. Экспериментальная оценка и результаты	74

6. Заключение.....	96
Библиографический список.....	97

Введение

Эмоции играют фундаментальную роль в человеческом общении, они влияют на принятие решений, социальные взаимодействия и общее психологическое благополучие. Способность классифицировать выражения лиц и эмоции становится все более важной задачей в развитии общения между человеком и компьютером (human-computer interaction, HCI), особенно в областях распознавания эмоций в разговорах (emotion recognition in conversations, ERC) и более современного мультимодального распознавания эмоций в разговорах (multimodal recognition in conversations, MERC).

Понимание текущего эмоционального состояния человека позволяет компьютерным системам получать больше информации о состоянии человека в конкретный момент времени и отвечать более естественным образом. В настоящее время это практически не применяется, но уже может быть использовано в:

- виртуальных ассистентах (Алиса, ChatGPT и т.д.) для того чтобы сделать общение с человеком более живым и естественным - формировать ответы с учетом текущего эмоционального состояния человека;
- системах мониторинга обслуживания клиентов и аналитике психологического состояния - эмоции человека могут показать его реальное отношение к каким-то действиям;
- образовании - определение вовлеченности студентов, усталости и скуки, автоматическая адаптация сложности материала;

- контроль состояния водителя автомобиля / автобуса / поезда / самолета - с предупреждением в случае сонливости, злости, отвлеченности;
- компьютерные игры с адаптацией под текущее состояние игрока.

В настоящее время такие механизмы уже применяются в современных системах, но ограниченно и совсем не на максимуме своих возможностей. Зачастую это происходит из-за высокой стоимости использования таких систем или недостаточно высокого качества классификации. В данной курсовой работе будет представлена новая мультимодальная архитектура, позволяющая снизить потребление вычислительных ресурсов с сохранением высокого качества классификации.

Таким образом, востребованность и актуальность темы данной работы обусловлены потребностями современных компаний в создании эффективных и экономичных систем определения эмоций. В условиях стремительного развития технологий искусственного интеллекта и расширения областей его применения особую значимость приобретает разработка именно оптимизированных методов распознавания эмоций.

1. Постановка задачи

В работе будут подробно рассмотрены современные подходы к классификации эмоции по речи, по выражению лиц, а также к мультимодальной классификации. Для лучшего понимания будут использоваться не только лучшие современные подходы, но и базовые, считающиеся фундаментальными в этих сферах.

Ключевым препятствием для внедрения мультимодальных систем распознавания эмоций в реальные приложения является их вычислительная сложность [12]. Современные модели, как правило, строятся по принципу параллельной обработки обоих потоков данных: видео и аудио обрабатываются одновременно тяжелыми нейросетевыми бэкбонами, что приводит к высокому энергопотреблению, долгой работе моделей и делает практически невозможным их использование на мобильных устройствах, во встраиваемых системах или в сервисах с ограниченным бюджетом. Эта проблема активно осознается научным сообществом: в последние годы появились работы: направленные на создание легких моделей для устройств с ограниченными вычислительными ресурсами, например на основе MobileNetV3 [13] [14]. В контексте мультимодального анализа все чаще обсуждаются подходы с динамической активацией наиболее информативных модальностей или экспертные сети для повышения эффективности [15] [16].

В данной работе предлагается архитектурное решение, органично вписывающееся в эту тенденцию: двухстадийная система распознавания эмоций. Основная идея заключается в использовании легкого аудиогейта, который на входе бинарно решает «нейтральная» эмоция или «не

нейтральная», и только в случае обнаружения не нейтральных эмоций запускается ресурсоемкая модель по двум модальностям (аудио + видео), определяющая один из классов эмоций (в зависимости от датасета). Такой подход отличается от классических мультимодальных архитектур, которые в большинстве случаев ориентированы на параллельный анализ всех модальностей для каждого фрагмента. Предлагаемый каскад позволяет достичь компромисса между качеством распознавания и вычислительной эффективностью.

Таким образом **актуальность исследования обусловлена** четырьмя ключевыми факторами:

1. Практической потребностью в легких, энерго- и ресурсо-эффективных системах распознавания эмоций для мобильных, встраиваемых и периферийных платформ, где современные MER архитектуры неприменимы.
2. Отсутствием в литературе каскадных мультимодальных систем с аудиогейтом специально ориентированным на проверку речи на нейтральность. Хотя работы по динамическому стробированию появляются, они преимущественно фокусируются на взвешивании уже обработанных признаков, а не на раннем решении об активации целой ветви обработки [15].
3. Необходимостью в прозрачной методологии оценки, исключающей утечку информации о дикторе при сохранении баланса классов в выборке, что позволит получать результаты, адекватно отражающие работу системы в реальных условиях общения с незнакомыми людьми.

4. Возможностью значительного сокращения вычислительных затрат без потери качества распознавания за счет активации тяжелой бимодальной модели только при необходимости, что открывает перспективы для масштабирования и практического внедрения мультимодальных систем в тех областях, где ранее они считались слишком ресурсозатратными.

Предлагаемая работа вносит вклад в решение этих проблем, а полученные результаты могут быть использованы как в академических исследованиях, так и в прикладных разработках в области человеко-компьютерного взаимодействия.

Новизна данного исследования состоит в разработке новой двухстадийной эффективной, низко ресурсозатратной архитектуры для задачи MER, которая использует легкий бинарный аудио классификатор для определения нейтральности речи и, в случае эмоциональной речи включается видео модель для классификации конкретной эмоции.

Целью данного исследования является разработка, реализация и экспериментальная оценка и замер качества двухэтапной мультимодальной системы распознавания эмоций, которая уменьшает затраты вычислительных ресурсов по сравнению с традиционными синхронными архитектурами без значимого ухудшения точности классификации на стандартных датасетах (RAVDESS [2], CREMA-D [3]), а также финальном бенчмарке (IEMOCAP [4]).

Ключевая гипотеза этого проекта состоит в том, что в реальном диалоге подавляющая доля кадров эмоционально нейтральна. Следовательно, применение легкого аудиогейта, быстро выявляющего

нейтральные фрагменты, позволяет избежать использование тяжелых видеомоделей для этих кадров, значительно сокращая среднее время обработки без критической потери качества распознавания.

Задачами исследования являются:

1. Анализ предметной области: изучение подходов к распознаванию эмоций по речи (SER), по выражениям лиц (FER), по обеим модальностям (MER).
2. Выявление возможности оптимизации современных архитектур за счет последовательной обработки аудио и видео. Определение базовых моделей для сравнения с нашей архитектурой.
3. Подготовка данных. Анализ датасетов, выбор подходящих для нашей задачи, предобработка.
4. Разработка аудиогейта. Реализовать и сравнить несколько подходов для выявления лучшего, сравнение по трем параметрам: качество, скорость работы и вес модели.
5. Построение классификатора по видео. Определить модели для выявления признаков, а также модели-классификаторы получившихся признаков. Выбрать несколько лучших на текущий момент подходов, сравнить их с более легковесными, провести сравнение по аналогичным параметрам, как в пункте 4.
6. Сборка двухэтапного пайплайна. Объединение аудиогейта и классификатора по аудио и видео в одну архитектуру.
7. Написание бейзлайнов для сравнения нашей архитектуры с текущими лучшими. Экспериментальная оценка качества, времени работы и затраченной памяти на итоговом бенчмарке.

8. Реализация прототипа реального времени. Разработка демонстрационного скрипта, обрабатывающего поток с веб-камеры и микрофона в реальном времени. Практический пример работы итоговой архитектуры.

Решение данных задач позволит проверить сформулированную гипотезу и создать ресурсоэффективную архитектуру распознавания эмоций с аудиогейтом.

2. Аналитический обзор литературы

2.1. Ранние исследования в области распознавания эмоций

Исследования в области распознавания эмоций берут свое начало в работах по психологии и эффективным вычислениям. Фундаментальной основой для большинства современных систем стали работы Пола Экмана и Уоллеса Фризена, которые в середине 1970-х годов эмпирически обосновали теорию универсальности мимических выражений эмоций. Эта теория говорит о том, что независимо от культурного происхождения и воспитания, люди выражают шесть базовых эмоций сходным образом: счастье, грусть, гнев, страх, удивление и отвращение [17]. Пол Экман и Уоллес Фризен смогли не только определить 6 классов эмоций, но также они предложили детальную систему для классифицирования лицевых выражений (Facial Action Coding System, FACS), которая позволяет описывать мимические изменения через действия лицевых мышц [18]. Эта система до сих пор остается золотым стандартом для аннотирования выражений лиц в компьютерном зрении.

Первые попытки автоматизировать распознавание эмоций опирались на классические методы машинного обучения и ручной подбор признаков. В работе Ioannou и др. 2005 года [19] использовалась neurofuzzy network (нейро-нечеткая сеть) для классификации эмоций по изображениям лиц (Facial Emotion Recognition, FER). На первом этапе детекция лица выполнялась с помощью метода опорных векторов (SVM), затем из выделенной области лица извлекались геометрические признаки (положение бровей, глаз, уголков губ). Полученный вектор признаков подавался на вход neurofuzzy сети, сочетающей преимущества нейронных

сетей и нечеткой логики. Эксперименты показали, что такой гибридный подход может превосходить чистые статистические методы, однако он оставался чувствительным к условиям освещения и поворотам головы, а также требовал тщательной ручной настройки детектора лицевых признаков.

Параллельно с компьютерным зрением развивалась область распознавания эмоций по голосу (Speech Emotion Recognition, SER). Ключевой идеей было выделение просодических и спектральных характеристик речевого сигнала, которые коррелируют с эмоциями говорящего. Наиболее популярным набором признаков стали мел-частотные кепстральные коэффициенты (MFCC), которые компактно представляют спектральную огибающую звука [20]. Кроме MFCC, использовались также следующие признаки: основная частота голоса (F0), энергия, длительность пауз, скорость речи. Классическими классификаторами выступали скрытые марковские модели (Hidden Markov Model, HMM), методы опорных векторов (SVM) и гауссовские смеси (Gaussian Mixture Model, GMM). Однако универсальные системы SER сильно уступали человеку по точности, особенно в условиях фонового шума или при распознавании эмоций незнакомых дикторов.

С развитием Deep Learning (DL) ситуация в обеих областях: FER и SER, кардинально изменилась. Появилась возможность автоматически извлекать иерархические признаки из сырых данных, что устранило необходимость в ручном проектировании признаков. В компьютерном зрении стали доминировать сверточные нейронные сети (CNN), такие как VGG, ResNet и более легкие архитектуры (MobileNet, EfficientNet). В обработке речи – рекуррентные сети (LSTM, GRU) и трансформеры

(Wav2Vec 2.0, HuBERT). Однако, проблема распознавания эмоций в реальных сценариях, когда одновременно присутствуют и мимика, и голос, и они могут быть частично избыточны или противоречивы, оставалась открытой. Именно это привело к формированию направления мультимодального распознавания эмоций (Multimodal Emotion Recognition, MER), в котором информация из двух и более каналов (аудио, видео, текст) объединяется для повышения точности, надежности и устойчивости.

2.2. Методы распознавания эмоций по речевому сигналу (SER)

Задача распознавания эмоций по речи (Speech Emotion Recognition, SER) [7] заключается в автоматическом определении эмоционального состояния говорящего по акустическим характеристикам речевого сигнала. В отличие от задач распознавания речи (ASR), где основное внимание уделяется лингвистическому содержанию, SER ориентирована на паралингвистические компоненты – интонацию, тембр, энергию и паузальную структуру. Исторически SER развивалась в двух параллельных направлениях: 1) методы, основанные на ручном проектировании акустических признаков с последующей классификацией с помощью моделей машинного обучения, и 2) методы глубокого обучения, которые автоматически извлекают иерархические представления из сырого сигнала или его спектрального представления. В данном разделе рассматриваются фундаментальные подходы первой группы, которые, несмотря на появление более сложных нейросетевых архитектур, продолжают использоваться в задачах, критичных к вычислительным ресурсам и интерпретируемости.

2.2.1. Фундаментальные подходы: MFCC, метод опорных векторов (SVM) и лог-мел-спектограммы

Классические методы SER строятся на двухэтапной схеме: извлечение признаков, а затем применение классификатора для определения эмоции по вектору признаков.

Мел-частотные кепстральные коэффициенты (MFCC). Наиболее широко используемым представлением речевого сигнала в задачах SER являются MFCC [20]. Данные коэффициенты моделируют нелинейность слухового восприятия человека путем преобразования частотной шкалы в мел-шкалу:

$$\text{mel}(f) = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right), \text{ где } f - \text{частота в Гц}$$

Процедура вычисления MFCC включает следующие шаги: сегментация сигнала на перекрывающиеся кадры (обычно 25 мс с шагом 10 мс), применение оконной функции (Ханна или Хэмминга), вычисление кратковременного преобразования Фурье (STFT), фильтрация спектра с треугольными мел-фильтрами, логарифмирование энергий фильтров и дискретное косинусное преобразование (DCT). В результате каждого кадра получается вектор из 12-40 коэффициентов, к которым часто добавляют дельта- и дельта-дельта- характеристики. Для представления целого высказывания векторы кадров агрегируются (среднее, стандартное отклонение, асимметрия, эксцесс) либо подаются в классификатор, способный работать с последовательностями.

Лог-мел-спектограммы (Log-Mel Spectrogram). Альтернативным представлением, также широко используемым в SER, является лог-мел-

спектрограмма. В отличие от MFCC, данный формат сохраняет больше спектральной информации за счет отказа от дискретного косинусного преобразования. Лог-мел-спектрограмма представляет собой двумерный массив, где по оси времени отложены кадры, по оси частот – мел-фильтры (обычно от 64 до 128), а значение в каждой ячейке – логарифм энергии соответствующего мел-фильтра. Такое представление может быть подано на вход сверточной нейронной сети, которая извлекает релевантные признаки. В данной работе для построения лог-мел-спектрограмм используется библиотека librosa [22].

Метод опорных векторов (SVM). После извлечения признаков (агрегированных MFCC) требуется классификатор, способный разделить эмоциональные классы в многомерном пространстве. Одним из наиболее эффективных и широко применяемых методов является метод опорных векторов (Support Vector Machine, SVM) [23]. SVM строит разделяющую гиперплоскость, максимизирующую зазор между ближайшими точками разных классов. Для линейно неразделимых данных используется kernel trick: исходное пространство признаков отображается в пространство более высокой размерности с помощью ядерной функции. В задачах SER наиболее часто применяется радиальное базисное ядро (Radial Basis Function, RBF):

$$K(x_i, x_j) = \exp\left(-\gamma\|x_i - x_j\|^2\right)$$

SVM демонстрирует высокую обобщающую способность на небольших размеченных наборах данных, устойчив к переобучению при правильном подборе гиперпараметров, а также обеспечивает быстрое выполнение на этапе инференса.

2.2.2. Трансформерные энкодеры Wav2Vec 2.0 и DistilHuBERT

Следующим значимым этапом в развитии SER после классических методов стало применение предобученных самонаблюдаемых (Self-Supervised Learning, SSL) моделей. В отличие от традиционных подходов, требующих ручного проектирования признаков, SSL-модели обучаются на больших объемах неразмеченных аудиоданных для извлечения универсальных речевых представлений, которые затем могут быть адаптированы под конкретную задачу с помощью минимального количества размеченных примеров. Среди таких моделей наибольшее распространение получили Wav2Vec 2.0 и его последующая эффективная версия DistilHuBERT, используемые в данной работе в качестве одного из сравниваемых методов для аудиогейта.

Wav2Vec 2.0 был предложен в 2020 году исследователями из Meta Ai [24]. Архитектура модели включает три основных компонента: многоканальную сверточную сеть (feature encoder), преобразующую сырую звуковую волну в латентные представления; модуль квантизации, дискредитирующий полученные представления; и трансформный контекстуальный кодировщик, который обрабатывает замаскированные латентные представления и извлекает контекстно-зависимые эмбединги. Обучение модели происходит в рамках контрастивной задачи: для каждого замаскированного временного отрезка модель должна идентифицировать соответствующее ему истинное квантизованное представление среди набора дистракторов. Такая схема обучения позволяет Wav2Vec 2.0 эффективно использовать большие объемы неразмеченных аудиоданных и достигать высоких результатов на различных речевых задачах.

Применительно к SER модель Wav2Vec 2.0 может использоваться двумя основными способами. Первый подход – извлечение признаков: замороженная предобученная модель Wav2Vec 2.0 прогоняет входной аудиосигнал и выдает последовательность эмбеддингов, которые усредняются по времени и подаются в небольшую обучаемую голову (линейный слой или многослойный перцептрон) для классификации эмоций. Именно этот подход реализован в данной работе с использованием модели *facebook/wav2vec2-base* в качестве экстрактора признаков, поверх которой обучается двухслойный MLP-классификатор для бинарного определения «нейтрально / не нейтрально». Преимуществами такого подхода являются компактность обучаемой части (всего несколько миллионов параметров вместо 95 млн. у полной модели) и высокая скорость инференса, что критично для задачи данного исследования.

Результаты многочисленных исследований демонстрируют эффективность Wav2Vec 2.0 в задачах SER. В работе, посвященной сравнению SSL-моделей на корпусах IEMOCAP, RAVDESS, EMODB, метод экстракции признаков на основе Wav2Vec 2.0 с последующей классификацией с помощью логистической регрессии достигает среднего значения полноты 87.01% на RAVDESS при кросс-валидации [27]. При этом в большинстве работ отмечается, что даже простая экстракция признаков с последующей линейной классификацией дает результаты, сравнимые с полной тонкой настройкой, при значительно меньших вычислительных затратах, что подтверждает обоснованность подхода, используемого в данном исследовании.

DistilHuBERT представляет собой дистиллированную (уменьшенную) версию модели HuBERT (Hidden-Unit BERT) [25],

архитектурно близкой к Wav2Vec 2.0. Основное отличие от первой модели заключается в способе целевой функции: вместо контрастивной потери HuBERT использует кластеризацию латентных представлений для генерации целевых меток и решает задачу предсказания замаскированных фрагментов, аналогично masked language modeling в BERT. DistilHuBERT, в свою очередь, предложен как метод сжатия исходной модели HuBERT путем послойной дистилляции представлений в многофункциональной обучающей схеме [26]. Это позволяет сократить размер модели на 75% (с 95 млн до примерно 24 млн параметров) и ускорить инференс в 3.7 раза при минимальной потере точности на десяти различных задачах распознавания речи.

В контексте SER легкость DistilHuBERT делает его особенно привлекательным для мобильных и встраиваемых приложений. В работе [28] была проведена валидация DistilHuBERT на нескольких стандартных наборах данных (IEMOCAP, CREMA-D). Предложенный подход с 8 битной квантизацией модели (метод уменьшения размера модели) достиг 61.4% невзвешенной точности на IEMOCAP при размере модели всего 23 МБ, что составляет 91% от производительности полноразмерного бейзлайна. При этом добавление CREMA-D в обучающую выборку повысило взвешенную точность на 1.2% и макро F1 метрику на 1.4% [28]. Эти результаты подтверждают, что DistilHuBERT обеспечивает компромисс между точностью и вычислительной эффективностью, который особенно важен в задачах потокового распознавания на устройствах с ограниченными ресурсами.

В рамках данной работы DistilHuBERT сравнивается с другими методами для задачи бинарной классификации «нейтрально / не

нейтрально». Модель используется в режиме замороженного экстрактора признаков: предобученная версия *ntu-spml/distilhubert* преобразует входной аудиосигнал в последовательность эмбеддингов, которые затем усредняются по времени и подаются в линейный классификатор. Такой подход позволяет оценить качество представлений, извлеченных дистиллированной моделью, в сравнении с более тяжелыми моделями и традиционными методами, и определить, насколько целесообразно применение DistilHuBERT в роли аудиогейта в каскадной системе распознавания эмоций.

2.2.3. Сверточные нейронные сети на основе спектральных представлений

Трансформерные энкодеры, такие как Wav2Vec 2.0 и DistilHuBERT, обеспечивают высокую точность распознавания эмоций за счет предобучения на огромных корпусах речи, однако их применение в сценариях с жесткими ограничениями по вычислительным ресурсам (мобильные устройства, встраиваемые системы, потоковая обработка) может быть затруднено из-за большого размера модели и требований к аппаратному ускорению. Альтернативой выступают легкие сверточные нейронные сети (Convolutional Neural Networks, CNN), которые могут быть обучены с нуля на размеченных датасетах среднего объема, и демонстрируют компромисс между точностью, скоростью инференса и размером модели, конечно, немного уступая в качестве тяжеловесным трансформерам.

Принципы работы CNN для SER. В отличие от трансформеров, работающих с последовательностями эмбеддингов, CNN принимают на

вход двумерное представление сигнала – чаще всего лог-мел-спектрограмму. Как описано в разделе 3.2.1, лог-мел-спектрограмма имеет размерность (n_mels, n_time) , где n_mels – число мел-фильтров (обычно 64-128), а n_time – число временных кадров. Сверточные слои с ядрами 3×3 или 5×5 скользят по частоте и времени, извлекая локальные паттерны – например, изменения энергии в определенных частотных диапазонах, переходные процессы, модуляции. Совокупность таких паттернов, пропущенная через последовательность сверточных, пуллинговых и полносвязных слоев, формирует вектор признаков, который затем классифицируется.

Обзор существующих CNN-архитектур для SER. Многочисленные исследования подтверждают эффективность CNN на лог-мел-спектрограммах. В работе [29] на датасете RAVDESS сравнили различные представления (MFCC, лог-мел-спектрограммы, спектрограммы) с 4-слойной CNN. Авторы показали, что наибольшая точность (68% на 14 классах, включая пол и эмоции) достигается именно на лог-мел-спектрограмме, причем выбор признаков оказывает большее влияние на результат, чем глубина сети. В другой работе [30] была предложена компактная CNN из трех сверточных слоев, которая на IEMOCAP достигла точности 65.8% при классификации четырех эмоций (нейтральная, счастье, грусть, гнев).

Более поздние исследования развивают идею легких CNN с использованием современных техник регуляризации. В работе [31] была применена глубокая сеть CNN (четыре сверточных блока) на лог-мел-спектрограммах с размерностью 128×186 (частота $\times$ время) и была достигнута точность 86.5% на датасете RAVDESS на 8 эмоциях. Однако

такая сеть уже имела около 4 миллионов параметров, что снижало ее преимущество в скорости. Также была разработана специальная сверхлегкая CNN (560 тыс. параметров) для SER на RAVDESS, добившись точности 81.12% на 8 классах эмоций [32]. Авторы показали, что дальнейшее уменьшение числа параметров приводит к падению точности на 15%, но даже такая ультралегкая сеть остается работоспособной для бинарных задач.

2.3. Методы распознавания эмоций по выражению лица (FER)

Распознавание эмоций по выражению лица (Facial Emotion Recognition, FER) [8] является одной из наиболее активно развивающихся областей компьютерного зрения, что обусловлено высокой информативностью мимики как канала невербальной коммуникации. В отличие от речевого сигнала, который может быть зашумлен или фрагментарен, выражение лица в моменты эмоционального переживания зачастую предоставляет более прямой и однозначный сигнал о текущем состоянии человека. Задача FER включает три основных этапа: детекция лица на изображении или на кадре видео, извлечение признаков из области лица, и классификация эмоции на основе выделенных признаков.

Исторически, ранние системы FER опирались на классические методы машинного обучения. На этапе детекции лица широко применялись каскады Хаара, предложенные в 2001 году [33]. Данный метод использует набор прямоугольных признаков, вычисляемых с помощью интегрального представления изображения, и каскад классификаторов на основе AdaBoost для быстрого отсеивания областей без лица. Несмотря на высокую скорость работы, каскады Хаара демонстрируют низкую точность при поворотах

головы, изменении освещения и других окклюзиях. В качестве альтернативы использовался метод HOG (Histogram of Oriented Gradients) в комбинации с линейным SVM, а также MTCNN (Multi-Task Cascaded Convolutional Networks), обеспечивающий более высокую точность за счет трехстадийной каскадной архитектуры.

С развитием глубокого обучения стандарты в области FER кардинально изменились. Сверточные нейронные сети позволили автоматически извлекать иерархические признаки непосредственно из пиксельного представления области лица, исключив необходимость в ручном проектировании геометрических и текстурных дескрипторов. На смену тяжелым архитектурам, таким как VGG, ResNet и Inception, пришли легкие модели, оптимизированные для работы на мобильных и встраиваемых устройствах (MobileNet, EfficientNet, ShuffleNet). Параллельно с этим значительный прогресс был достигнут в области детекции лиц, где появились высокоточные и быстрые решения, способные работать в реальном времени.

2.3.1. Детекция лиц MediaPipe BlazeFace

Первый и обязательный этап любой системы распознавания эмоций по выражению лиц – локализация области лица в кадре. Точность детекции напрямую влияет на последующее извлечение признаков и итоговую классификацию: ошибка определения лица приводит к потере релевантной мимической информации или включению в анализ фоновых областей. В задачах реального времени, где каждый кадр должен быть обработан за миллисекунды, к детектору предъявляются дополнительные требования по скорости работы и компактности модели.

Media Pipe BlazeFace – легкий детектор лиц, разработанный командой Google для работы на мобильных GPU [34]. Архитектура модели основана на Single Shot Detector (SSD) с бэкбоном MobileNetV2; ключевым решением является использование глубоких разделимых сверток, что позволяет сократить число параметров до 2.7 млн. Модель предсказывает ограничивающие рамки и шесть ключевых точек лица, доступна в двух вариантах: *short_range* и *full_range*. Производительность BlazeFace на мобильных GPU превышает 200 кадров в секунду, на CPU – не менее 30 кадров в секунду. Размер INT8 версии – несколько сотен килобайт.

Альтернативные детекторы:

- Каскады Хаара [33] и HOG + SVM [35] проигрывают по точности BlazeFace при поворотах головы и окклюзиях;
- MTCNN [36] существенно медленнее и не подходит для мобильных устройств;
- RetinaFace [37] точен, но слишком тяжелый для нашей задачи
- YOLOv8 Nano [38] и MobileNet SSD [39] не предсказывают ключевые точки лица и имеют больший размер модели.

Таким образом, Media Pipe BlazeFace обеспечивает наилучший баланс скорости, точности и компактности для потоковой системы.

2.3.2. Легкие бэкбоны для видеокадров: MobileNetV3-Small и EmotiEffNet

После определения границ области лица на вход системы подается кроп лица, из которого необходимо извлечь пространственные признаки, релевантные для распознавания эмоций. В современных FER системах эту

роль выполняют сверточные нейронные сети, выступающие в качестве бэкбона – модели, преобразующей изображение лица в вектор числовых признаков. В данной работе сравниваются два подхода: MobileNetV3-Small – универсальная легковесная архитектура, оптимизированная для мобильных устройств, и EmotiEffNet – специализированная модель, предобученная на крупном датасете AffectNet для задачи распознавания эмоций.

MobileNetV3-Small – третье поколение семейства MobileNet, разработанное Google с использованием комбинации методов аппаратного осознанного поиска архитектуры (NetAdapt) и дополнительных улучшений, таких как squeeze-and-excitation модули и новая нелинейная функция активации hard-swish [40]. Модель имеет 1.3 млн параметров и характеризуется вычислительной сложностью 0.19 GMac (Giga Multiply-Accumulate operations), что делает ее в несколько раз легче и быстрее предшественников. За счет использования глубоких разделимых сверток и инвертированных линейных бутылочных слоев MobileNetV3-Small обеспечивает высокую эффективность инференса на устройствах с ограниченными ресурсами.

В задачах FER MobileNetV3-Small демонстрирует конкурентоспособные результаты. В работе [41] модифицированная версия MobileNetV3 достигла точности 87.5% на датасете FERPlus и 86.6% на RAF-DB, при этом размер модели составил всего 15.9 МБ. Наибольшее преимущество модели проявляется на устройствах с ограниченными ресурсами, где она одновременно обеспечивает и высокую скорость, и приемлимую точность. Для сравнения: MobileNetV3-Large имеет порядка 5.4 млн. параметров (в MobileNetV3-Small – 2.9 млн. параметров), при этом

выигрыш в точности составляет лишь 3-4 процентных пункта при существенно большем объеме вычислений.

EmotiEffNet представляет собой семейство предобученных сверточных сетей на базе EfficientNet-B0, специально настроенных для решения задач распознавания эмоций. Эффективность EmotiEffNet достигается за счет двухэтапной стратегии предобучения: сеть сначала обучается на крупном датасете VGGFace2 для задачи определения лица, а затем дообучается на AffectNet с фокусом на эмоциональные категории. Такая схема позволяет модели наследовать способность различать тонкие лицевые особенности от VGGFace2, а затем адаптировать эти знания к пространству эмоций. В работе А.В. Савченко [42], представлено семейство EmotiEffNets, предназначенных для распознавания выражений лица, предсказания валентности и возбуждения, а также детекции лицевых действий. Эти модели показали эффективность на международных соревнованиях, в частности соревнования ABAW (Affective & Behavior Analysis in-the-wild).

2.3.3. Темпоральные агрегаторы для последовательности кадров: BiGRU, BiLSTM, TCN

Извлечение пространственных признаков из отдельных кадров (с помощью бэкбонов, рассмотренных в прошлом параграфе) дает статическое представление мимики. Однако эмоциональное состояние человека разворачивается во времени: удивление может смениться на радость, грусть – нейтральным состоянием, а интенсивность эмоции может нарастать или затухать на протяжении высказывания. Учет этих временных зависимостей требует агрегации пространственных признаков по некоторой

последовательности кадров, что достигается с помощью темпоральных агрегаторов. Рассмотрим два класса темпоральных агрегаторов: двунаправленные рекуррентные сети и временные сверточные сети. Выбор этих архитектур обусловлен их различными компромиссами между учетом контекста, параллелизуемостью и вычислительной эффективностью.

Двунаправленные рекуррентные сети (BiLSTM и BiGRU).

Базовыми рекуррентными архитектурами для последовательных данных являются долгая краткосрочная память (LSTM) и управляемый рекуррентный блок (GRU) [43] [44] [45]. Оба подхода решают проблему затухающих градиентов стандартных RNN за счет вентильных механизмов, регулирующих поток информации. Однако в задаче распознавания эмоций текущая мимика зависит не только от предыдущих кадров, но и от последующих – человек может проявлять эмоцию, затем возвращаться к нейтральному состоянию, и этот возврат важен для контекста. Двунаправленные версии (BiLSTM, BiGRU) обрабатывают последовательность в обоих направлениях: прямой слой захватывает зависимости от прошлого к будущему, обратный – от будущего к прошлому, а финальное представление формируется конкатенацией скрытых состояний обоих слоев.

В работе по распознаванию выражений лица было предложено объединение трех комплексных потоков признаков (текстурных, полусырых геометрических и явных геометрических) с последующей подачей в BiLSTM для моделирования временной динамики. Предложенный метод достиг взвешенной точности 58.40% на CREMA-D и 82.99% на RAVDESS при 8.68 млн параметров в BiLSTM [46]. В исследовании. Посвященному анализу эмоций клиентов в видео, была

предложена модель BiLSTM-Attention в комбинации с VGG16; BiLSTM использовался для получения контекстных характеристик последовательных кадров и захвата долгосрочных эмоциональных колебаний, тогда как механизм внимания присваивал важность кадрам, представляющим краткосрочные выражения лица, в результате чего модель могла точно определять комплексные эмоции человека на временном интервале [47].

BiGRU – это упрощенный вариант, архитектура объединяет входной и забывающий вентили LSTM в один вентиль обновления и дополнительно использует вентиль сброса. BiGRU имеет меньшее число параметров и часто демонстрирует близкую BiLSTM точность. В работе для мультимодального распознавания эмоций было показано, что BiGRU улучшает точность распознавания во временных контекстах, а метод инициализации сети и модуль внимания, вычисляющий распределение внимания для каждой модальности в реальном времени, позволяют сети изучать мультимодальную контекстную информацию в реальном времени [48].

Временные сверточные сети (Temporal Convolutional Networks, TCN). Альтернативой рекуррентным сетям выступают временные сверточные сети, предложенные как замена RNN для задач моделирования последовательностей [49]. TCN строятся из трех типов слоев: 1D причинных сверток, сохраняющих порядок (значение в момент t зависит только от L предыдущих значений, исключая «подглядывание» в будущее); дилатированных сверток с растущими коэффициентами расширения ($dilation = 1, 2, 4, 8...$) для экспоненциального увеличения рецептивного

поля без роста числа параметров; а также остаточных соединений, облегчающих обучение глубоких сетей.

По сравнению с RNN, TCN обладают рядом преимуществ: параллельная обработка всей последовательности (в отличие от рекуррентных сетей, требующих последовательного прохода), стабильность градиентов (отсутствие затухания или взрыва за счет сверточных операций), гибкое изменение рецептивного поля (путем увеличения числа слоев или дилатации) и низкий расход памяти. В работе [50] был предложен дизайн TimeConvNets с глубокими временными окнами для распознавания выражений лица в реальном времени. Авторы продемонстрировали, что TimeConvNets лучше захватывают быстрые изменения выражений лица и повышают точность классификации, сохраняя низкое время инференса. В работе [51] метод NAC-TCN (Neighborhood Attention with Convolutions TCN) объединил механизм внимания и TCN, что привело к снижению вычислительных и память-затрат при сохранении понимания причинных связей. Несмотря на перечисленные достоинства, TCN могут уступать RNN на последовательностях с очень сложной долгосрочной зависимостью, где рекуррентные вентильные механизмы оказываются более адаптивными.

2.4. Мультимодальное распознавание эмоций (MER)

Несмотря на успехи в распознавании эмоций по отдельным модальностям — речи (SER) и выражению лица (FER), — универсальные системы, опирающиеся только на одну модальность, обладают фундаментальными ограничениями. Речевой сигнал может быть зашумлен или содержать паралингвистические артефакты, не связанные с эмоцией (например, акцент или речевые нарушения). Выражение лица, в свою

очередь, может быть частично скрыто (окклюзия), слабо выражено или не соответствовать вербальному содержанию (например, «ложная улыбка»). В естественном диалоге обе модальности дополняют друг друга: голос передает интенсивность и динамику эмоции, лицо — ее качественную категорию. Именно это наблюдение привело к формированию направления мультимодального распознавания эмоций (Multimodal Emotion Recognition, MER) [10], в котором информация из двух и более каналов (аудио, видео, текст) объединяется для повышения точности, робастности и устойчивости к сбоям отдельных сенсоров.

Современные системы MER решают три основные подзадачи: извлечение признаков из каждой модальности (с использованием моделей, описанных в разделах 3.2 и 3.3), синхронизация модальностей по времени и слияние признаков для получения итогового предсказания.

2.4.1. Классические стратегии слияния модальностей

В литературе по MER традиционно выделяют три уровня слияния модальностей, различающиеся тем, на каком этапе обработки объединяются аудио- и видеопотоки.

Раннее слияние (early fusion). При раннем слиянии признаки из разных модальностей объединяются непосредственно на уровне входных данных или низкоуровневых представлений. Например, конкатенация векторов MFCC и извлеченных из лиц геометрических признаков с последующей подачей в общий классификатор. Преимущество подхода — простота и возможность учета корреляций модальностей на раннем этапе. Недостатки: признаки разных модальностей могут иметь различную размерность и темпоральное разрешение, а также требовать сложной

нормализации. Раннее слияние часто приводит к переобучению, если объем размеченных мультимодальных данных невелик [52].

Позднее слияние (late fusion). При позднем слиянии каждая модальность обрабатывается независимо собственным классификатором, а итоговое решение принимается путем объединения выходных вероятностей (например, усреднением, взвешенным голосованием или обучением мета-классификатора). Основное достоинство — устойчивость к временной асинхронности модальностей и возможность использования разнородных архитектур для каждой модальности. Недостаток — игнорируются взаимодействия между разными модальностями на уровне признаков. В задачах, где модальности сильно коррелируют, позднее слияние уступает более тесной интеграции [53].

Гибридное и динамическое слияние. Компромиссным решением является гибридное слияние, при котором сначала извлекаются независимые признаки каждой модальности, затем эти признаки проходят через слои, моделирующие мультимодальные взаимодействия (например, кросс-внимание), после чего объединенное представление передается в общий классификатор. Динамические подходы, такие как гейтированные сети или механизмы внимания, позволяют адаптивно взвешивать вклад каждой модальности в зависимости от контекста [54]. Именно такие стратегии лежат в основе современных архитектур MER, рассматриваемых ниже.

2.4.2. Современные мультимодальные архитектуры для IEMOSCAP

В рамках нашей работы проводится бенчмарк предлагаемой каскадной системы против нескольких современных подходов на IEMOSCAP

– на одном из наиболее сложных корпусов со спонтанной диалоговой речью. В качестве конкурентов выбраны модели, представляющие различные парадигмы мультимодального слияния: графовое динамическое слияние (MM-NodeFormer), трансформер с кросс-модальным вниманием (SCME+GF), текущий SOTA подход, опубликованный в 2025 году, - GiA-MIC и простой конкатенационный бейзлайн на основе предобученных бэкбонов (ResNet18+GRU).

SCME+GF (Sparse Cross-Modal Encoder + Gated Fusion) [55].

Архитектура SCME+GF была предложена в 2024 году для задачи мультимодальной классификации эмоций. Основная идея – использование разреженного кросс-модального энкодера, который для каждой пары модальностей (аудио и видео) вычисляет взаимное внимание (cross-attention) только над наиболее информативными временными позициями, сокращая вычислительную сложность по сравнению с полным трансформером. Затем признаки разных модальностей пропускаются через гейтированную сеть слияния (Gated Fusion Network), которая обучается динамически взвешивать вклад аудио и видео в зависимости от временного контекста: для кадров, где эмоция ярко выражена визуально, вес видео увеличивается; для кадров с четкой интонацией – вес аудио. Гейтированный механизм позволяет модели адаптироваться к естественным вариациям в диалоге, где то лицо, то голос могут быть более информативны.

MM-NodeFormer (Multimodal Node-Former) [56]. MM-NodeFormer, представленный на Interspeech 2024, является эволюцией графовых динамических сетей для MER. В отличие от предыдущих графовых подходов, MM-NodeFormer строит над каждым временным шагом двудольный граф между аудио-узлами и видео-узлами, а затем применяет

многослойный трансформер с перекрестным вниманием для распространения информации между модальностями. Ключевое нововведение – использование позиционных кодирований, учитывающих не только абсолютное время, но и разницу в темпах изменений аудио и видео. Это особенно важно для IEMOCAP, где мимика может отставать от речи или опережать ее. MM-NodeFormer достигает на IEMOCAP взвешенной точности до 76,1% для шести эмоциональных классов, что является одним из лучших результатов среди не-трансформерных моделей.

GiA-MIC (Gated Interactive Attention with Modality-Invariant Learning Constraints). GiA-MIC — архитектура мультимодального распознавания эмоций, предложенная He с соавторами в 2025 году (Interspeech 2025). В отличие от SCME+GF и MM-NodeFormer, GiA-MIC изначально спроектирована для произвольного набора модальностей (аудио, видео, текст) и основана на двух ключевых компонентах. Первый — gated interactive attention, который адаптивно извлекает модально-специфичные признаки и усиливает эмоциональную информацию за счет попарного взаимодействия между модальностями (audio–visual, audio–text, visual–text). Второй — modality-invariant generator, обучающий инвариантные представления выравниванием кросс-модальных сходств, что снижает влияние гетерогенности распределений признаков. Такой дизайн отвечает двум основным вызовам MER: эффективному извлечению признаков из каждой модальности и надежный мультимодальной фьюжн. На наборе данных IEMOCAP GiA-MIC достигает **WA 80,7% и UA 81,3%** на шести эмоциональных классах, что делает её одной из сильнейших моделей в категории аудиовизуального MER.

ResNet18 + GRU (бейзлайн). В качестве простого, но репрезентативного бейзлайна в работе используется модель, состоящая из: замороженного ResNet18 для извлечения визуальных признаков из каждого кадра видео; усреднения аудиоэмбеддингов (из Wav2Vec 2.0 или MFCC) по времени; конкатенации аудио- и видео-признаков; двунаправленного GRU для учета временной динамики. Хотя данная модель не использует сложных механизмов внимания, она часто служит отправной точкой для сравнения благодаря своей интерпретируемости и легкости реализации. Ожидается, что она уступит более специализированным архитектурам, но позволит оценить, какой объем сложности действительно необходим для получения высоких результатов на IEMOCAP.

3. Обзор датасетов для задачи мультимодальной классификации эмоций

Для обучения моделей, а также для корректной валидации результатов необходимо подобрать датасеты. Наша архитектура подразумевает использование датасетов для двух задач: классификация нейтральности по речи, и определение эмоции по выражению лица.

Для более качественного, эффективного и сбалансированного обучения мы будем комбинировать датасеты при обучении, то есть использовать сразу несколько для обучения каждой модели. Это позволит модели обучиться на различных данных, не зависящих от конкретного языка датасета, национальности авторов или других уникальных признаков датасета.

Важно также различать датасеты, которые мы будем использовать для предобучения наших моделей и датасеты, на которых будем измерять качество, так как если для обеих целей использовать одни и те же датасеты, то в результате мы получим завышенные результаты из-за “утечки таргета” (Target leakage).

В данной работе для построения эффективной мультимодальной системы распознавания эмоций были использованы три датасета: RAVDESS, CREMA-D и IEMOCAP. Первые два использовались для предварительного обучения аудио и видео моделей, а IEMOCAP - в качестве целевого датасета для тонкой настройки и финального замера качества архитектуры. Данные три датасета были выбраны, так как они широко используются в работах по классификации эмоций, содержат чистые аудио

и хорошо различимые видео данные, а также содержат сразу обе модальности.

3.1. RAVDESS (Ryerson Audio-Visual Database of Emotional Speech and Song)

Первым датасет, использованным в данной работе, является **RAVDESS** [2]. В нем содержатся студийные записи разговоров актеров. Всего: 7356 аудиовизуальных записей, записанных 24 профессиональными актерами, как мужчинами, так и женщинами. Все фрагменты записаны с высокой частотой дискретизации (48 кГц). Язык датасета - английский.

Датасет содержит 8 классов эмоций: нейтральная, спокойная, радость, грусть, страх, гнев, отвращение и удивление. А также 5 категорий для вокального исполнения, которые не использовались в данной работе. Каждая запись маркируется уровнем интенсивности эмоции: нормальный или высокий. Каждое видео содержит ровно одну эмоцию.

Для нашего исследования использовались только речевые аудио и видео фрагменты (пение не использовалось). Аудиодорожки были приведены к моноформату с частотой 16 кГц - для большей универсальности и применимости модели к другим датасетам с частотой 16 кГц, а также для повышения производительности модели.

RAVDESS был выбран в качестве основного датасета для предобучения видео модели, поскольку содержит хорошо размеченные, синхронизированные аудио и видеозаписи с хорошо видимыми выражениями лиц.

3.2. CREMA-D (Crowd-sourced Emotional Multimodal Actors Dataset)

CREMA-D [3] содержит 7442 видео, записанных 48 мужчинами и 43 женщинами. В отличие от RAVDESS это добровольцы, а не профессиональные актеры, из-за чего эмоции менее наигранные. Также среди участников были различные этнические и возрастные группы.

Использование датасета CREMA-D в дополнение к RAVDESS обеспечивает большее разнообразие лицевых особенностей и обучение на более естественных эмоциях. Каждый клип также содержит произнесение одной фразы с одной из шести эмоциональных окрасок: нейтральная, радость, грусть, гнев, страх, отвращение. Как можно заметить, эмоции совпадают с первым датасетом, за исключением двух отсутствующих: спокойная и удивленная - некоторый дисбаланс классов важно будет учитывать при обучении.

Запись датасета также велась в студийных условиях с частотой дискретизации 16 кГц для аудио и разрешением видео 640x480 пикселей.

CREMA-D использовался совместно с RAVDESS для предварительного обучения аудио классификатора. Объединение данных привело к повышению обобщающей способности аудиогейта перед итоговым замером качества на IEMOCAP.

3.3. IEMOCAP (Interactive emotional dyadic motion capture database)

IEMOCAP [4] считается одним из фундаментальных наборов данных для классификации эмоций в диалоговой речи. В нем содержатся около 12 часов аудиовизуальных записей разговоров между 10 актерами (5 мужчин и

5 женщин), разбитых на 5 сессий. Каждая такая сессия включает в себя диалог по заранее написанному сценарию, а также спонтанные импровизации на определенную тему. Категории эмоций проставлены для отдельных высказываний – каждому такому фрагменту соответствует одна эмоция (гнев, радость, грусть, нейтральность, волнение, усталость, восхищение, страх и «другая» эмоция).

Существует принципиальное отличие от RAVDESS и CREMA-D – в данном датасете спонтанный, диалоговый характер речи и мимики, более приближенный к реальному общению людей. Эмоции здесь менее утрированы, часто появляются между состояниями в пределах одного высказывания. Кроме того, видео содержат естественные окклюзии, различные варианты освещения и повороты головы, характерные для реальных условий общения. Из-за этого IEMOCAP более сложный датасет для нашей задачи, но одновременно с этим является более репрезентативным бенчмарком для оценки качества мультимодальных систем распознавания эмоций.

В данном исследовании IEMOCAP выступает в качестве целевого датасета. Модели, предварительно обученные на RAVDESS и CREMA-D, дообучаются на сессиях 1-4 с валидацией на сессии 5. Модели классифицируют аудио и видео по 8 классам эмоций. «Другая» эмоция была исключена из датасета из-за крайне малого количества примеров, а также отсутствия в датасетах предобучения.

3.4. Другие датасеты для мультимодального распознавания эмоций

Помимо RAVDESS, CREMA-D и IEMOCAP, в области мультимодального распознавания эмоций существует ряд других широко известных датасетов. Некоторые из них были рассмотрены в рамках настоящего исследования, однако по разным причинам были исключены из итогового пайплайна. Ниже приводится краткий обзор этих датасетов и обоснование отказа от их использования.

Aff-Wild. Aff-Wild представляет собой крупный видео-датасет, содержащий спонтанные выражения лиц в неконтролируемых условиях (in the wild) с аннотациями непрерывных аффективных измерений валентности (Valence) и возбуждения (Arousal) [9]. Он включает около 300 видео (более 2000 минут данных) из YouTube и широко используется для обучения и оценки алгоритмов распознавания непрерывных аффективных состояний. Однако в настоящей работе Aff-Wild не использовался по следующим причинам. Во-первых, датасет ориентирован на задачу регрессии (предсказание валентности и возбуждения), в то время как настоящая работа решает задачу классификации дискретных эмоциональных категорий. Во-вторых, Aff-Wild является одномерным (только видео модальность), тогда как предлагаемая архитектура является мультимодальной, объединяющей аудио и видео. В-третьих, видео включают значительные вариации качества и условий съемки (разрешение, освещение), что делает их предобработку сложнее по сравнению с лабораторными датасетами, а для оценки качества был выбран более стандартный в этой сфере датасет IEMOCAP.

Aff-Wild2. Aff-Wild2 является расширенной версией Aff-Wild и представляет собой крупномасштабный мультимодальный (аудио-видео) датасет, который включает аннотации для трех задач: предсказание валентности и возбуждения, распознавание выражений лиц и детектирование лицевых действий (Action Unit) [11]. На его основе ежегодно проводится международная соревнования ABAW (Affective Behavior Analysis in-the-wild). При этом также существует статическая версия s-Aff-Wild2, фокусирующаяся на отдельных изображениях. Несмотря на то, что Aff-Wild2 является мультимодальным датасетом, он был исключен из данного исследования по следующим причинам. Во-первых, Aff-Wild2 ориентирован главным образом на задачи предсказания валентности и возбуждения (регрессия), в то время как данная работа решает задачу классификации на 6 дискретных эмоциональных классов (neutral, happy, sad, angry, excited, frustrated). Во-вторых, наиболее близкая по задаче к IEMOCAP задача распознавания выражений лиц в Aff-Wild2 использует другой набор дискретных эмоций, отличный от шести выбранных в данной работе. В-третьих, датасет значительно сложнее в предобработке (значительные вариации качества, разнообразие условий съемки, неуправляемые сцены), что требует больших вычислительных ресурсов.

MELD (Multimodal EmotionLines Dataset). MELD является крупным мультимодальным датасетом для анализа эмоций в диалогах. Он содержит синхронизированные аудио, видео и текстовые данные для более 13 000 высказываний из 1 400 диалогов сериала «Друзья» [57]. Основным преимуществом MELD является его размер и наличие текстовой модальности. Однако в рамках настоящей работы MELD не использовался

по следующим причинам. Во-первых, MELD содержит преимущественно постановочные диалоги из телесериала, что снижает его репрезентативность для спонтанной речи по сравнению с IEMOCAP. Во-вторых, видео в MELD извлечены из телевизионного контента, поэтому мимика и жесты актеров могут быть избыточно выразительными, что не соответствует реальным условиям диалога между незнакомыми людьми. В-третьих, наличие текстовой модальности создает риск несправедливого сравнения с моделями, которые ее не используют, а в данном исследовании текстовые данные не обрабатываются. В-четвертых, постановочный характер MELD приводит к тому, что модель, обученная на нем, может страдать от переобучения на стиль конкретного телешоу.

RAMAS (Russian Multimodal Corpus of Dyadic Interaction) [58].

RAMAS представляет собой русскоязычный мультимодальный корпус диалогического взаимодействия, содержащий высококачественные видеозаписи лиц, речь, данные захвата движения, а также такие физиологические сигналы, как электродермальная активность и фотоплетизмограмма. Корпус включает 6 базовых эмоций (гнев, грусть, отвращение, радость, страх и удивление) и был размечен 21 аннотатором. Несмотря на высокое качество и релевантность для задач реального времени, RAMAS был исключен из настоящего исследования по следующим причинам. Во-первых, на момент проведения исследования RAMAS перестал быть доступным для скачивания из открытых источников. К моменту начала работы лицензионные соглашения были изменены, и датасет был закрыт для публичного доступа, что сделало его использование невозможным. Во-вторых, RAMAS записан на русском языке, что создает потенциальные проблемы с обобщением на целевой датасет IEMOCAP

(английский язык). В-третьих, RAMAS имеет ограниченный объем данных (примерно 7 часов аудио), что может быть недостаточно для обучения нейросетевых моделей без дополнительной аугментации.

Таким образом, перечисленные выше датасеты были исключены из итогового пайплайна по различным причинам. Как следствие, основное внимание в работе сосредоточено на трех датасетах: RAVDESS, CREMA-D и IEMOCAP, которые в совокупности обеспечивают высококачественные размеченные данные, репрезентативность и достаточный объем для обучения и оценки каскадной системы распознавания эмоций.

3.5. Стратегия использования датасетов для обучения

Как было показано в предыдущих разделах, RAVDESS и CREMA-D представляют собой лабораторные датасеты, содержащие студийные записи актерской речи с хорошо выраженными, часто утрированными эмоциональными проявлениями. Напротив, IEMOCAP является существенно более сложным и реалистичным набором данных, включающим спонтанные диалоги с естественными вариациями мимики, освещения и частичными окклюзиями. Прямое обучение мультимодальной модели на RAVDESS и CREMA-D с последующим тестированием на IEMOCAP приводит к значительному падению качества из-за доменного сдвига (domain shift) между актерской и спонтанной речью. Для преодоления этого разрыва в настоящей работе используется двухэтапная стратегия: 1) предобучение компонентов на лабораторных данных с интенсивной аугментацией, 2) дообучение итогового каскада на IEMOCAP с замороженным визуальным энкодером.

3.5.1. Предобучение на RAVDESS и CREMA-D

Аудиогейт (бинарный классификатор «нейтрально / не нейтрально») обучается на объединенном наборе данных RAVDESS и CREMA-D. Аудиодорожки всех записей приводятся к моноформату с частотой дискретизации 16 кГц. Метки преобразуются следующим образом: для RAVDESS нейтральная (emotion = 01) и спокойная (emotion = 02) эмоции кодируются как 0 = neutral, все остальные эмоции — как 1 = non-neutral; для CREMA-D метка NEU кодируется как 0, все остальные — как 1. Спикеро-независимое разбиение выполняется так, что последние 20% дикторов (актеров) каждого датасета попадают в тестовую выборку, а оставшиеся — в обучающую. Это гарантирует отсутствие пересечения по дикторам между обучением и тестированием.

Видеомодель (многоклассовая классификация эмоций) обучается только на видеоданных RAVDESS. Из каждого видеофайла равномерно извлекаются 16 кадров, выполняется детекция лица с помощью MediaPipe BlazeFace, кроп и нормализация до размера 224×224 пикселя. Эмоциональная метка используется непосредственно из имени файла (8 классов, от 0 до 7). Спикеро-независимый сплит также основан на 20% актеров в тесте.

3.5.2. Оффлайн аугментация данных

Для повышения обобщающей способности и снижения влияния доменного сдвига применяется офлайн-аугментация с коэффициентом расширения $K=3$. Каждая запись обучающей выборки дополняется тремя независимыми копиями, сгенерированными со случайными параметрами аугментации; оригинальная запись сохраняется без изменений. Таким

образом, итоговый обучающий набор становится в 4 раза больше исходного (оригинал + 3 аугментированные копии). Тестовая выборка никогда не аугментируется.

Аудиоаугментация выполняется с помощью библиотеки audiomentations [59] и включает следующие преобразования, применяемые к сырой волновой форме до извлечения признаков, см. Таблицу 1.

Таблица 1. Используемые аудио аугментации.

Аугментация	Параметры	Вероятность	Описание
AddGaussianSNR	SNR = 5-25 дБ	P = 0.6	Добавление гауссовского шума на аудио
Shift	Сдвиг ± 1 с, заполнение тишиной	P = 0.5	Временной сдвиг сигнала
Gain	Усиление от -9 до +6 дБ	P = 0.5	Изменение громкости
TimeStretch	Растяжение 0.9-1.1, длина сохраняется	P = 0.4	Растяжение или сжатие сигнала (изменение скорости речи)
PitchShift	Сдвиг высоты ± 2 полутона	P = 0.4	Изменение высоты тона

Каждая аугментированная копия генерируется с независимо семплированными параметрами. Случайное начальное число (seed) фиксировано для воспроизводимости.

Видеоаугментация выполняется с критическим требованием per-clip-consistency: все 16 кадров одного видеофрагмента (клипа) должны быть преобразованы с использованием одного и того же набора случайных параметров, иначе временная согласованность будет нарушена, что негативно скажется на работе темпоральных агрегаторов (BiGRU, BiLSTM, TCN). Аугментация разделена на две стадии конвейера:

Стадия 1 (clip_aug) – геометрические и цветовые преобразования, применяемые к uint8-тензору клипа ($T \times 3 \times H \times W$) после детекции лиц и кропа, см. Таблицу 2.

Таблица 2. Используемые видео аугментации, стадия 1.

Аугментация	Параметры	Вероятность	Описание
RandomResizedCrop	Масштаб 0.85-1.0, соотношение сторон 0.9-1.1	всегда	Случайное вырезание области с масштабированием до 224x224
RandomHorizontalFlip	-	$P = 0.5$	Зеркальное отражение по горизонтали
ColorJitter	Яркость, контраст, насыщенность ± 0.2	$P = 0.8$	Случайное изменение цветовых характеристик изображения
GaussianBlur	Ядро 3, sigma 0.1-1.0	$P = 0.3$	Сглаживание с помощью гауссовского фильтра

Стадия 2 (clip_erase) – RandomErasing, применяемый только к аугментированным копиям (но не к оригинальным) на этапе нормализованного тензора (ImageNet-статистики), непосредственно перед подачей в бэкбон, см. Таблицу 3.

Таблица 3. Используемые видео аугментации, стадия 2.

Аугментация	Параметры	Вероятность	Описание
RandomErasing	Площадь прямоугольника 2-10% от площади кадра, ratio 0.3-3.3	$P = 0.5$	Случайное закрашивание прямоугольной области нулями

Такое разделение позволяет увеличить разнообразие обучающих примеров, сохранив при этом пространственно-временную структуру видеопоследовательности.

3.5.3. Разделение ролей датасетов

На этапе предобучения используются только RAVDESS (и CREMA-D для аудио) в качестве источников данных. Веса предобученных моделей сохраняются для последующего использования.

На этапе построения итогового каскада сохраненные предобученные веса загружаются в качестве инициализации. Модели дообучаются на IEMOCAP с замороженным визуальным энкодером (EmotiEffNet или MobileNetV3-Small), чтобы сохранить пространственные представления, полученные на RAVDESS, и одновременно адаптировать классификационные головы к более сложным и естественным условиям диалоговой речи.

3.5.4. Обоснование эффективности выбранной стратегии

Многочисленные исследования подтверждают, что предварительное обучение на крупных датасетах актерской речи с последующей тонкой настройкой на IEMOCAP позволяет получить веса моделей, релевантные для задачи классификации нейтральных и эмоциональных состояний, а также сократить объем данных, необходимых для адаптации к спонтанной речи [4], [5]. Применение офлайн-аугментации с $K=3$ дополнительно снижает риск переобучения под лабораторные условия и повышает устойчивость к естественным вариациям (шум, изменение громкости, повороты головы, изменения освещения). Важно отметить, что RandomErasing для видео применяется только к аугментированным копиям, что позволяет не искажать оригинальные примеры, сохраняя базу для стабильного обучения.

За счет выбранной стратегии мы сможем проверить, будет ли преимущество у предобученной модели, по сравнению с непредобученной или нет. Таким образом, выбранный набор датасетов и стратегия обучения позволяют:

- использовать высококачественные лабораторные данные для формирования базовых представлений аудио- и видеомоделей;
- за счет аугментаций повысить обобщающую способность и уменьшить доменный сдвиг;
- адаптировать итоговый каскад к сложным, естественным условиям диалогового взаимодействия при дообучении на IEMOCAP.

4. Методология предлагаемой системы

В данной главе описывается разработанная двухстадийная каскадная система мультимодального распознавания эмоций. В отличие от традиционных подходов, обрабатывающих аудио и видео модальности параллельно на каждом входном фрагменте, предлагаемая архитектура использует легкий аудиогейт для бинарной классификации «нейтрально / не нейтрально». Тяжелая видео модель запускается только в случае обнаружения эмоционально окрашенной речи, что позволяет существенно сократить вычислительные затраты в сценариях, где преобладает нейтральный диалог.

4.1. Общая архитектура двухстадийного каскада

Предлагаемая система предназначена для потокового распознавания эмоций в диалоговой речи. Входными данными являются аудиосигнал (речь человека, 16 кГц, моносигнал) и видеопоследовательность (кадры лица человека), соответствующие одной реплике говорящего. Выходом системы является одна из четырех эмоциональных категорий: нейтральная, радость, грусть, гнев (данный набор соответствует стандартным бенчмаркам на целевом датасете IEMOCAP).




Рисунок 1. Предлагаемая архитектура.

Архитектура представляет собой жёсткий двухстадийный каскад (рисунок 1):

1. **Аудиогейт** - лёгкая модель, обрабатывающая только аудио и принимающая бинарное решение: «нейтрально» (класс 0) или «не нейтрально» (класс 1).
2. **Бимодальная голова** - объединяет видео- и аудиомодальность. Видео-ветка построена на базе видеомодели, которая будет выбрана по результатам сравнения; аудио-ветка архитектурно повторяет аудиогейт, и получает тот же самый тензор признаков, что и гейт. Голова запускается только при положительном решении гейта.

Если аудиогейт предсказал «нейтрально», система немедленно возвращает метку «нейтрально», не вызывая детектор лиц и саму бимодальную голову. При предсказании «не нейтрально» управление передаётся бимодальной голове, которая классифицирует эмоцию в один из четырёх классов. Такая селективная активация радикально сокращает вычислительные затраты на нейтральных репликах, составляющих, согласно статистике, значительную долю диалогов [60].

Выбор аудиомодальности в качестве первой стадии обусловлен её принципиально более низкой вычислительной сложностью по сравнению с видео. Даже легкие нейросетевые аудиомодели требуют на порядок меньше операций, чем детекция лиц, кроп, нормализация и прогон 16 кадров через с последующей обработкой. Таким образом, архитектура достигает компромисса между качеством распознавания (за счёт использования полной мультимодальной информации на эмоциональных репликах) и ресурсоэффективностью (за счёт пропуска нейтральных реплик). Дополнительный выигрыш даёт однократное вычисление аудио признаков: один и тот же тензор подаётся и в гейт, и в аудио-ветку головы, полностью исключая повторную экстракцию признаков

4.2. Аудио модель: бинарная классификация

Первой стадией предлагаемой архитектуры является аудиогейт – бинарный классификатор, определяющий, содержит ли речевой фрагмент эмоциональную нагрузку. В отличие от многоклассовой классификации эмоций, бинарная задача «нейтрально / не нейтрально» является более простой и может быть решена с высокой точностью даже легкими моделями. Основные требования к аудиогейту в контексте реального

времени: высокая скорость инференса (менее 20 мс на фрагмент), компактный размер модели (единицы мегабайт) и приемлемая точность (особенно по классу «нейтрально», чтобы не пропускать ложное срабатывание видеоветви). В данном разделе описываются подготовка данных, процедура аугментации и сравнительное исследование четырех подходов: DistilHuBERT с линейным классификатором, сверточная сеть на лог-мел-спектрограммах (MelCNN), классический пайплайн MFCC + SVM и Wav2Vec 2.0 с MLP-головой.

4.2.1. Подготовка данных и спикеро-независимое разбиение

Для повышения обобщающей способности и снижения риска переобучения применяется офлайн-аугментация с коэффициентом расширения $K=3$. Каждый файл обучающей выборки дополняется тремя копиями, сгенерированными со случайными параметрами аугментации; оригинальная запись сохраняется без изменений. Тестовая выборка никогда не аугментируется.

Аугментации реализованы с помощью библиотеки `audiomentations` и включают пять преобразований, применяемых последовательно к сырой волновой форме, см. Таблицу 1.

- `AddGaussianSNR` ($p=0,6$): добавление гауссовского шума с отношением сигнал/шум в диапазоне 5–25 дБ.
- `Shift` ($p=0,5$): временной сдвиг на ± 1 секунду с заполнением освободившегося края тишиной (без циклического переноса).
- `Gain` ($p=0,5$): изменение громкости путем умножения на коэффициент, соответствующий диапазону от -9 до $+6$ дБ.

- TimeStretch ($p=0,4$): растяжение или сжатие сигнала во времени с коэффициентом $0,9-1,1$; длина выходного сигнала сохраняется за счет обрезки/дополнения.
- PitchShift ($p=0,4$): сдвиг высоты тона на ± 2 полутона без изменения длительности.

Каждая из трех аугментированных копий генерируется с независимо семплированными параметрами. Случайное начальное число фиксировано для воспроизводимости. После аугментации обучающая выборка расширяется до 28668 файлов (4448 нейтральных, 24220 эмоциональных), что способствует более устойчивому обучению модели, особенно для миноритарного класса «нейтрально».

4.2.2. Сравнимые архитектуры аудиомоделей

В рамках экспериментального исследования сравниваются четыре подхода, различающиеся методами извлечения признаков и классификаторами.

4.2.3. DistilHuBERT + Linear

В качестве мощного предобученного аудиоэнкодера используется модель ntu-spml/distilhubert [26]. DistilHuBERT представляет собой дистиллированную версию HuBERT с 23,5 млн параметров и размером скрытого состояния 768. Бэкбон полностью заморожен (параметры не обновляются в процессе обучения). Для каждого аудиофрагмента вычисляется последовательность скрытых состояний последнего слоя, затем выполняется усреднение по временной оси, формируя вектор признаков размерности 768. Поверх этого вектора обучается простой

линейный классификатор Linear (768-2) с 1,5 тыс. параметров. Обучение проводится с использованием PyTorch Lightning в течение 200 эпох с оптимизатором Adam (скорость обучения $1e-3$, L2-регуляризация $1e-4$), размер батча 32. Функция потерь – кросс-энтропия без взвешивания классов.

4.2.4. Log-Mel + CNN (MelCNN)

Этот подход основан на сверточной нейронной сети, принимающей на вход лог-мел-спектрограмму. Признаки извлекаются с помощью библиотеки librosa со следующими параметрами: частота дискретизации 16 кГц, число мел-фильтров $n_mels = 64$, размер быстрого преобразования Фурье $n_fft = 1024$, шаг $hop_length = 512$, окно Ханна. Полученная спектрограмма обрезается или дополняется нулями до фиксированного числа временных кадров – 128. Нормализация выполняется по предварительно вычисленным среднему значению и стандартному отклонению обучающей выборки.

Архитектура MelCNN состоит из трех сверточных блоков, за которыми следует классификатор. Каждый блок включает: сверточный слой (Conv2d) с ядром 3×3 и padding 1, батчевую нормализацию (BatchNorm2d), нелинейность ReLU и операцию максимального пуллинга (MaxPool2d) с окном 2×2 . Количество каналов последовательно увеличивается: 16 - 32 - 64. После третьего блока размерность признакового тензора составляет $64 \times 8 \times 16$ (каналы $\times$ время $\times$ частота). Тензор выпрямляется (flatten) и подается в классификатор: полносвязный слой с 256 нейронами, ReLU, dropout (0,5) и выходной слой Linear (256-2). Общее число параметров модели – 2,1 млн.

Для борьбы с дисбалансом классов в функции кросс-энтропии используются веса классов, обратно пропорциональные частоте встречаемости: для нейтрального класса вес = $7507 / 1375 \sim 5,46$, для эмоционального – 1. Нормализованные веса: Neutral 3,223, Emotional 0,592. Обучение проводится в течение 50 эпох с оптимизатором Adam (начальная скорость обучения $1e-5$, L2-регуляризация $2e-6$) и планировщиком CosineAnnealingLR с минимальной скоростью $1e-7$. Размер батча – 32.

4.2.5. MFCC + SVM

Классический ML подход включает извлечение 40 мел-частотных кепстральных коэффициентов на кадр (длина кадра 25 мс, шаг 10 мс), к которым добавляются дельта- и дельта-дельта-коэффициенты. Для представления целого высказывания вычисляются среднее значение и стандартное отклонение каждого коэффициента по всем кадрам, что дает 120-мерный вектор признаков ($40 \text{ MFCC} \times 3 \text{ статистики}$). Признаки нормализуются с помощью StandardScaler. В качестве классификатора используется метод опорных векторов с радиальным базисным ядром (SVC, $C=10$, $\text{gamma}='scale'$).

4.2.6. Wav2Vec 2.0 + MLP

Четвертый подход использует предобученную модель facebook/wav2vec2-base [24] в качестве замороженного экстрактора признаков. Аудиофрагменты обрезаются до 6 секунд. Модель возвращает последовательность эмбеддингов размерности 768, из которой маскированный средний пулинг (с учетом маски внимания, чтобы игнорировать паддинг) формирует вектор фиксированной длины. Голова представляет собой двухслойный многослойный перцептрон: Linear(768 -

256) - ReLU - Dropout(0,3) - Linear(256 - 2), содержащий 197 тыс. обучаемых параметров. Веса классов для кросс-энтропии смягчены взятием квадратного корня (sqrt) от обратных частот с последующей нормализацией: Neutral 1,400, Non-neutral 0,600.

Обучение выполняется в ручном цикле в течение 30 эпох с оптимизатором AdamW (скорость обучения $1e-3$, weight decay 0,01), размер батча 64, планировщик с линейным разогревом (warmup 10% от числа итераций) и последующим косинусным затуханием, градиентный клиппинг на уровне 1,0. Сохраняется лучшая модель по взвешенной F1-мере.

4.2.7. Оценка баланса качества и производительности и выбор оптимального аудиогейта

Можно заметить, что начальные параметры оптимизаторов, шедулеров, LR и weight decay отличаются у разных моделей. Важно, так как на данном этапе мы выбираем модели для нашей итоговой архитектуры, а не строим бенчмарк качества – параметры (LR, WD) и используемые планировщики / оптимизаторы подбирались вручную. Это было необходимо для получения наилучшего качества каждого подхода и использования самых лучших подходов в итоговой архитектуре. То есть для каждой модели проводились эксперименты с замером качества на разных гиперпараметрах и в данном разделе представлены итоговые наилучшие конфигурации.

Все модели оцениваются на спикеро-независимой тестовой выборке (1715 файлов, 22 диктора). Метрики включают ассурасу, macro F1, precision, recall по каждому классу, а также среднее время инференса на файл (в миллисекундах) и размер модели/пайплайна (в мегабайтах). Инференс

измеряется на устройстве Apple MacBook M1 Pro, с использованием MPS (аналог CUDA).

Таблица 4. Сравнение аудио моделей.

Модель	Accuracy	Macro F1	Precision	Recall	Инференс, мс/файл	Размер пайплайна, МБ
DistilHuBERT + Linear	0.9044	0.8348	0.8070	0.8750	15.0	89.62
Log-Mel + CNN	0.8274	0.7344	0.7073	0.8031	3.4	8.09
MFCC + SVM	0.7749	0.6379	0.6247	0.6709	4.5	21.47
Wav2Vec 2.0 + MLP	0.8653	0.7300	0.7403	0.7212	40.9	360.75

Как видно из таблицы, наивысшее качество по всем метрикам качества демонстрирует **DistilHuBERT + Linear** (ассурасу 90,4%, макро F1 0.835, recall 0.83). При этом модель имеет умеренный размер (89.6 МБ) и достаточно быстрое время инференса (15 мс). Однако для каскадной системы реального времени наиболее критичными параметрами являются скорость работы и компактность, поскольку аудиогейт обрабатывает каждую реплику.




Рисунок 2. График сравнения аудио моделей.

На Рисунке 2 видно, что скорость инференса DistilHuBERT в ~4 раза превышает скорость инференса моделей Log-Mel + CNN и MFCC + SVM, а размер пайплайна в целых 11 раз больше, по сравнению с Log-Mel + CNN.

MelCNN (Log-Mel+CNN) обеспечивает лучшее сочетание качества и эффективности: при несколько более низкой accuracy (82.7%) и, что важнее, второй среди оцениваемых метрикой Macro F1 (73.4%), модель имеет наименьший размер (8.1 МБ) и самое быстрое время инференса (3.4 мс на файл). Ее полнота (0.77) достаточно высока, чтобы не пропускать нейтральные фрагменты в видео модель.

Wav2Vec2 + MLP показывает высокую общую точность, но низкий recall (0.51), что означает, что почти половина нейтральных реплик будет ошибочно направлена в видео модель. Кроме того, модель имеет огромный размер (360 МБ) и самую низкую скорость инференса (41 мс). По результатам видно, что модель слишком сложная для нашей задачи бинарной классификации.

MFCC + SVM является классическим бейзлайном, но существенно уступает нейросетевым методам (accuracy 77.5%, macro F1 0.638), особенно плохо распознает нейтральный класс (F1=0.42). Несмотря на это, модель показывает хорошую скорость инференса, а также модель небольшая по размеру, но 9.6% разницы по F1 Score, по сравнению с MelCNN является критической проблемой.

На основании проведенного сравнения для использования в качестве аудиогейта каскадной системы выбрана модель MelCNN. Данный выбор обусловлен:

- минимальным размером модели (8 МБ) и наименьшим временем работы (3.4 мс);
- приемлемой полнотой (0.77) и Macro F1 (73.4%), обеспечивающей эффективную фильтрацию нейтральных реплик.

Веса модели MelCNN сохраняются в файл `mel_cnn.pt` (вместе с `meta.json`, содержащим параметры нормализации). В дальнейшем этот чекпойнт используется дважды:

- как самостоятельный бинарный гейт;
- как источник инициализации аудио-ветки бимодальной головы.

Такой подход гарантирует, что гейт и аудио-часть головы оперируют одинаковыми низкоуровневыми признаками, извлечёнными из лог-мел-спектрограммы.

4.3. Видео модель: классификация выражений лиц

Вторая стадия каскада активируется только при положительном решении аудиогейта. Она объединяет видео- и аудиомодальности в единой бимодальной голове. Видео-составляющая этой головы агрегирует пространственные признаки лица, извлечённые экстрактором, которые затем передаются в классификатор эмоций.

Задача видео модели – по 16ти равномерно распределенным кадрам видеосфрагмента определить одну из шести эмоций (нейтральная, радость, грусть, гнев, волнение, фрустрация) на целевом датасете IEMOCAP. Однако предобучение видео модели выполняется на датасете RAVDESS (8 эмоций), поскольку он содержит хорошо размеченные и синхронизированные

видеозаписи с четкими выражениями лиц. Обучение включает три этапа: 1) детекция лиц и предобработка кадров, 2) извлечение пространственных признаков с помощью замороженного бэкбона, 3) временная агрегация признаков и классификация. Сравниваются два бэкбона (MobileNetV3-Small и EmotiEffNet) и три темпоральных агрегатора (BiGRU, BiLSTM, TCN). После предобучения лучшая конфигурация адаптируется под 6 классов IEMOCAP и используется в каскаде.

Обучение на датасете с большим количеством эмоций (8 в датасете RAVDESS) предоставляет нам больше возможностей для теста нашей модели на различных датасетах. Соответственно, для предсказания 4 классов на IEMOCAP нам требуется сделать маппинг результатов модели. При этом, если бы мы обучались на датасете IEMOCAP и затем хотели бы замерить качество на наборе данных RAVDESS – модели бы пришлось из предобученных 4 эмоций каким-то образом получать 8 эмоций, а так как модель не знает дополнительные два класса – такое предобучение было бы неоправданно и скорей всего ухудшало бы метрики качества.

4.3.1. Детекция лиц и предобработка видеокадров

Для каждого видеофайла из датасета RAVDESS равномерно извлекаются 16 кадров с помощью cv2.VideoCapture и np.linspace. Если число кадров в видео меньше 16, последний кадр дублируется для достижения требуемой длины. Каждый кадр преобразуется из цветового пространства BGR (используемого OpenCV) в RGB, после чего выполняется детекция лица с использованием MediaPipe BlazeFace в конфигурации blaze_face_short_range.tflite [34]. Данная модель была выбрана по причинам, изложенным в разделе 3.3.1: субмиллисекундное время инференса на GPU,

малый размер (INT8-версия – несколько сотен килобайт), наличие встроенной регрессии шести ключевых точек лица

Детектор возвращает ограничивающую рамку лица. Для повышения надежности к небольшим смещениям к рамке добавляется паддинг 10% от ее ширины и высоты, затем область лица обрезается и масштабируется до фиксированного размера 224×224 пикселя (билинейная интерполяция). В случае, если лицо не обнаружено (например, при сильном повороте головы, окклюзии или экстремальном освещении), применяется fallback-механизм: центральный квадратный кроп кадра с последующим масштабированием до 224×224 . Такая стратегия обеспечивает устойчивость конвейера к редким сбоям детектора.

После обработки всех 16 кадров формируется тензор клипа размерностью (16, 3, 224, 224) с типом данных uint8. Для ускорения последующего обучения все клипы обучающей и тестовой выборки предварительно обрабатываются и кэшируются в памяти. Данная процедура выполняется один раз перед началом обучения моделей.

4.3.2. Оффлайн аугментация видеоклипов

Для повышения обобщающей способности видеомодели и снижения риска переобучения на ограниченном наборе дикторов RAVDESS (всего 24 актера) применяется офлайн-аугментация с коэффициентом расширения $K=3$. Обучающая выборка (1200 видео, 20 актеров) дополняется тремя аугментированными копиями каждого клипа, в результате чего итоговый обучающий набор увеличивается в 4 раза (4800 клипов). Тестовая выборка

никогда не аугментируется. Случайное начальное число (`seed=42`) фиксировано для воспроизводимости.

Ключевым требованием к видеоаугментации является `per-clip-consistency`: все 16 кадров одного клипа должны быть преобразованы с использованием одного и того же набора случайных параметров. Если бы каждый кадр аугментировался независимо, временная согласованность была бы нарушена: например, лицо могло бы «дрожать» или менять цвет от кадра к кадру, что дезорганизует работу темпоральных агрегаторов (BiGRU, BiLSTM, TCN), которые ожидают плавной мимической динамики.

Аугментации реализованы с помощью библиотеки `torchvision.transforms.v2` и разделены на две стадии: геометрические/цветовые преобразования (`clip_aug`), применяемые к `uint8`-тензору клипа после детекции лиц, и операция случайного стирания (`clip_erase`), применяемая только к аугментированным копиям на этапе нормализованного `float`-тензора.

Стадия 1 – `clip_aug` (геометрия и цвет). Преобразования применяются ко всем 16 кадрам клипа одновременно, с едиными параметрами для всего клипа. Состав и параметры приведены в Таблице 2.

Стадия 2 – `clip_erase` (`RandomErasing`). Операция случайного стирания (также известная как `cutout`) применяется только к аугментированным копиям (оригинальные клипы не подвергаются стиранию). Это сделано для того, чтобы не искажать исходные примеры, сохраняя базу для стабильного обучения. `RandomErasing` закрашивает прямоугольную область на изображении нулями (после нормализации), что вынуждает модель не полагаться на отдельные пиксели или локальные

текстуры. Операция выполняется на этапе нормализованного float-тензора (после приведения к Imagenet-статистикам: $\text{mean} = [0,485, 0,456, 0,406]$, $\text{std} = [0,229, 0,224, 0,225]$), непосредственно перед подачей в бэкбон. Параметры приведены в Таблице 3.

Важно отметить, что RandomErasing не нарушает per-clip-consistency, поскольку применяется к каждому кадру клипа с одинаковыми параметрами (координаты и размер прямоугольника фиксированы для всего клипа). Это сохраняет пространственную когерентность: «вырезанная» область движется вместе с лицом от кадра к кадру.

После аугментации обучающая выборка расширяется до 4800 клипов, тестовая (240 видео) остается без изменений. Все аугментированные копии сохраняются в памяти в виде тензоров признаков после извлечения бэкбоном, что позволяет повторно использовать их на этапах обучения темпоральных агрегаторов без повторного прогона детекции лиц и сверточных бэкбонов.

4.3.3. Бэкбоны для извлечения пространственных признаков

После предобработки и аугментации каждый клип представляет собой тензор размерностью (16, 3, 224, 224) – 16 кадров, три цветовых канала, пространственное разрешение 224×224 пикселя. На следующем этапе каждый кадр независимо пропускается через сверточную нейронную сеть (бэкбон), которая преобразует изображение лица в компактный вектор пространственных признаков. В настоящей работе сравниваются два бэкбона, различающихся архитектурой и характером предобучения: универсальный MobileNetV3-Small и специализированный EmotiEffNet. Обе модели используются в замороженном режиме (без вычисления

градиентов), поскольку их задача – предоставить стабильные признаки для последующей темпоральной агрегации, а не адаптироваться к конкретному датасету. Это также существенно сокращает количество обучаемых параметров и время обучения.

MobileNetV3-Small – третье поколение семейства MobileNet, оптимизированное для мобильных устройств. Архитектура основана на глубоких разделимых свертках, инвертированных линейных бутылочных слоях, а также включает модули squeeze-and-excitation и нелинейность hard-swish. Модель предобучена на ImageNet, что позволяет ей извлекать общие визуальные признаки (формы, текстуры, границы), но не специфичные для мимики. Из стандартной реализации `torchvision.models.mobilenet_v3_small` удаляется классификационная голова, и выходным слоем становится последний слой перед классификатором, возвращающий 576-мерный вектор признаков. Размер модели составляет 3,6 МБ. Для каждого из 16 кадров клипа MobileNetV3-Small вычисляет признаковый вектор, формируя последовательность размерностью (16, 576).

EmotiEffNet – специализированная сверточная сеть на базе EfficientNet-B0, дообученная для задач распознавания выражений лица. Используется предобученная версия `enet_b0_8_best_vgaf.pt` из библиотеки `emotiefflib`. Двухэтапная стратегия предобучения: сначала сеть обучается на датасете VGGFace2 (идентификация лиц), затем дообучается на AffectNet с фокусом на эмоциональные категории (8 классов). Благодаря этому EmotiEffNet изначально кодирует такие тонкие мимические признаки, как положение бровей, уголков губ, морщины, что критически важно для распознавания эмоций. Модель принимает на вход изображения 224×224 и

выдает 1280-мерный признаковый вектор. Размер модели – 15,4 МБ. Для каждого клипа формируется последовательность (16, 1280).

Извлечение и кэширование признаков. Поскольку оба бэкбона заморожены, признаки могут быть вычислены один раз и сохранены в памяти для многократного использования при обучении различных темпоральных агрегаторов. Процедура извлечения выполняется отдельно для обучающей и тестовой выборок. Для каждого клипа (4800 в обучающей выборке после аугментации, 240 в тестовой) последовательно обрабатываются все 16 кадров, формируется тензор признаков, который сохраняется в оперативной памяти. Размер кэша для EmotiEffNet составляет приблизительно $4800 \times 16 \times 1280 \times 4$ байта (float32) $\sim 9,4$ ГБ. После завершения извлечения исходные кадры и аугментированные тензоры удаляются для освобождения памяти. Такой подход позволяет ускорить обучение темпоральных агрегаторов в 5–10 раз, поскольку исключается повторный прогон детекции лиц и сверточных бэкбонов на каждой эпохе.

Сравнительная характеристика. Выбор двух бэкбонов обусловлен необходимостью оценить вклад специализированной предобученности в качество распознавания эмоций. Ожидается, что EmotiEffNet, благодаря дообучению на AffectNet, обеспечит более высокую точность на тестовых актерах, даже при использовании простых темпоральных агрегаторов, тогда как MobileNetV3-Small потребует более сложной головы и большего объема данных для достижения сопоставимых результатов.

4.3.4. Темпоральные агрегаторы и обучение

После извлечения пространственных признаков (последовательность из 16 векторов размерности 576 для MobileNet или 1280 для EmotiEffNet)

требуется агрегировать их во времени для получения финального представления, которое затем классифицируется. В настоящей работе сравниваются три типа темпоральных агрегаторов: двунаправленный GRU (BiGRU), двунаправленный LSTM (BiLSTM) и временная сверточная сеть (TCN). Все агрегаторы принимают на вход последовательность переменной длины (16 шагов) и возвращают вектор фиксированной размерности, который подается в классификатор для предсказания одной из 8 эмоций RAVDESS.

BiGRUClassifier. Архитектура включает двунаправленный GRU с 2 слоями и размером скрытого состояния 128. Dropout между слоями установлен в 0,3. Для каждого временного шага прямой слой вычисляет скрытое состояние, зависящее от прошлых шагов, обратный слой – от будущих. В качестве выхода агрегатора берутся финальные скрытые состояния последнего слоя в прямом и обратном направлениях, которые конкатенируются, формируя 256-мерный вектор. Далее следуют: полносвязный слой с 64 нейронами, ReLU, Dropout (0,5), и выходной линейный слой с 8 нейронами (для классификации эмоций RAVDESS). Общее число параметров головы – около 390 тыс.

BiLSTMClassifier. Аналогичная архитектура на основе двунаправленного LSTM с 1 слоем, скрытым размером 128, dropout 0,3. Конкатенация финальных скрытых состояний дает 256-мерный вектор, который проходит через тот же классификатор Linear (256 - 64) - ReLU - Dropout - Linear(64 - 8). Число параметров – около 850 тыс.

TCNClassifier. Временная сверточная сеть состоит из трех блоков одномерных дилатированных сверток с растущим коэффициентом

расширения (1, 2, 4). Количество каналов во всех блоках – 256. Ядро свертки – 3. Каждый блок включает свертку, затем ReLU, пакетную нормализацию и Dropout 0,2. Паддинг симметричный, чтобы сохранять длину последовательности. После сверточных блоков выполняется глобальное усреднение по временному измерению, получая 256-мерный вектор, который подается на выходной линейный слой Linear (256 - 8). TCN не требует рекуррентного обхода последовательности и может обрабатывать все 16 шагов параллельно, что потенциально дает выигрыш в скорости. Однако для коротких последовательностей (16 шагов) это преимущество не столь существенно.

Обучение. Все модели обучаются с использованием кросс-энтропийной функции потерь со сглаживанием меток (`label_smoothing=0,1`). Оптимизатор – Adam. Гиперпараметры (скорость обучения, `weight decay`, число эпох) подбирались отдельно для каждой комбинации бэкбона и агрегатора, исходя из динамики валидационной точности. Для EmotiEffNet-моделей обучение требовало 10–15 эпох, тогда как для MobileNet – до 60 эпох. Для TCN применялся планировщик OneCycleLR с максимальной скоростью обучения $3e-4$ (MobileNet) или $3e-5$ (EmotiEffNet).

Аналогично аудио моделям – для каждой видео модели вручную подбирались гиперпараметры с целью получения наилучшего качества (подробнее в пункте 4.2.7.). Финальные параметры для каждой модели приведены в таблице 5.

Таблица 5. Финальные параметры для видео моделей.

Модель	Начальный LR	Weight decay	Эпохи	Планировщик
MobileNet + BiGRU	1e-3	5e-4	60	-

MobileNet + BiLSTM	1e-3	5e-4	30	-
MobileNet + TCN	3e-4	2e-3	20	OneCycleLR
EmotiEffNet + BiGRU	1e-3	5e-4	15	-
EmotiEffNet + BiLSTM	1e-4	5e-5	10	-
EmotiEffNet + TCN	3e-5	2e-6	10	OneCycleLR

Во время обучения на каждой эпохе вычисляется accuracy и loss на валидационной выборке (20% от обучающих актеров). После завершения обучения сохраняется чекпойнт агрегатора head_emotieffnet_bilstm.pt, содержащий веса BiLSTM и вспомогательного классификатора (последний в дальнейшем отбрасывается). Чекпойнт будет использован для инициализации видео-ветви в составе бимодальной головы. Обучение проводится на устройстве MPS (Apple Silicon) с агрессивной очисткой памяти между моделями.

4.3.5. Результаты предобучения и выбор лучшей конфигурации

После завершения обучения всех шести моделей проведена их сравнительная оценка на тестовой выборке RAVDESS, содержащей 240 видео от четырех актеров, не участвовавших в обучении. Оценка включала метрики accuracy (точность), macro F1 (средняя F1-мера по всем восьми классам), precision и recall по каждому классу, а также практические параметры: среднее время end-to-end инференса на одно видео (включая детекцию лиц, извлечение признаков бэкбоном и работу темпоральной головы), время обучения и общий размер пайплайна. Результаты сведены в Таблицу 6.

Таблица 6. Сравнение видео моделей.

Модель	Accuracy	Macro F1	Инференс, мс/файл	Размер пайплайна, МБ
--------	----------	----------	-------------------	----------------------

MobileNet + BiGRU	0.4625	0.429	266.4	3.70
MobileNet + BiLSTM	0.5083	0.484	247.4	6.41
MobileNet + TCN	0.3958	0.383	246.7	6.79
EmotiEffNet + BiGRU	0.6750	0.679	275.6	15.70
EmotiEffNet + BiLSTM	0.6833	0.671	275.1	21.02
EmotiEffNet + TCN	0.6042	0.585	274.5	20.72

Сравнение бэкбонов. Наиболее значимый результат – превосходство EmotiEffNet над MobileNetV3-Small во всех конфигурациях. При использовании BiLSTM замена бэкбона с MobileNet на EmotiEffNet повышает accuracy с 50.8% до 68.3% (разница 17,5 процентных пункта), macro F1 – с 0.484 до 0.671. Для BiGRU улучшение составляет +21,2 п.п. по accuracy и +25,0 п.п. по macro F1. Это объясняется фундаментальным различием в предобучении: MobileNetV3-Small обучен на ImageNet для общей классификации объектов и не специализирован на мимике. Напротив, EmotiEffNet прошел двухэтапное обучение на VGGFace2 и AffectNet, поэтому его признаки уже кодируют эмоционально значимые особенности лица. При ограниченном объеме обучающей выборки RAVDESS (всего 1200 видео до аугментации) темпоральная голова не способна компенсировать отсутствие эмоциональной специфики в признаках.

Сравнение темпоральных агрегаторов. Среди трех агрегаторов на базе EmotiEffNet лучшую accuracy показал BiLSTM (68.3%), лучший macro F1 – BiGRU (0.679). Разница между ними находится в пределах статистической погрешности (~3% для 240 тестовых примеров). BiLSTM и BiGRU работают сопоставимо, что согласуется с литературными данными о близости этих архитектур при коротких последовательностях (16 шагов). TCN показал худшие результаты на обоих бэкбонах: для EmotiEffNet

accuracy на 7,9 п.п. ниже, чем у BiLSTM. Причинами могут быть: (1) короткая последовательность (16 кадров), где преимущество TCN в параллельной обработке и большом рецептивном поле не проявляется; (2) отсутствие механизма, аналогичного вентилям LSTM/GRU, что делает TCN более чувствительным к нерегулярностям временной динамики.

Скорость и размер модели. Время инференса всех моделей лежит в узком диапазоне 247–276 мс на видео, причем основная доля затрат приходится на этап извлечения кадров (cv2.VideoCapture, декодирование) и детекцию лиц MediaPipe. Разница между самыми легкими (MobileNet+BiGRU, 3.7 МБ) и самыми тяжелыми (EmotiEffNet+BiLSTM, 21.0 МБ) моделями по времени инференса составляет менее 10%, поэтому компактность пайплайна не является критическим фактором. В реальном сценарии каскада видео модель запускается только для эмоциональных реплик (доля которых в диалоге обычно не превышает 20–40%), поэтому время 275 мс на видео является приемлемым.

Выбор лучшей конфигурации. На основании полученных результатов для использования в каскадной системе и последующего дообучения на IEMOCAP выбрана конфигурация **EmotiEffNet + BiLSTM**. Этот выбор обусловлен:

- наивысшей accuracy (68.33%) среди всех моделей;
- высоким macro F1 (0.671), что свидетельствует о сбалансированном качестве по всем классам, включая малочисленный neutral;
- стабильностью обучения (10 эпох, быстрая сходимость);

- подтвержденной эффективностью BiLSTM в задачах временной агрегации мимических признаков.

Таким образом, для использования в каскадной системе выбрана конфигурация EmotiEffNet + BiLSTM. Полученный файл head_emotieffnet_bilstm.pt вместе с замороженным бэкбоном enet_b0_8_best_vgaf.pt обеспечивает начальные веса для видео-ветви бимодальной головы. Дальнейшая адаптация к 4 классам IEMOCAP происходит уже в составе полной двухстадийной модели.

4.4. Архитектура итоговой каскадной системы

Итоговая каскадная система строится вокруг бимодальной головы BiLSTMBimodal (рисунок 2). Голова реализует стратегию позднего слияния (late fusion): видео- и аудиопризнаки извлекаются независимыми ветвями, затем конкатенируются и подаются в общий классификатор.




Рисунок 2. Бимодальная голова.

Видео-ветка. Предварительно извлечённые кадры лица (16 кадров, 224×224) подаются на замороженный экстрактор EmotiEffNet (enet_b0_8_best_vgaf), формируя последовательность пространственных векторов размерности 1280. Однослойный двунаправленный LSTM (bilstm_v) со скрытым размером 128 обрабатывает эту последовательность, после чего финальные скрытые состояния прямого и обратного направлений конкатенируются в вектор $h_v \in \mathbb{R}^{256}$.

Веса bilstm_v загружаются из чекпойнта head_emotieffnet_bilstm.pt, полученного при обучении на RAVDESS (раздел 4.3).

Аудио-ветка. Архитектура аудио-ветки — точная копия свёрточной части MelCNN (audio_features) и первого линейного слоя её

классификатора. На вход подаётся **тот же** лог-мел тензор (1, 64, 128), что и в гейт. После трёх свёрточных блоков признаковая карта выпрямляется и проецируется линейным слоем $8192 \rightarrow 256$, формируя вектор $h_a \in \mathbb{R}^{256}$ с применением ReLU и Dropout (0.3).

Веса свёрточной модели `audio_features` и матрица `audio_proj` переносятся из глобального MelCNN-чекпойнта `mel_cnn.pt` (раздел 4.2).

Классификатор слияния. Векторы h_v и h_a конкатенируются в общий вектор размерности 512, который проходит через двухслойный классификатор: $\text{Linear}(512 \rightarrow 64) \rightarrow \text{ReLU} \rightarrow \text{Dropout}(0.5) \rightarrow \text{Linear}(64 \rightarrow 4)$. Классификатор инициализируется случайным образом и не наследует весов предобученных компонентов.

Логика итогового предсказания формализована правилом:

$$\text{pred} = \begin{cases} \text{neutral}, & \text{gate_pred} = 0 \\ \arg \max(\text{head_logits}), & \text{gate_pred} = 1 \end{cases}$$

При $\text{gate_pred} = 0$ вызов `BlazeFace`, `EmotiEffNet` и всей бимодальной головы полностью пропускается. При $\text{gate_pred} = 1$ решение принимается исключительно по выходам головы (4 класса).

4.4.1. Двухстадийное обучение архитектуры на IEMOSCAP

Для адаптации предобученной модели к импровизированной речи IEMOSCAP применяется двухстадийный режим:

1. Разогрев (5 эпох) — обучается только классификатор слияния, все предобученные модули (`bilstm_v`, `audio_features`, `audio_proj`) заморожены.
2. Дообучение (до 55 эпох) — размораживаются все параметры; предобученные части получают скорость обучения 10^{-4} , классификатор — $3 \cdot 10^{-4}$. Используется косинусное затухание, градиентный клиппинг 1.0 и кросс-энтропия с весами, обратно пропорциональными частотам классов.

Метрикой для выбора лучшего чекпойнта служит взвешенная точность (UA). Для подавления шума, вызванного малым валидационным сплитом и случайными флипами гейта, применяется экспоненциальное сглаживание (ЕМА, коэффициент 0.5). Ранняя остановка срабатывает после 8 эпох без улучшения сглаженной метрики.

4.4.2. Размер и эффективность архитектуры

Суммарное количество обучаемых параметров составляет около 5.7М, полный размер на диске (включая замороженные экстракторы) — около 37 МБ. На нейтральных репликах инференс ограничивается единственным прогоном MelCNN (~3.4 мс), а тяжёлый видеопайплайн не запускается. На эмоциональных репликах бимодальная голова добавляет примерно 275 мс (детекция лиц + EmotiEffNet + BiLSTM), что сравнимо с обычными мультимодальными системами, но благодаря жёсткому пропуску средняя латентность на реальных диалогах оказывается значительно ниже.

5. Экспериментальная оценка и результаты

В данной главе описывается экспериментальная оценка предложенной каскадной системы распознавания эмоций на целевом датасете IEMOSCAP. Протокол эксперименты был приближен к уже существующим научным работам, для валидного сравнения с другими моделями по метрикам качества [63] [64].

5.1. Целевой датасет IEMOSCAP и протокол эксперимента

Экспериментальная оценка всех моделей проводится на корпусе IEMOSCAP. Каждое высказывание (utterance) размечено по шкале эмоций; для нашего исследования мы ограничиваемся **четырьмя категориями**: neutral, happy, sad, angry. Категория excited объединяется с happy (отображение "exc" -> "hap"), а малочисленные или неоднозначные классы (frustrated, fear, surprise, disgust, other) исключаются из рассмотрения. После фильтрации объём выборки составляет около 5500 высказываний. Текстовая транскрипция не используется ни одной из сравниваемых моделей; задача решается исключительно по аудио- и видеомодальностям.

Оценка качества выполняется по строгой схеме Leave-One-Session-Out (LOSO) с пятью фолдами. В каждом фолде ровно одна сессия выступает тестовой, одна – валидационной, а оставшиеся три – обучающей. Валидационная сессия назначается циклически: для тестовой сессии i валидационной является сессия $(i + 1) \bmod 5$. Полный лог распределения можно найти в репозитории. Поскольку каждая сессия IEMOSCAP записана с участием уникальной пары актёров, ни на одном фолде не происходит пересечения говорящих между обучением,

валидацией и тестом, что обеспечивает полностью спикеро-независимую оценку.

Основной метрикой выступает несбалансированная точность (Unweighted Average Recall, UAR), вычисляемая как среднее арифметическое per-class полноты (recall) по четырём классам:

$$UA = \frac{1}{4} \sum_{c \in \{neutral, happy, sad, angry\}} Recall_c.$$

Данная метрика выбрана потому, что в IEMOCAP наблюдается значительный дисбаланс классов (преобладают *neutral* и *happy*), из-за чего взвешенная точность (WA) может быть искусственно завышена при уверенном предсказании мажоритарных эмоций. UA одинаково штрафует ошибки на любом классе и тем самым даёт более объективную картину.

В дополнение к UA фиксируются следующие метрики:

- Weighted Accuracy (WA) - доля правильных предсказаний модели с учетом весов разных классов;
- Macro-F1 – невзвешенное среднее F1-меры по четырём классам;
- Per-class F1 – F1-мера для каждого класса в отдельности;
- Матрица ошибок (confusion matrix) размера 4×4.

Все метрики вычисляются для каждого фолда отдельно, после чего агрегируются в виде среднего арифметического и стандартного отклонения по пяти фолдам (mean ± std).

Для обеспечения воспроизводимости результатов:

- Фиксируется начальное случайное число, дополнительно накладывается детерминизм на операции PyTorch. На каждом фолде перед началом обучения вызывается `seed_everything(SEED + k)`, где k – порядковый номер фолда.
- Вместе с результатами каждого прогона сохраняется файл `run_meta.json`, содержащий, полную конфигурацию модели, а также информацию об оборудовании и временную метку.

Таким образом, предлагаемый протокол гарантирует корректное, спикеро-независимое сравнение всех архитектур в равных условиях и исключает любые скрытые формы подгонки под тестовую выборку.

5.2. Сравнимые модели

Для всесторонней оценки предлагаемой архитектуры в бенчмарк включены шесть конфигураций, различающихся по числу используемых модальностей, способу слияния информации, наличию каскадного механизма и стратегии инициализации.

1. **Ours (BiLSTM bimodal, hard skip)** — основная модель, разработанная в главе 4. Двухстадийный жёсткий каскад: бинарный аудиогейт MelCNN предфильтрует нейтральные реплики; бимодальная голова BiLSTMBimodal, активируемая только на не-нейтральных высказываниях, объединяет видео (BiLSTM поверх EmotiEffNet) и аудио (conv-стек, идентичный гейту). Аудио- и видеоветви инициализированы предобученными весами (RAVDESS+CREMA-D и RAVDESS соответственно), классификатор слияния обучается с нуля.

2. **Ours (BiLSTM bimodal, hard skip, scratch)** — инициализированный случайными весами вариант той же архитектуры. Предназначен для оценки вклада предобучения.
3. **GIA-MIC** — мультимодальный трансформер с механизмом Gated Interactive Attention и многозадачной декомпозицией признакового пространства на общее и частное (MISA-style). Относится к наиболее сильным современным мультимодальным подходам.
4. **SCME+GF** — упрощённый кросс-модальный энкодер с вентильным слиянием (Gated Fusion). Два трансформерных энкодера независимо кодируют аудио и видео, после чего одномасштабный гейт смешивает агрегированные представления модальностей. Может рассматриваться как облегчённый представитель семейства SCME-подобных архитектур.
5. **MM-NodeFormer** — двухпоточный кросс-модальный трансформер, состоящий из нескольких идентичных блоков, каждый из которых выполняет self-attention по каждой модальности и взаимное cross-attention. Простая и легко воспроизводимая архитектура, распространённая в задачах мультимодального слияния.
6. **ResNet18+GRU** — видео baseline. Пространственные признаки извлекаются замороженным ResNet18, временная агрегация выполняется двунаправленной GRU. Аудиомодальность полностью игнорируется, что позволяет оценить нижнюю границу качества, достижимого без акустической информации.

Ключевые характеристики всех участников сведены в таблице 9. Подробное описание архитектурных решений и гиперпараметров для каждой модели дано в разделах 4.2–4.4 (для нашей системы).

Таблица 7 Сравнительная характеристика моделей бенчмарка

Модель	Модальность	Число параметров	Инициализация	Год публикации
Ours (BiLSTM bimodal, hard skip)	Аудио + Видео	5.72M	Предобученная	2026
Ours (scratch)	Аудио + Видео	5.72M	Случайная	2026
GIA-MIC	Аудио + Видео	0.84M	Случайная	2025
SCME+GF	Аудио + Видео	0.97M	Случайная	2024
MM-NodeFormer	Аудио + Видео	1.49M	Случайная	2024
ResNet18+GRU	Видео	0.81M	Случайная	-

Примечание: количество обучаемых параметров указано без учёта замороженных экстракторов признаков (EmotiEffNet, Wav2Vec2, ResNet18); полный E2E-размер моделей с учётом всех компонентов, используемых на инференсе, анализируется в разделе 5.5.

Таким образом, в сравнительный анализ включены как новейшие мультимодальные архитектуры, так и одномодальный бейзлайн, что позволяет оценить как абсолютный прирост от использования двух модальностей, так и преимущества каскадной организации и целенаправленного предобучения.

5.3. Условия обучения моделей

Для обеспечения максимально честного сравнения все шесть моделей обучаются и оцениваются в строго идентичных условиях. С этой целью создаётся унифицированный конвейер данных и единый тренировочный цикл с возможностью переопределения гиперпараметров.

Тренировочный цикл. Все модели обслуживаются единым тренером `train_one_fold`. Per-model оверрайды задаются через конфигурационный словарь `MODEL_ZOO`, специфицирующий: наличие предобученных модулей, число эпох, темпы обучения для различных групп параметров, `weight decay`, коэффициент `label smoothing`, режим каскада.

Функция потерь и оптимизация. В качестве критерия используется кросс-энтропия с весами классов (`compute_class_weight("balanced")`), вычисляемыми на обучающем подмножестве каждого фолда. `Label smoothing` для предлагаемой модели отключён (0.0), для конкурентов составляет 0.1. Оптимизатор — AdamW с независимым `weight decay` для каждой модели ($1e-5$ для предлагаемой и GIA-MIC, 0.05 для MM-NodeFormer, $1e-4$ для остальных). Применяется градиентный клиппинг на уровне 1.0. Размер батча — 64, на обучающей выборке применяется перемешивание с дропом неполного последнего батча.

Двухстадийное обучение предлагаемой модели. Модели, специфицированные как `pretrained_init = True`, проходят двухстадийную процедуру. Первая стадия (`warm-up`, 5 эпох): обучается только свежеинициализированный классификатор слияния, все предобученные модули заморожены; темп обучения для классификатора — $1e-3$, планировщик OneCycleLR. Вторая стадия (`fine-tune`, до 55 эпох): все параметры размораживаются; предобученные компоненты получают темп обучения $1e-4$, классификатор — $3e-4$; применяется косинусное затухание без второго разогрева. Остальные (`scratch`) модели обучаются одностадийно с AdamW и OneCycleLR.

Дообучение аудиогейта. Для каждой тестовой сессии (один раз на фолд, результат кэшируется и разделяется между двумя каскадными моделями) глобальный MelCNN-гейт (`mel_cnn.pt`, обученный на RAVDESS+CREMA-D) дообучается под бинарную задачу «нейтрально / не нейтрально» на обучающем подмножестве данного фолда IEMOCAP. Дообучение занимает 20 эпох (AdamW, $lr=1e-4$, OneCycleLR) с ранней остановкой по валидационной сбалансированной точности.

ЕМА-селекция чекпойнта. Валидационная UA вычисляется на каждой эпохе строго в той же каскадной политике, которая используется на инференсе. Из-за малого валидационного сплита (~150 высказываний на класс) raw UA подвержена шуму (2–5 п.п. от эпохи к эпохе). Для устойчивого выбора лучшего чекпойнта применяется экспоненциальное скользящее среднее с коэффициентом 0.5: $ema_ua = 0.5 \cdot ema_ua + 0.5 \cdot raw_ua$. Лучшим считается чекпойнт, при котором `ema_ua` достигает максимума. Ранняя остановка срабатывает после 8 эпох без улучшения сглаженной метрики. Такой подход гарантирует, что отбирается модель, стабильно качественная, а не получившая случайно высокую оценку.

Оборудование. Эксперименты проводились на системе с Apple Silicon M1 Pro (32 ГБ unified memory) с использованием PyTorch MPS-бэкенда.

5.4. Результаты сравнения моделей

Общая точность. В таблице 8 приведены агрегированные по пяти фолдам результаты всех шести моделей. Основная метрика — UAR, взвешенная по классам точность WA и Macro-F1 выступают дополнительными.

Таблица 8. Сравнение моделей на IEMOCAP (mean±std, LOSO 5-fold)

Модель	UAR	Macro F1	WA
Ours (BiLSTM bimodal, hard skip)	0.5094±0.0232	0.4940±0.0257	0.5113±0.0255
Ours (scratch)	0.5048±0.0211	0.4921±0.0269	0.5086±0.0253
GIA-MIC	0.4739±0.0145	0.4658±0.0180	0.4739±0.0145
SCME+GF	0.4626±0.0294	0.3814±0.0203	0.4127±0.0312
MM-NodeFormer	0.4475±0.0173	0.3985±0.0395	0.4145±0.0392
ResNet18+GRU	0.3110±0.0450	0.2782±0.0498	0.3192±0.0480

Предлагаемая модель лидирует по всем трём агрегированным метрикам. Предобученный вариант превосходит scratch-версию на ~ 0.46 п.п. по UA — разница лежит в пределах одного стандартного отклонения, однако преимущество стабильно воспроизводится на всех трёх метриках и, как будет показано ниже, наиболее заметно на классах *neutral* и *angry*. По сравнению с лучшим конкурентом (GIA-MIC) выигрыш по UA составляет +1.8 п.п. Это объясняется тем, что GIA-MIC достигает наилучшего качества при трех модальностях (аудио, видео, текст), однако на двух модальностях — наша модель показывает более высокие результаты. По сравнению с SCME+GF — +4.7 п.п., с MM-NodeFormer — +6.2 п.п.

Видео baseline (ResNet18+GRU) ожидаемо замыкает таблицу с UA ≈ 0.311 , что на 19.8 п.п. ниже предлагаемой модели. Столь значительный разрыв подтверждает, что акустическая модальность несёт критически важную информацию для различения эмоций в IEMOCAP, а простое добавление аудио даже в простейшей форме (лог-мел + CNN) даёт принципиальный прирост.

Поклассовый анализ. Таблица 9 детализирует F1-меру для каждого из четырёх классов (среднее по пяти фолдам). Это позволяет понять, за счёт каких эмоций достигается итоговое преимущество.

Таблица 9. Поклассовый метрики качества (среднее, LOSO 5-fold)

Модель	neutral	happy	sad	angry
Ours (BiLSTM bimodal, hard skip)	0.553	0.331	0.508	0.584
Ours (scratch)	0.542	0.339	0.510	0.577
GIA-MIC	0.325	0.508	0.539	0.491
SCME+GF	0.085	0.447	0.536	0.458
MM-NodeFormer	0.250	0.379	0.557	0.408
ResNet18+GRU	0.340	0.277	0.297	0.199

Ключевые наблюдения:

- *Neutral.* Предлагаемая модель достигает $F1 = 0.553$, тогда как ближайший конкурент (ResNet18+GRU) — лишь 0.340, а мультимодальные GIA-MIC и SCME+GF — 0.325 и 0.085 соответственно. Драматический разрыв объясняется архитектурным решением: жёсткий каскад с per-fold дообученным гейтом специализированно вычленяет нейтральные реплики, в то время как не-каскадные модели вынуждены различать *neutral* среди всех четырёх классов в условиях его значительного численного перевеса.
- *Happy.* Это наиболее слабый класс для предлагаемой модели ($F1 = 0.331$ против 0.508 у GIA-MIC). Причина кроется в процедуре объединения *happy* и *excited* в один класс; *excited* по акустическим характеристикам часто близок к *angry*, что создаёт высокую внутриклассовую дисперсию. GIA-MIC с его механизмом per-token вентильного кросс-внимания, по-видимому, лучше улавливает тонкие

различия между *happy/excited* и *angry*. Данный класс является приоритетным направлением для дальнейшего улучшения.

- *Sad*. Все модели показывают близкие результаты (0.51–0.56). *Sad* в IEMOCAP уверенно распознаётся практически любым подходом; дальнейший прирост, вероятно, требует выхода за пределы используемых акустических и визуальных признаков.
- *Angry*. Предлагаемая модель вновь лидирует ($F1 = 0.584$), причём предобученный вариант на 0.7 п.п. опережает *scratch*-версию именно на этом классе. Жёсткий каскад здесь не даёт прямого преимущества (гейт пропускает гневные реплики в голову), однако качественная инициализация аудио-ветви весами глобального MelCNN обеспечивает лучшее различение *angry* и *sad* по сравнению со случайной инициализацией.

Стабильность по фолдам. Для предлагаемой модели UAR по отдельным фолдам варьируется от 0.4824 (Session 4) до 0.5527 (Session 1). Session4, несмотря на максимальное качество гейта (Acc = 0.7120), демонстрирует худший итоговый результат — следовательно, ограничивающим фактором выступает не гейт, а способность бимодальной головы различать эмоциональные классы на конкретной паре актёров. Напротив, Session1 (гейт Acc = 0.6697) даёт наивысшую UAR; можно предположить, что данная сессия содержит более отчётливые мимические и просодические паттерны.

Матрицы ошибок. На рисунке 3 представлены агрегированные матрицы ошибок для всех шести моделей (сумма по всем пяти тестовым фолдам). Наглядно видны систематические паттерны: для предлагаемой

модели доминирующая ошибка — путаница *happy* и *angry*; GIA-MIC часто принимает *neutral* за *sad*; SCME+GF практически не выделяет *neutral*, относя его преимущественно к *happy* и *sad*; видео baseline обнаруживает почти случайное угадывание для *angry* и *sad*. Матрицы подтверждают количественные выводы per-class анализа.




Рисунок 3. Матрица ошибок всех моделей.

Таким образом, предлагаемая каскадная архитектура с предобученными компонентами и жёстким аудиогейтом достигает наивысшего качества распознавания на IEMOCAP в условиях строгого LOSO-протокола, превосходя как более сложные трансформерные конкуренты, так и простые базовые подходы. Основной источник преимущества — эффективная обработка класса *neutral*, который остаётся камнем преткновения для не-каскадных мультимодальных систем.

5.5. Эффективность и размер моделей

Помимо точности распознавания, критически важными характеристиками модели для практического применения являются объём занимаемой памяти и скорость обработки одной реплики. В сценариях потокового анализа диалогов, особенно на мобильных или встраиваемых устройствах, избыточный размер модели или высокая латентность делают систему неприменимой. В данном разделе проводится сравнительный анализ всех шести моделей по двум интегральным показателям: end-to-end размеру — суммарному объёму всех компонентов, реально загружаемых в оперативную память при инференсе, — и среднему времени обработки одного высказывания.

Методология измерения. Размер модели вычисляется функцией, суммирующей число параметров и буферов (включая текущие статистики BatchNorm) каждого модуля с учётом разрядности представления. Для мультимодальных систем к размеру головы добавляются все необходимые экстракторы признаков: для видео — детектор лиц MediaPipe BlazeFace и свёрточный бэкбон (EmotiEffNet или ResNet18); для аудио — модель извлечения спектрограммы и, если требуется, предобученный аудиоэнкодер (Wav2Vec2). В каскадной архитектуре учитывается также бинарный гейт MelCNN. Все значения приводятся в мегабайтах (МБ).

Время работы измеряется как среднее время полного цикла обработки одного высказывания на тестовой выборке, включая все стадии: от получения сырого сигнала до выдачи предсказанной эмоции. Для видео-моделей в замер входит детекция лица, извлечение и нормализация кадров, прогон через бэкбон и голову; для аудио — вычисление признаков и проход

через соответствующие сети. В случае каскадной модели отдельно фиксируется время для нейтральных реплик (срабатывает только гейт) и для эмоциональных (активируется полный видеопайплайн). Среднее время работы в реальных диалогах будет зависеть от доли нейтральных высказываний, то есть с большой вероятностью в условиях реальной проверки наша модель покажет более низкое среднее время работы.

Результаты. Таблица 10 суммирует end-to-end размеры и среднее времена инференса для всех участников бенчмарка.

Таблица 10. End-to-end размер и время обработки реплик.

Модель	Размер, МБ	Время обработки реплики, мс	Примечание
Ours (BiLSTM bimodal, hard skip)	37.7	216	3.4 мс – нейтральная 278 мс - эмоциональная
Ours (scratch)	37.7	215	Аналогично основной
GIA-MIC	115	612	Wav2Vec 2.0
SCME+GF	115	625	Wav2Vec2.0
MM-NodeFormer	117	609	Wav2Vec 2.0
ResNet18+GRU	48	533	Только видео




Рисунок 4. Диаграммы метрик качества, размера, времени и интегральные диаграммы

Анализ. Предлагаемая каскадная архитектура демонстрирует наименьший размер среди всех аудиовизуальных моделей — около 37,7 МБ, что почти втрое компактнее ближайшего мультимодального конкурента (GIA-MIC, ≈ 115 МБ). Такой выигрыш достигнут благодаря двум принципиальным решениям:

1. **Отказ от тяжёлого аудиоэнкодера Wav2Vec2.** Все конкуренты полагаются на универсальную модель Wav2Vec2-base (~95 МБ) для извлечения аудиопредставлений. В нашей системе аналогичную роль выполняет легковесный свёрточный стек MelCNN (~8 МБ), обученный непосредственно под задачу различения эмоциональной окраски. Более того, его веса переиспользуются и в гейте, и в аудио-ветке бимодальной головы, что исключает дублирование.
2. **Жёсткий каскад с пропуском видео на нейтральных репликах.** Хотя EmotiEffNet (16 МБ) и BlazeFace (0,2 МБ) присутствуют в комплекте поставки, они физически не загружаются и не исполняются для нейтральных высказываний. Это не влияет на пиковый объём занимаемой памяти (все компоненты должны быть доступны в адресном пространстве), но радикально сокращает *эффективную* латентность в типичных диалогах, где доля нейтральных реплик может превышать 50%.

С точки зрения скорости обработки, на нейтральных репликах наша модель достигает времени отклика **3,4 мс** — практически мгновенного с точки зрения человеческого восприятия, то есть возможно обрабатывать

порядка 300 кадров в секунду. Для эмоциональных высказываний латентность возрастает до ~ 278 мс, что сравнимо с показателями конкурентов (≈ 316 мс), однако последние тратят это время на *каждую* реплику, включая нейтральные. В результате среднее время обслуживания одного высказывания в диалоге для предлагаемой системы оказывается значительно ниже, чем у любой из рассмотренных мультимодальных альтернатив.

Видео baseline ResNet18+GRU ожидаемо имеет наименьший размер (~ 48 МБ) и приемлемую латентность (~ 250 мс), однако его качество ($UA \approx 0,311$) находится на уровне, неприемлемом для практических приложений. Это подчёркивает, что простота не должна достигаться ценой катастрофической потери точности.

Интегральные диаграммы. На рисунке 4 приведены сводные графики, демонстрирующие компромисс между качеством (Macro F1) и вычислительной стоимостью. На плоскости «Macro F1 vs E2E-размер» предлагаемая модель занимает наилучшую позицию — максимальная точность при минимальном (среди аудиовизуальных решений) объёме памяти. На плоскости «Macro F1 vs средняя латентность» (при реалистичной доле нейтральных реплик 50%) наша система также оказывается оптимальной, совмещая наивысшую Macro F1 с наименьшей задержкой. Эти результаты подтверждают, что спроектированный каскад является не только академически сильным, но и практически эффективным решением.

Сравнение предобученной vs непредобученной модели. По всем итоговым метрикам видно, что за счет предобучения не удастся достичь

серьезного улучшения качества. Это вполне оправдано тем, что датасеты предобучения – лабораторные, и вероятно для получения преимущества нужно рассмотреть более живые и реальные датасеты, например Aff-Wild. Это одно из основных направлений для дальнейшего развития архитектуры.

Таким образом, данный раздел демонстрирует, что предлагаемая архитектура устанавливает новый парето-оптимальный фронт в пространстве «точность – память – скорость» для мультимодального распознавания эмоций на IEMOCAP без использования текста. Достигнуто это за счёт синергии трёх факторов: переиспользования лёгкого аудиобэббона между гейтом и головой, отказа от универсальных тяжёлых аудиоэнкодеров и селективного выполнения ресурсоёмкого видеопайплайна только на эмоционально окрашенных высказываниях.

5.6. Реализация real-time демо версии

В дополнение к офлайн-экспериментам на размеченных датасетах был разработан демонстрационный прототип, подтверждающий работоспособность предложенной каскадной архитектуры в режиме реального времени. Прототип повторяет логику финальной модели Ours (BiLSTM bimodal, hard skip), оценённой в разделе 5.4, и адаптирует её к непрерывным аудио- и видеопотокам с микрофона и веб-камеры. Система автоматически выделяет речевые фразы, выполняет их классификацию и отображает результат поверх видеокадра.

5.6.1. Общая архитектура потоковой модели

Структурно прототип воспроизводит двухстадийную каскадную архитектуру, подробно описанный в разделе 4.4, и реализует три параллельных процесса:

- **Поток захвата аудио** непрерывно опрашивает микрофон, с помощью модели Silero VAD сегментирует речь на отдельные фразы и накапливает их в буфере.
- **Поток захвата видео** в фоновом режиме читает кадры с веб-камеры и сохраняет их в кольцевой буфер ограниченной длительности (около 3 секунд).
- **Поток логического вывода** запускается при обнаружении завершённой фразы и выполняет каскадный инференс. Чтобы избежать одновременной обработки нескольких фраз, используется флаг `processing`; если новая фраза завершается до окончания текущего инференса, она игнорируется.

Главный поток приложения в цикле опрашивает готовые фразы, запускает инференс и отрисовывает поверх последнего кадра предсказанную эмоцию, её уверенность и индикатор состояния (`LISTENING / IDLE`). Такая многопоточная организация гарантирует, что тяжёлые вычисления не блокируют захват аудио и видео, а интерфейс остаётся отзывчивым.

Логика обработки одной фразы в точности соответствует бенчмарку:

1. Из волновой формы вычисляется лог-мел-спектрограмма и подаётся на бинарный аудиогейт (MelCNN, дообученный под соответствующий LOSO-фолд IEMOCAP).
2. Если гейт предсказывает «нейтрально», система немедленно возвращает метку *neutral*, не активируя видео-ветку.
3. При предсказании «не нейтрально» из кольцевого видеобуфера равномерно выбираются 16 кадров; для каждого выполняется детекция лица (BlazeFace), извлечение пространственных признаков замороженным EmotiEffNet и временная агрегация двунаправленным LSTM. Тот же самый тензор лог-мел-спектрограммы параллельно проходит через аудио-ветку бимодальной головы, после чего видеопредставление и аудиопредставление конкатенируются и классифицируются в один из четырёх классов: *neutral*, *happy*, *sad*, *angry*.

Таким образом, демонстрационный прототип является точным runtime-воплощением модели, исследованной в бенчмарке, с минимальными инженерными отличиями, продиктованными потоковой природой данных.

5.6.2. Итоговая работоспособность и соответствие бенчмарку

Разработанный прототип полностью воспроизводит логику финальной модели Ours (BiLSTM bimodal, hard skip) в потоковом окружении. Детальное сопоставление ключевых этапов обработки в демонстрационной системе и в офлайн-бенчмарке подтверждает их высокую степень идентичности.

- **Частота дискретизации аудио** — 16 кГц в обоих случаях, моно.
- **Параметры лог-мел-спектрограммы** — 64 мел-фильтра, шаг 512 отсчётов, приведение к логарифмической шкале относительно максимума, нормализация глобальными статистиками MEL_MEAN и MEL_STD из датасета audio_neutral_3_augmentation.
- **Временная ось спектрограммы** — 128 кадров, с заполнением нулями для коротких и обрезкой для длинных высказываний.
- **Аудиогейт** — та же модель MelCNN, что и в бенчмарке; загружаются веса per-fold чекпойнта gate_iemocap_{Session}.pt (в демонстрации — Session5).
- **Видео-экстрактор** — замороженный EmotiEffNet enet_b0_8_best_vgaf, идентичный использованному при построении офлайн-фиче-кэша.
- **Выборка кадров** — 16 кадров равномерно распределяются по буферу с помощью pr.linspace, что в точности повторяет стратегию экстракции клипов в бенчмарке.
- **Бимодальная голова** — архитектура BiLSTMBimodal; загружается чекпойнт ours_bilstm_bimodal_hard_skip_{Session}.pt с удалением префикса head., как описано в разделе 4.4.
- **Переиспользование лог-мел-признаков** — один и тот же тензор размером (1, 64, 128) подаётся на вход гейта и аудио-ветви бимодальной головы, полностью исключая повторную экстракцию.

- **Политика каскада** — если гейт предсказывает *neutral*, система немедленно возвращает эту метку и не активирует тяжелую модель; в противном случае решение принимается бимодальной головой.
- **Финальное предсказание** — argmax логитов головы для эмоциональных реплик, что соответствует логике инференса в бенчмарке.

Единственное заметное расхождение касается **процедуры детекции лиц**. В офлайн-кэше использовался порог уверенности BlazeFace 0,25, а при промахх детекции кадры восполнялись из соседних успешных детекций (gap-fill). В реальном времени, с учётом ограничений потоковой обработки, порог установлен на уровне 0,5, а при обнаружении лица применяется центральный квадратный кроп. Это может приводить к незначительному снижению точности видео-ветви на кадрах с экстремальными ракурсами или окклюзиями, однако не нарушает общей работоспособности каскада и не меняет фундаментальные выводы о преимуществах архитектуры.

Тестирование в различных условиях (фоновый шум, разное освещение, умеренные повороты головы) показало стабильную работу системы. На нейтральных фразах видео-конвейер не активируется ни разу, что подтверждает корректность жёсткого каскада. Задержка на нейтральных высказываниях не превышает 10 мс; на эмоциональных составляет в среднем 60–110 мс (MPS) и ещё меньше при использовании CUDA-совместимого GPU. Благодаря выносу инференса в отдельный поток интерфейс остаётся плавным при стандартной частоте веб-камеры 15–30 кадров/с.

Таким образом, практическая реализация полностью подтверждает пригодность предложенной архитектуры для потоковых приложений и демонстрирует достижение заявленной цели — экономию вычислительных ресурсов на нейтральной речи при сохранении высокой точности на эмоциональных высказываниях.

Примеры работы системы можно увидеть в Приложении 1.

5.6.3. Известные ограничения

Несмотря на успешное функционирование, разработанный прототип имеет ряд ограничений, которые могут быть устранены в следующих итерациях:

- **Отсутствие очереди фраз.** Если новая фраза завершается во время обработки предыдущей, она отбрасывается. При высокой плотности речи это может приводить к потере коротких высказываний.
- **Расхождение аудио- и видео-окон.** Аудиогейт анализирует первые ~4,1 с фразы (128 кадров спектрограммы), тогда как видео-буфер хранит последние ~3 с. Для длинных монологов пик эмоциональной экспрессии может смещаться, и окна перестают совпадать.
- **Обработка одного лица.** При наличии в кадре нескольких людей выбирается детекция с наибольшей уверенностью; прототип рассчитан на одного говорящего.
- **Упрощённый fallback детекции лиц.** В реальном времени не применяется gap-fill, и при серии промахов BlazeFace используется центральный кроп, что потенциально снижает точность видео-ветви по сравнению с офлайн-бенчмарком.

- **Чувствительность к условиям съёмки.** Как и любая система визуального распознавания эмоций, прототип чувствителен к освещению, окклюзиям и сильным поворотам головы. Качество может падать в неконтролируемых средах.

Перечисленные ограничения не носят фундаментального характера и могут быть сняты введением очереди сообщений, более гибкой синхронизацией модальностей и усовершенствованным трекингом лиц, что составляет направления дальнейшей инженерной разработки, так как это лишь демо-прототип применения модели в реальном времени.

6. Заключение

Git-репозиторий курсовой работы и проекта доступен по ссылке:
<https://github.com/Kaparya/PathTracing>

Библиографический список

1. Burkhardt, Felix & Paeschke, Astrid & Rolfes, M. & Sendlmeier, Walter & Weiss, Benjamin. (2005). A database of German emotional speech. 9th European Conference on Speech Communication and Technology. 5. 1517-1520. 10.21437/Interspeech.2005-446.
2. Livingstone SR, Russo FA. The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in North American English. PLoS One. 2018 May 16;13(5):e0196391. doi: 10.1371/journal.pone.0196391. PMID: 29768426; PMCID: PMC5955500.
3. Cao H, Cooper DG, Keutmann MK, Gur RC, Nenkova A, Verma R. CREMA-D: Crowd-sourced Emotional Multimodal Actors Dataset. IEEE Trans Affect Comput. 2014 Oct-Dec;5(4):377-390. doi: 10.1109/TAFFC.2014.2336244. PMID: 25653738; PMCID: PMC4313618.
4. C. Busso, M. Bulut, C. Lee, A. Kazemzadeh, E. Mower, S. Kim, J. Chang, S. Lee, and S. Narayanan, "IEMOCAP: Interactive emotional dyadic motion capture database," Journal of Language Resources and Evaluation, vol. 42, no. 4, pp. 335-359, December 2008
5. Latif, Siddique & Rana, Rajib & Younis, Shahzad & Qadir, Junaid & Epps, Julien. (2018). Cross Corpus Speech Emotion Classification - An Effective Transfer Learning Technique. 10.48550/arXiv.1801.06353.
6. Fu H, Zhuang Z, Wang Y, Huang C, Duan W. Cross-Corpus Speech Emotion Recognition Based on Multi-Task Learning and Subdomain Adaptation. Entropy (Basel). 2023 Jan 7;25(1):124. doi: 10.3390/e25010124. PMID: 36673265; PMCID: PMC9858266.

7. Khalil, R. A., & Jones, E., & Babar, M., & Jan, T., & Zafar, M., & Alhussain, T. (2019). Speech Emotion Recognition Using Deep Learning Techniques: A Review. IEEE Access. PP. 1-1. 10.1109/ACCESS.2019.2936124.
8. Huang, Z., & Chiang, C., & Chen, J., & Chen, Yi-Chian & Chung, H., & Cai, Y., & Hsu, H. (2023). A study on computer vision for facial emotion recognition. Scientific Reports. 13. 10.1038/s41598-023-35446-4.
9. Kollias, D., Tzirakis, P., Nicolaou, M.A. et al. Deep Affect Prediction in-the-Wild: Aff-Wild Database and Challenge, Deep Architectures, and Beyond. Int J Comput Vis 127, 907–929 (2019). <https://doi.org/10.1007/s11263-019-01158-4>.
10. Zhang, S., & Yang, Y., & Chen, C., & Zhang, X., & Leng, Q., & Zhao, X. (2024). Deep Learning-based Multimodal Emotion Recognition from Audio, Visual, and Text Modalities: A Systematic Review of Recent Advancements and Future Prospects. Expert Systems with Applications. 237. 121692.10.1016/j.eswa.2023.121692.
11. Kollias, Dimitrios & Zafeiriou, Stefanos. (2018). Aff-Wild2: Extending the Aff-Wild Database for Affect Recognition. 10.48550/arXiv.1811.07770.
12. Nhut Minh Nguyen, Thanh Trung Nguyen, Phuong-Nam Tran, Chee Peng Lim, Nhat Truong Pham, Duc Ngoc Minh Dang, Multimodal fusion in speech emotion recognition: A comprehensive review of methods and technologies, Engineering Applications of Artificial Intelligence, Volume 163, Part 1, 2026, 112624, ISSN 0952-1976, <https://doi.org/10.1016/j.engappai.2025.112624>.
13. Savchenko, A.V., Savchenko, L.V. Audio-Visual Continuous Recognition of Emotional State in a Multi-User System Based on Personalized

- Representation of Facial Expressions and Voice. *Pattern Recognit. Image Anal.* 32, 665–671 (2022). <https://doi.org/10.1134/S1054661822030397>
14. Yang X, Lan Z, Wang N, Li J, Wang Y, Meng Y. LiteFer: An Approach Based on MobileViT Expression Recognition. *Sensors (Basel)*. 2024 Sep 10;24(18):5868. doi: 10.3390/s24185868. PMID: 39338612; PMCID: PMC11435806.
 15. Musheng Chen, Qiang Wen, Xiaohong Qiu, Junhua Wu, Wenqing Fu, MDGET-MER: Multi-Level Dynamic Gating and Emotion Transfer for Multi-Modal Emotion Recognition, *Computers, Materials and Continua*, Volume 86, Issue 3, 2026, ISSN 1546-2218, <https://doi.org/10.32604/cmc.2025.071207>.
 16. Mengara Mengara, A. G., & Moon, Y.-k. (2025). CAG-MoE: Multimodal Emotion Recognition with Cross-Attention Gated Mixture of Experts. *Mathematics*, 13(12), 1907. <https://doi.org/10.3390/math13121907>.
 17. Ekman, P., & Friesen, W. V. (1975). *Unmasking the Face: A guide to recognizing emotions from facial clues*. Englewood Cliffs, NJ: Prentice-Hall.
 18. Ekman, P. and Friesen, W.V. (1978) *Facial Action Coding System: A Technique for the Measurement of Facial Movement*. Consulting Psychologists Press, Palo Alto, CA. <https://doi.org/10.1037/t27734-000>.
 19. Ioannou, S., & Raouzaïou, A., & Tzouvaras, V., & Mailis, T., & Karpouzis, K., & Kollias, S. (2005). Emotion recognition through facial expression analysis based on a neurofuzzy network. *Neural Networks*. 18. 423-435.
 20. Abdul, Z., & Al-Talabani, A.. (2022). Mel Frequency Cepstral Coefficient and its Applications: A Review. *IEEE Access*. PP. 1-1. 10.1109/ACCESS.2022.3223444.

21. Eyben, F., & Wöllmer, M., & Schuller, B. (2010). openSMILE -- The Munich Versatile and Fast Open-Source Audio Feature Extractor. MM'10 - Proceedings of the ACM Multimedia 2010 International Conference. 1459-1462. [10.1145/1873951.1874246](https://doi.org/10.1145/1873951.1874246).
22. McFee, B., Raffel, C., Liang, D., Ellis, D. P., McVicar, M., Battenberg, E., & Nieto, O. (2015). librosa: Audio and music signal analysis in Python. In Proceedings of the 14th Python in Science Conference (SciPy 2015) (pp. 18–25). <https://doi.org/10.25080/Majora-7b98e3ed-003>.
23. Hearst, M. A., Dumais, S. T., Osuna, E., Platt, J., & Scholkopf, B. (1998). Support vector machines. IEEE Intelligent Systems and Their Applications, 13(4), 18–28. <https://doi.org/10.1109/5254.708428>.
24. Baevski, A., Zhou, H., Mohamed, A., & Auli, M. (2020). wav2vec 2.0: A framework for self-supervised learning of speech representations. Advances in Neural Information Processing Systems, 33, 12449–12460. <https://arxiv.org/abs/2006.11477>.
25. Wei-Ning Hsu, Benjamin Bolte, Yao-Hung Hubert Tsai, Kushal Lakhotia, Ruslan Salakhutdinov, and Abdelrahman Mohamed. 2021. HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units. IEEE/ACM Trans. Audio, Speech and Lang. Proc. 29 (2021), 3451–3460. <https://doi.org/10.1109/TASLP.2021.3122291>.
26. Chang, Heng-Jui & Yang, Shu-Wen & Lee, Hung-yi. (2021). DistilHuBERT: Speech Representation Learning by Layer-wise Distillation of Hidden-unit BERT. 10.48550/arXiv.2110.01900.
27. Gavali, M. P., & Verma, A. (2026). A novel fusion framework of SSL models and acoustic features for robust speech emotion recognition across languages. Multimedia Tools and Applications, 85, Article 352. <https://doi.org/10.1007/s11042-026-21508-y>.

28. Ismail, S. M. (2025). Mobile-efficient speech emotion recognition using DistilHuBERT: A cross-corpus validation study. arXiv preprint, arXiv:2512.23435. <https://arxiv.org/abs/2512.23435>.
29. Venkataramanan, K., & Rajamohan, H. R. (2019). Emotion recognition from speech. arXiv preprint, arXiv:1912.10458. <https://arxiv.org/abs/1912.10458>.
30. Satt, A., Rozenberg, S., & Hoory, R. (2017). Efficient emotion recognition from speech using deep learning on spectrograms. In Proceedings of Interspeech 2017 (pp. 1081–1085). ISCA. <https://doi.org/10.21437/Interspeech.2017-30>.
31. Mao, Q., Dong, M., Huang, Z., & Zhan, Y. (2019). Learning salient features for speech emotion recognition using convolutional neural networks. IEEE Transactions on Multimedia, 16(8), 2203–2213. <https://doi.org/10.1109/TMM.2014.2360798>.
32. Boonkla, S., et al. (2019). A light-weight deep convolutional neural network for speech emotion recognition using mel-spectrograms. In *2019 14th International Joint Symposium on Artificial Intelligence and Natural Language Processing (iSAI-NLP)* (pp. 1–4). IEEE. <https://doi.org/10.1109/iSAI-NLP48611.2019.9045511>.
33. Viola, P., & Jones, M. (2001). Rapid object detection using a boosted cascade of simple features. Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR 2001), 1, I–I. <https://doi.org/10.1109/CVPR.2001.990517>.
34. Bazarevsky, Valentin & Kartynnik, Yury & Vakunov, Andrey & Raveendran, Karthik & Grundmann, Matthias. (2019). BlazeFace: Sub-millisecond Neural Face Detection on Mobile GPUs. 10.48550/arXiv.1907.05047.

- 35.N. Dalal and B. Triggs, "Histograms of oriented gradients for human detection," 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05), San Diego, CA, USA, 2005, pp. 886-893 vol. 1, doi: 10.1109/CVPR.2005.177.
- 36.K. Zhang, Z. Zhang, Z. Li and Y. Qiao, "Joint Face Detection and Alignment Using Multitask Cascaded Convolutional Networks," in IEEE Signal Processing Letters, vol. 23, no. 10, pp. 1499-1503, Oct. 2016, doi: 10.1109/LSP.2016.2603342.
- 37.Deng, Jiankang & Guo, Jia & Zhou, Yuxiang & Yu, Jinke & Kotsia, Irene & Zafeiriou, Stefanos. (2019). RetinaFace: Single-stage Dense Face Localisation in the Wild. 10.48550/arXiv.1905.00641.
- 38.Jocher, G., Chaurasia, A., & Qiu, J. (2023). Ultralytics YOLOv8 (Version 8.0.0) [Computer software]. <https://github.com/ultralytics/ultralytics>
- 39.Liu, Wei & Erhan, Dumitru & Szegedy, Christian & Reed, Scott & Fu, Cheng-Yang & Berg, Alexander. (2016). SSD: Single Shot MultiBox Detector. 9905. 21-37. 10.1007/978-3-319-46448-0_2.
- 40.A. Howard et al., "Searching for MobileNetV3," 2019 IEEE/CVF International Conference on Computer Vision (ICCV), Seoul, Korea (South), 2019, pp. 1314-1324, doi: 10.1109/ICCV.2019.00140.
- 41.Wang, F., Li, X., & Zhang, Y. (2023). A lightweight method for face expression recognition based on improved MobileNetV3. IET Image Processing. <https://doi.org/10.1049/ipr2.12860>
- 42.A. V. Savchenko, "EmotiEffNets for Facial Processing in Video-based Valence-Arousal Prediction, Expression Classification and Action Unit Detection," 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Vancouver, BC, Canada, 2023, pp. 5716-5724, doi: 10.1109/CVPRW59228.2023.00606.

- 43.Graves, Alex & Schmidhuber, Jürgen. (2005). Framewise phoneme classification with bidirectional LSTM and other neural network architectures. *Neural networks: the official journal of the International Neural Network Society*. 18. 602-10. 10.1016/j.neunet.2005.06.042.
- 44.Cho, Kyunghyun & Merrienboer, Bart & Bahdanau, Dzmitry & Schwenk, Holger & Gulcehre, Caglar & Bougares, Fethi. (2014). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. 10.3115/v1/D14-1179.
- 45.Chung, Junyoung & Gulcehre, Caglar & Cho, KyungHyun. (2014). Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling.
- 46.Sotelo-Barrales, J., Nakano-Miyatake, M., Mata-Mendoza, D., Perez-Meana, H., & Escamilla-Hernandez, E. (2026). Dynamic Facial Expression Recognition by Concatenation of Raw, Semi-Raw, and Distance Features. *Engineering Proceedings*, 123(1), 5. <https://doi.org/10.3390/engproc2026123005>.
- 47.L. Chen, Y. Ouyang, Y. Zeng and Y. Li, "Dynamic facial expression recognition model based on BiLSTM-Attention," 2020 15th International Conference on Computer Science & Education (ICCSE), Delft, Netherlands, 2020, pp. 828-832, doi: 10.1109/ICCSE49874.2020.9201892.
- 48.Huan, Ruo-Hong & Shu, Jia & Bao, Sheng-Lin & Liang, Rong-Hua & Chen, Peng & Chi, Kai-Kai. (2021). Video multimodal emotion recognition based on Bi-GRU and attention fusion. *Multimedia Tools and Applications*. 80. 1-28. 10.1007/s11042-020-10030-4.
- 49.Bai, S., Kolter, J. Z., & Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint, arXiv:1803.01271*.

50. Lee, J. R. H., & Wong, A. (2020). TimeConvNets: A deep time windowed convolution neural network design for real-time video facial expression recognition. 2020 17th Conference on Computer and Robot Vision (CRV), 9–16. <https://api.semanticscholar.org/CorpusID:211988091>.
51. Mehta, A., & Yang, W. (2023). NAC-TCN: Temporal convolutional networks with causal dilated neighborhood attention for emotion understanding. arXiv preprint. <https://www.semanticscholar.org/paper/NAC-TCN%3A-Temporal-Convolutional-Networks-with-for-Mehta-Yang/bda9dc937f701427822aa850e2bde23060346acf>.
52. Poria, S., Cambria, E., Bajpai, R., & Hussain, A. (2017). A review of affective computing: From unimodal analysis to multimodal fusion. *Information Fusion*, 37, 98–125. <https://doi.org/10.1016/j.inffus.2017.02.003>.
53. Zadeh, A., Chen, M., Poria, S., Cambria, E., & Morency, L.-P. (2017). Tensor fusion network for multimodal sentiment analysis. *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, 1103–1114. <https://arxiv.org/abs/1707.07250>.
54. Hu, D., Hou, X., Wei, L., Jiang, L., & Mo, Y. (2022). MM-DFN: Multimodal dynamic fusion network for emotion recognition in conversations. *Proceedings of ICASSP 2022*, 7037–7041. <https://doi.org/10.1109/ICASSP43922.2022.9747397>.
55. Cui, Lin & Zhang, Yuanbang & Cui, Yingkai & Wang, Boyan & Sun, Xiaodong. (2024). A high speed inference architecture for multimodal emotion recognition based on sparse cross modal encoder. *Journal of King Saud University - Computer and Information Sciences*. 36. 102092. [10.1016/j.jksuci.2024.102092](https://doi.org/10.1016/j.jksuci.2024.102092).

56. Huang, Z., Mak, M.-W., Lee, K.A. (2024) MM-NodeFormer: Node Transformer Multimodal Fusion for Emotion Recognition in Conversation. Proc. Interspeech 2024, 4069-4073, doi: 10.21437/Interspeech.2024-538.
57. Soujanya Poria, Devamanyu Hazarika, Navonil Majumder, Gautam Naik, Erik Cambria, and Rada Mihalcea. 2019. MELD: A Multimodal Multi-Party Dataset for Emotion Recognition in Conversations. In Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, pages 527–536, Florence, Italy. Association for Computational Linguistics.
58. Perepelkina, Olga & Kazimirova, Evdokia & Konstantinova, Maria. (2018). RAMAS: Russian Multimodal Corpus of Dyadic Interaction for Studying Emotion Recognition. 10.7287/peerj.preprints.26688v1.
59. Jordal, I., & contributors. (2019). audiomentations: A Python library for audio data augmentation (Version x.x.x) [Computer software]. Zenodo. doi.org
60. Busso, C., Lee, S., & Narayanan, S. S. (2007). Using neutral speech models for emotional speech analysis. Proceedings of Interspeech 2007, 2225–2228.
61. Silero Team. (2021). Silero VAD: pre-trained enterprise-grade Voice Activity Detector (VAD), Number Detector and Language Classifier. GitHub repository. Available at: <https://github.com/snakers4/silero-vad>.
62. He, Jiajun & Mi, Jinyi & Toda, Tomoki. (2025). GIA-MIC: Multimodal Emotion Recognition with Gated Interactive Attention and Modality-Invariant Learning Constraints. 10.48550/arXiv.2506.00865.
63. Mittal, Trisha & Bhattacharya, Uttaran & Chandra, Rohan & Bera, Aniket & Manocha, Dinesh. (2020). M3ER: Multiplicative Multimodal Emotion Recognition using Facial, Textual, and Speech Cues. Proceedings of the

- AAAI Conference on Artificial Intelligence. 34. 1359-1367.
10.1609/aaai.v34i02.5492.
64. Tripathi, Samarth & Beigi, Homayoon. (2018). Multi-Modal Emotion recognition on IEMOCAP Dataset using Deep Learning. 10.48550/arXiv.1804.05788.

Приложение 1. Примеры работы real-time демо версии.

