

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

**Программа подготовки бакалавров по направлению
09.03.04 Программная инженерия**

Канделов Дамир Русланович

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Классификация выражений лиц с детектированием эмоций в речи

Научный руководитель

Старший научный сотрудник

факультета компьютерных наук

Доцент кафедры информационных

систем и технологий

Кандидат технических наук

Л.В. Савченко

Нижний Новгород, 2026

Содержание

1.	4
2.	10
3.	Исследование предметной области 7
3.1.	Что такое Path tracing? 7
3.2.	Отличие Path tracing от Ray tracing 8
3.3.	Алгоритм работы Path tracing 9
3.4.	Случайные числа в алгоритме Path tracing 13
3.5.	Влияние случайных чисел на качество изображений. 14
4.	Описание решения 15
4.1.	Реализация программы рендеринга изображений 15
4.1.1.	Написание базовой логики. Первые изображения. 15
4.1.2.	Добавление новых функций в 3D движок. 16
4.2.	Использование случайных чисел в 3D движке 18
4.3.	Генерация случайных чисел 19
4.3.1.	Standard sampler 19
4.3.2.	Halton sampler 20
4.3.3.	Halton Sampler с использованием RandomDigit скремблинга 23
4.3.4.	Halton Sampler с использованием Owen скремблинга 25

2

4.3.5. Blue Noise sampler	27
5. Результаты. Сравнение алгоритмов.	31
5.1. Визуальное сравнение	31
5.1.1. Сравнение методов выборки на сцене «Волк»	31
5.1.2. Сравнение методов выборки на сцене «Cornell Box»	35
5.1.3. Результаты визуального сравнения	39
5.2. Сравнение с использованием метрик	40
5.2.1. Метрика MSE	40
5.2.2. Метрика FLIP	43
5.3. Результаты сравнений	44
6.	20
7.	22

1. Введение

Эмоции играют фундаментальную роль в человеческом общении, они влияют на принятие решений, социальные взаимодействия и общее психологическое благополучие. Способность классифицировать выражения лиц и эмоции становится все более важной задачей в развитии общения между человек и компьютером (human-computer interaction, HCI), особенно в областях распознавания эмоций в разговорах (emotion recognition in conversations, ERC) и более современного мультимодального распознавания эмоций в разговорах (multimodal recognition in conversations, MERC).

Понимание текущего эмоционального состояния человека позволяет компьютерным системам получать больше информации о состоянии человека в конкретный момент времени и отвечать более естественным образом. В настоящее время это практически не применяется, но уже может быть использовано в:

- виртуальных ассистентах (Алиса, ChatGPT и т.д.) для того чтобы сделать общение с человеком более живым и естественным - формировать ответы с учетом текущего эмоционального состояния человека;
- системах мониторинга обслуживания клиентов и аналитике психологического состояния - эмоции человека могут показать его реальное отношение к каким-то действиям;
- образовании - определение вовлеченности студентов, усталости и скуки, автоматическая адаптация сложности материала;

- контроль состояния водителя автомобиля / автобуса / поезда / самолета - с предупреждением в случае сонливости, злости, отвлеченности;
- компьютерные игры с адаптацией под текущее состояние игрока.

В настоящее время такие механизмы уже применяются в современных системах, но ограниченно и совсем не на максимуме своих возможностей. Зачастую это происходит из-за высокой стоимости использования таких систем или недостаточно высокого качества классификации. В данной курсовой работе будет представлена новая мультимодальная архитектура, позволяющая снизить потребление вычислительных ресурсов с сохранением высокого качества классификации.

Таким образом, востребованность и актуальность темы данной работы обусловлены потребностями современных компаний в создании эффективных и экономичных систем определения эмоций. В условиях стремительного развития технологий искусственного интеллекта и расширения областей его применения особую значимость приобретает разработка именно оптимизированных методов распознавания эмоций.

2. Постановка задачи

В работе будут подробно рассмотрены современные подходы к классификации эмоции по речи, по выражению лиц, а также к мультимодальной классификации. Для лучшего понимания будут использоваться не только лучшие современные подходы, но и базовые, считающиеся фундаментальными в этих сферах.

Ключевым препятствием для внедрения мультимодальных систем распознавания эмоций в реальные приложения является их вычислительная сложность [12]. Современные модели, как правило, строятся по принципу параллельной обработки обоих потоков данных: видео и аудио обрабатываются одновременно тяжелыми нейросетевыми бэкбонами, что приводит к высокому энергопотреблению, долгой работе моделей и делает практически невозможным их использование на мобильных устройствах, во встраиваемых системах или в сервисах с ограниченным бюджетом. Эта проблема активно осознается научным сообществом: в последние годы появились работы: направленные на создание легких моделей для устройств с ограниченными вычислительными ресурсами, например на основе MobileNetV3 [13] [14]. В контексте мультимодального анализа все чаще обсуждаются подходы с динамической активацией наиболее информативных модальностей или экспертные сети для повышения эффективности [15] [16].

В данной работе предлагается архитектурное решение, органично вписывающееся в эту тенденцию: двухстадийная система распознавания эмоций. Основная идея заключается в использовании легкого аудиогейта, который на входе бинарно решает «нейтральная» эмоция или «не нейтральная», и только в случае обнаружения не нейтральных эмоций запускается ресурсоемкая

видеомодель, определяющая один из шести – восьми классов эмоций (в зависимости от датасета). Такой подход отличается от классических мультимодальных архитектур, которые в большинстве случаев ориентированы на параллельный анализ всех модальностей для каждого фрагмента. Предлагаемый каскад позволяет достичь компромисса между качеством распознавания и вычислительной эффективностью.

Таким образом **актуальность исследования обусловлена** четырьмя ключевыми факторами:

1. Практической потребностью в легких, энерго- и ресурсо-эффективных системах распознавания эмоций для мобильных, встраиваемых и периферийных платформ, где современные MER архитектуры неприменимы.
2. Отсутствием в литературе каскадных мультимодальных систем с аудиогейтом специально ориентированным на проверку речи на нейтральность. Хотя работы по динамическому стробированию появляются, они преимущественно фокусируются на взвешивании уже обработанных признаков, а не на раннем решении об активации целой ветви обработки [15].
3. Необходимостью в прозрачной методологии оценки, исключающей утечку информации о дикторе при сохранении баланса классов в выборке, что позволит получать результаты, адекватно отражающие работу системы в реальных условиях общения с незнакомыми людьми.
4. Возможностью значительного сокращения вычислительных затрат без потери качества распознавания за счет активации видео модели только при необходимости, что открывает перспективы для масштабирования

и практического внедрения мультимодальных систем в тех областях, где ранее они считались слишком ресурсозатратными.

Предлагаемая работа вносит вклад в решение этих проблем, а полученные результаты могут быть использованы как в академических исследованиях, так и в прикладных разработках в области человеко-компьютерного взаимодействия.

Новизна данного исследования состоит в разработке новой двухстадийной эффективной, малоресурсозатратной архитектуры для задачи MER, которая использует легкий бинарный аудио классификатор для определения нейтральности речи и, в случае эмоциональной речи включается видео модель для классификации конкретной эмоции.

Целью данного исследования является разработка, реализация и экспериментальная оценка и замер качества двухэтапной мультимодальной системы распознавания эмоций, которая уменьшает затраты вычислительных ресурсов по сравнению с традиционными синхронными архитектурами без значимого ухудшения точности классификации на стандартных датасетах (RAVDESS [2], CREMA-D [3]), а также финальном бенчмарке (IEMOCAP [4]).

Ключевая гипотеза этого проекта состоит в том, что в реальном диалоге подавляющая доля кадров эмоционально нейтральна. Следовательно, применение легкого аудиогейта, быстро выявляющего нейтральные фрагменты, позволяет избежать использование тяжелых видеомоделей для этих кадров, значительно сокращая среднее время обработки без критической потери качества распознавания.

Задачами исследования являются:

1. Анализ предметной области: изучение подходов к распознаванию эмоций по речи (SER), по выражениям лиц (FER), по обеим модальностям (MER).
2. Выявление возможности оптимизации современных архитектур за счет последовательной обработки аудио и видео. Определение базовых моделей для сравнения с нашей архитектурой.
3. Подготовка данных. Анализ датасетов, выбор подходящих для нашей задачи, предобработка.
4. Разработка аудиогейта. Реализовать и сравнить несколько подходов для выявления лучшего, сравнение по трем параметрам: качество, скорость работы и вес модели.
5. Построение классификатора по видео. Определить модели для выявления признаков, а также модели-классификаторы получившихся признаков. Выбрать несколько лучших на текущий момент подходов, сравнить их с более легковесными, провести сравнение по аналогичным параметрам, как в пункте 4.
6. Сборка двухэтапного пайплайна. Объединение аудиогейта и классификатора по видео в одну архитектуру.
7. Написание бейзлайнов для сравнения нашей архитектуры с текущими лучшими. Экспериментальная оценка качества, времени работы и затраченной памяти на итоговом бенчмарке.
8. Реализация прототипа реального времени. Разработка демонстрационного скрипта, обрабатывающего поток с веб-камеры и микрофона в реальном времени. Практический пример работы итоговой архитектуры.

Решение данных задач позволит проверить сформулированную гипотезу и создать ресурсоэффективную архитектуру распознавания эмоций с аудиогейтом.

3. Аналитический обзор литературы

3.1. Ранние исследования в области распознавания эмоций

Исследования в области распознавания эмоций берут свое начало в работах по психологии и эффективным вычислениям. Фундаментальной основой для большинства современных систем стали работы Пола Экмана и Уоллеса Фризена, которые в середине 1970-х годов эмпирически обосновали теорию универсальности мимических выражений эмоций. Эта теория говорит о том, что независимо от культурного происхождения и воспитания, люди выражают шесть базовых эмоций сходным образом: счастье, грусть, гнев, страх, удивление и отвращение [17]. Пол Экман и Уоллес Фризен смогли не только определить 6 классов эмоций, но также они предложили детальную систему для классифицирования лицевых выражений (Facial Action Coding System, FACS), которая позволяет описывать мимические изменения через действия лицевых мышц [18]. Эта система до сих пор остается золотым стандартом для аннотирования выражений лиц в компьютерном зрении.

Первые попытки автоматизировать распознавание эмоций опирались на классические методы машинного обучения и ручной подбор признаков. В работе Ioannou и др. 2005 года [19] использовалась neurofuzzy network (нейро-нечеткая сеть) для классификации эмоций по изображениям лиц (Facial Emotion Recognition, FER). На первом этапе детекция лица выполнялась с помощью метода опорных векторов (SVM), затем из выделенной области лица извлекались геометрические признаки (положение бровей, глаз, уголков губ). Полученный вектор признаков подавался на вход neurofuzzy сети, сочетающей преимущества нейронных сетей и нечеткой логики. Эксперименты показали, что такой гибридный подход может превосходить чистые статистические методы, однако

он оставался чувствительным к условиям освещения и поворотам головы, а также требовал тщательной ручной настройки детектора лицевых признаков.

Параллельно с компьютерным зрением развивалась область распознавания эмоций по голосу (Speech Emotion Recognition, SER). Ключевой идеей было выделение просодических и спектральных характеристик речевого сигнала, которые коррелируют с эмоциями говорящего. Наиболее популярным набором признаков стали мел-частотные кепстральные коэффициенты (MFCC), которые компактно представляют спектральную огибающую звука [20]. Кроме MFCC, использовались также следующие признаки: основная частота голоса (F0), энергия, длительность пауз, скорость речи. Классическими классификаторами выступали скрытые марковские модели (Hidden Markov Model, HMM), методы опорных векторов (SVM) и гауссовские смеси (Gaussian Mixture Model, GMM). Однако универсальные системы SER сильно уступали человеку по точности, особенно в условиях фонового шума или при распознавании эмоций незнакомых дикторов.

С развитием Deep Learning (DL) ситуация в обеих областях: FER и SER, кардинально изменилась. Появилась возможность автоматически извлекать иерархические признаки из сырых данных, что устранило необходимость в ручном проектировании признаков. В компьютерном зрении стали доминировать сверточные нейронные сети (CNN), такие как VGG, ResNet и более легкие архитектуры (MobileNet, EfficientNet). В обработке речи – рекуррентные сети (LSTM, GRU) и трансформеры (Wav2Vec 2.0, HuBERT). Однако, проблема распознавания эмоций в реальных сценариях, когда одновременно присутствуют и мимика, и голос, и они могут быть частично избыточны или противоречивы, оставалась открытой. Именно это привело к

формированию направления мультимодального распознавания эмоций (Multimodal Emotion Recognition, MER), в котором информация из двух и более каналов (аудио, видео, текст) объединяется для повышения точности, надежности и устойчивости.

Ранние исследования были сфокусированы на одномодальных подходах (определение эмоций только по речи / только по выражению лица).

Первый вид: Speech emotion recognition (SER) [7] заключается в выделении признаков из речи человека, с помощью, например лог-мел спектограмм или мел-частотных коэффициентов (MFCC) и использование классификационных моделей, чтобы определить и выучить общие паттерны эмоций.

Второй вид: Facial expression emotion recognition (FER) [8] состоит в использовании техник компьютерного зрения (CV), для отслеживания изменений мышц лица. В фундаментальной работе Ekman и Friesen [9] все мышцы лица были разделены на три основные группы, наиболее важные для задачи FER: брови и лоб, глаза и веки, а также нижняя часть лица.

Однако, одномодальные системы ограничены по двум параметрам: количеству информации, которую можно получить из одной модальности и подверженности влиянию окружающих факторов (шум, недостаток света и т.д.). Это приводит к следующему этапу развития систем классификации эмоций: мультимодальные системы.

Мультимодальные системы определения эмоций (MER) [10] являются объединением систем SER, FER, а также не описанной ранее системы определения эмоций по тексту (расшифровке речи человека) для более надежной и качественной классификации. Один из примеров MER архитектуры, основанный на графовых нейросетях [11] показал, что данный подход способен показывать высокие метрики качества, однако требует большого количества вычислительных ресурсов. Именно в этом и заключается основная проблема использования MER систем в приложениях, которые обрабатывают данные в реальном времени.

3.2. Обзор существующих алгоритмов распознавания эмоций

Задача классификации выражений лиц с детектированием эмоций в речи подразумевает определение эмоции по двум модальностям: голосу и выражению лица человека. Рассмотрим уже существующие подходы по данным темам.

4. Анализ датасетов

Для обучения моделей, а также для корректной валидации результатов необходимо подобрать датасеты. Наша архитектура подразумевает использование датасетов для двух задач: классификация нейтральности по речи, и определение эмоции по выражению лица.

Для более качественного, эффективного и сбалансированного обучения мы будем комбинировать датасеты при обучении, то есть использовать сразу несколько для обучения каждой модели. Это позволит модели обучиться на различных данных, не зависящих от конкретного языка датасета, национальности авторов или других уникальных признаков датасета.

Важно также различать датасеты, которые мы будем использовать для предобучения наших моделей и датасеты, на которых будем измерять качество, так как если для обеих целей использовать одни и те же датасеты, то в результаты мы получим завышенные результаты из-за “утечки таргета” (Target leakage).

В данной работе для построения эффективной мультимодальной системы распознавания эмоций были использованы три датасета: RAVDESS, CREMA-D и IEMOCAP. Первые два использовались для предварительного обучения аудио и видео моделей, а IEMOCAP - в качестве целевого датасета для тонкой настройки и финального замера качества архитектуры. Данные три датасета были выбраны, так как они широко используются в работах по классификации эмоций, содержат чистые аудио и хорошо различимые видео данные, а также содержат сразу обе модальности.

4.1. RAVDESS (Ryerson Audio-Visual Database of Emotional Speech and Song)

Первый датасет, который я использовал - **RAVDESS** [2]. В нем содержатся студийные записи разговоров актеров. Всего: 7356 аудиовизуальных записей, записанных 24 профессиональными актерами, как мужчинами, так и женщинами. Все фрагменты записаны с высокой частотой дискретизации (48 кГц). Язык датасета - английский.

Датасет содержит 8 классов эмоций: нейтральная, спокойная, радость, грусть, страх, гнев, отвращение и удивление. А также 5 категорий для вокального исполнения, которые не использовались в данной работе. Каждая запись маркируется уровнем интенсивности эмоции: нормальный или высокий. Каждое видео содержит ровно одну эмоцию.

Для нашего исследования использовались только речевые аудио и видео фрагменты (пение не использовалось). Аудиодорожки были приведены к моноформату с частотой 16 кГц - для большей универсальности и применимости модели к другим датасетам с частотой 16 кГц, а также для повышения производительности модели.

RAVDESS был выбран в качестве основного датасета для предобучения видео модели, поскольку содержит хорошо размеченные, синхронизированные аудио и видеозаписи с хорошо видимыми выражениями лиц.

4.2. CREMA-D (Crowd-sourced Emotional Multimodal Actors Dataset)

CREMA-D [3] содержит 7442 видео, записанных 48 мужчинами и 43 женщинами. В отличие от RAVDESS это добровольцы, а не профессиональные

актеры, из-за чего эмоции менее наигранные. Также среди участников были различные этнические и возрастные группы.

Использование датасета CREMA-D в дополнение к RAVDESS обеспечивает большее разнообразие лицевых особенностей и обучение на более естественных эмоциях. Каждый клип также содержит произнесение одной фразы с одной из шести эмоциональных окрасок: нейтральная, радость, грусть, гнев, страх, отвращение. Как можно заметить, эмоции совпадают с первым датасетом, за исключением двух отсутствующих: спокойная и удивленная - некоторый дисбаланс классов важно будет учитывать при обучении.

Запись датасета также велась в студийных условиях с частотой дискретизации 16 кГц для аудио и разрешением видео 640x480 пикселей.

CREMA-D использовался совместно с RAVDESS для предварительного обучения аудио классификатора. Объединение данных привело к повышению обобщающей способности аудиогейта перед итоговым замером качества на IEMOCAP.

4.3. IEMOCAP (Interactive emotional dyadic motion capture database)

IEMOCAP [4] считается одним из фундаментальных наборов данных для классификации эмоций в диалоговой речи. В нем содержатся около 12 часов аудиовизуальных записей разговоров между 10 актерами (5 мужчин и 5 женщин), разбитых на 5 сессий. Каждая такая сессия включает в себя диалог по заранее написанному сценарию, а также спонтанные импровизации на определенную тему. Категории эмоций проставлены для отдельных высказываний – каждому такому фрагменту соответствует одна эмоция (гнев,

радость, грусть, нейтральность, волнение, усталость, восхищение, страх и «другая» эмоция).

Существует принципиальное отличие от RAVDESS и CREMA-D – в данном датасете спонтанный, диалоговый характер речи и мимики, более приближенный к реальному общению людей. Эмоции здесь менее утрированы, часто появляются между состояниями в пределах одного высказывания. Кроме того, видео содержат естественные окклюзии, различные варианты освещения и повороты головы, характерные для реальных условий общения. Из-за этого IEMOCAP более сложный датасет для нашей задачи, но одновременно с этим является более репрезентативным бенчмарком для оценки качества мультимодальных систем распознавания эмоций.

В данном исследовании IEMOCAP выступает в качестве целевого датасета. Модели, предварительно обученные на RAVDESS и CREMA-D, дообучаются на сессиях 1-4 с валидацией на сессии 5. Модели классифицируют аудио и видео по 8 классам эмоций. «Другая» эмоция была исключена из датасета из-за крайне малого количества примеров, а также отсутствия в датасетах предобучения.

4.4. Стратегия использования датасетов для обучения

RAVDESS и CREMA-D являются «лабораторными» датасетами с качественными записями и хорошо выраженными эмоциями, тогда как IEMOCAP представляет собой существенно более сложный и реалистичный набор данных. Такой контраст создает серьезный доменный сдвиг между предобучением и целевой задачей. Данная проблема решается применением

аугментаций как к видео: уменьшение яркости, обрезание видео, так и к аудио: уменьшение громкости, добавление помех.

Многочисленные исследования демонстрируют, что предварительное обучение на крупных датасетах актерской речи с последующей тонкой настройкой на IEMOCAP позволяет получить достаточно хорошие веса моделей, релевантные для задачи классификации нейтральных и эмоциональных состояний, а также сократить объем данных, необходимых для адаптации к спонтанной речи [4], [5].

Именно поэтому в нашем пайплайне компоненты обучаются в два этапа: сначала аудио-модель (классификатор нейтральная или не нейтральная речь) обучается на RAVDESS + CREMA-D с аугментациями, а видео-модель – на видеофрагментах RAVDESS, опять же с аугментациями; затем полученные веса загружаются, и вся итоговая архитектура дообучается на IEMOCAP с замороженным визуальным энкодером.

Таким образом, выбранный набор датасетов и стратегия обучения позволяют:

- Использовать высококачественные наборы данных для формирования базового представления моделей
- А также адаптировать модель к сложным, естественным условиям диалогового взаимодействия.

1. Заключение

Результатами данной курсовой работы стали:

- Подробное изучение существующих подходов к рендерингу изображений, как они устроены изнутри, а также методы их оптимизации и дальнейшего развития;
- Была написана собственная программа для рендеринга изображений на C++ с нуля, с возможностью дополнять ее новыми функциями, а также продолжать работать над ней, как над серьезным проектом;
- Было проведено исследование и поиск алгоритмов для генерации случайных чисел, которые могли бы поспособствовать уменьшению времени рендеринга изображений в хорошем качестве;
- Были выбраны и реализованы на языке C++ 4 метода генерации случайных чисел: Halton Sampler, Halton RandomDigit Sampler, Halton Owen Sampler, Blue Noise Sampler. Они были добавлены в программу рендеринга изображений и с их помощью были срендерены изображения, необходимые для сравнения;
- Было проведено сравнение и анализ написанных методов генерации случайных чисел с использованием современных метрик, используемых в настоящих проектах по 3D графике;
- Были выделены алгоритмы, которые показывают наилучшие результаты за наименьшее время: Blue Noise Sampler, Halton RandomDigit Sampler.

Все материалы и результаты, которые были получены в ходе данной курсовой работы имеют большой практический смысл и потенциал. На примере простой программы для рендеринга было показано, что с помощью изменения подхода к генерации случайных чисел в алгоритме рендеринга могут быть получены хорошие результаты за меньшее время. Все результаты могут быть полезны для всех, кто занимается рендерингом изображений и графикой, так как способны значительно ускорить рендеринг изображений хорошего качества.

А также знания и навыки, которые лично я получил в ходе написания данной курсовой работы оказались очень полезными, а их уровень близок к современному уровню развития графических приложений и алгоритмов рендеринга. Проект, который был написан в ходе данной курсовой работы, однозначно продолжит развиваться и расширяться.

Git-репозиторий курсовой работы и проекта доступен по ссылке:

<https://github.com/Kaparya/PathTracing>

2. Библиографический список

1. Burkhardt, Felix & Paeschke, Astrid & Rolfes, M. & Sendlmeier, Walter & Weiss, Benjamin. (2005). A database of German emotional speech. 9th European Conference on Speech Communication and Technology. 5. 1517-1520. 10.21437/Interspeech.2005-446.
2. Livingstone SR, Russo FA. The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in North American English. PLoS One. 2018 May 16;13(5):e0196391. doi: 10.1371/journal.pone.0196391. PMID: 29768426; PMCID: PMC5955500.
3. Cao H, Cooper DG, Keutmann MK, Gur RC, Nenkova A, Verma R. CREMA-D: Crowd-sourced Emotional Multimodal Actors Dataset. IEEE Trans Affect Comput. 2014 Oct-Dec;5(4):377-390. doi: 10.1109/TAFFC.2014.2336244. PMID: 25653738; PMCID: PMC4313618.
4. C. Busso, M. Bulut, C. Lee, A. Kazemzadeh, E. Mower, S. Kim, J. Chang, S. Lee, and S. Narayanan, "IEMOCAP: Interactive emotional dyadic motion capture database," Journal of Language Resources and Evaluation, vol. 42, no. 4, pp. 335-359, December 2008
5. Latif, Siddique & Rana, Rajib & Younis, Shahzad & Qadir, Junaid & Epps, Julien. (2018). Cross Corpus Speech Emotion Classification - An Effective Transfer Learning Technique. 10.48550/arXiv.1801.06353.
6. Fu H, Zhuang Z, Wang Y, Huang C, Duan W. Cross-Corpus Speech Emotion Recognition Based on Multi-Task Learning and Subdomain Adaptation. Entropy (Basel). 2023 Jan 7;25(1):124. doi: 10.3390/e25010124. PMID: 36673265; PMCID: PMC9858266.

7. Khalil, R. A., & Jones, E., & Babar, M., & Jan, T., & Zafar, M., & Alhussain, T. (2019). Speech Emotion Recognition Using Deep Learning Techniques: A Review. IEEE Access. PP. 1-1. 10.1109/ACCESS.2019.2936124.
8. Huang, Z., & Chiang, C., & Chen, J., & Chen, Yi-Chian & Chung, H., & Cai, Y., & Hsu, H. (2023). A study on computer vision for facial emotion recognition. Scientific Reports. 13. 10.1038/s41598-023-35446-4.
9. Ekman, P., & Friesen, W. V. (1975). Unmasking the Face: A guide to recognizing emotions from facial clues. Englewood Cliffs, NJ: Prentice-Hall.
10. Zhang, S., & Yang, Y., & Chen, C., & Zhang, X., & Leng, Q., & Zhao, X. (2024). Deep Learning-based Multimodal Emotion Recognition from Audio, Visual, and Text Modalities: A Systematic Review of Recent Advancements and Future Prospects. Expert Systems with Applications. 237. 121692.10.1016/j.eswa.2023.121692.
11. Hu, D., & Hou, X., & Wei, L., & Jiang, L., & Mo, Y. (2022). MM-DFN: Multimodal Dynamic Fusion Network for Emotion Recognition in Conversations. 7037-7041. 10.1109/ICASSP43922.2022.9747397.
12. Nhut Minh Nguyen, Thanh Trung Nguyen, Phuong-Nam Tran, Chee Peng Lim, Nhat Truong Pham, Duc Ngoc Minh Dang, Multimodal fusion in speech emotion recognition: A comprehensive review of methods and technologies, Engineering Applications of Artificial Intelligence, Volume 163, Part 1, 2026, 112624, ISSN 0952-1976, <https://doi.org/10.1016/j.engappai.2025.112624>.
13. Savchenko, A.V., Savchenko, L.V. Audio-Visual Continuous Recognition of Emotional State in a Multi-User System Based on Personalized Representation of Facial Expressions and Voice. Pattern Recognit. Image Anal. 32, 665–671 (2022). <https://doi.org/10.1134/S1054661822030397>

14. Yang X, Lan Z, Wang N, Li J, Wang Y, Meng Y. LiteFer: An Approach Based on MobileViT Expression Recognition. *Sensors* (Basel). 2024 Sep 10;24(18):5868. doi: 10.3390/s24185868. PMID: 39338612; PMCID: PMC11435806.
15. Musheng Chen, Qiang Wen, Xiaohong Qiu, Junhua Wu, Wenqing Fu, MDGET-MER: Multi-Level Dynamic Gating and Emotion Transfer for Multi-Modal Emotion Recognition, *Computers, Materials and Continua*, Volume 86, Issue 3, 2026, ISSN 1546-2218, <https://doi.org/10.32604/cmc.2025.071207>.
16. Mengara Mengara, A. G., & Moon, Y.-k. (2025). CAG-MoE: Multimodal Emotion Recognition with Cross-Attention Gated Mixture of Experts. *Mathematics*, 13(12), 1907. <https://doi.org/10.3390/math13121907>.
17. Ekman, P., & Friesen, W. V. (1975). *Unmasking the Face: A guide to recognizing emotions from facial clues*. Englewood Cliffs, NJ: Prentice-Hall.
18. Ekman, P. and Friesen, W.V. (1978) *Facial Action Coding System: A Technique for the Measurement of Facial Movement*. Consulting Psychologists Press, Palo Alto, CA. <https://doi.org/10.1037/t27734-000>.
19. Ioannou, S., & Raouzaïou, A., & Tzouvaras, V., & Mailis, T., & Karpouzis, K., & Kollias, S. (2005). Emotion recognition through facial expression analysis based on a neurofuzzy network. *Neural Networks*. 18. 423-435.
20. Abdul, Z., & Al-Talabani, A.. (2022). Mel Frequency Cepstral Coefficient and its Applications: A Review. *IEEE Access*. PP. 1-1. 10.1109/ACCESS.2022.3223444.