

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

**Программа подготовки бакалавров по направлению
09.03.04 Программная инженерия**

Канделов Дамир Русланович

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Классификация выражений лиц с детектированием эмоций в речи

Научный руководитель

Старший научный сотрудник

факультета компьютерных наук

Доцент кафедры информационных

систем и технологий

Кандидат технических наук

Л.В. Савченко

Нижний Новгород, 2026

Содержание

1.....	Введение
4	
2.Постановка	задачи
6	
3.Аналитический	обзор литературы
10	
3.1.Ранние исследования в области распознавания эмоций	
10	
3.2.Традиционные методы распознавания эмоций	
12	
3.2.1.Распознавание эмоций по речи (SER)	
12	
3.3.Современные подходы на основе глубокого обучения	
12	
3.4.Обзор существующих алгоритмов распознавания эмоций	
26	
4.Анализ	датасетов
27	
4.1.RAVDESS (Ryerson Audio-Visual Database of Emotional Speech and Song)	28
4.2.CREMA-D (Crowd-sourced Emotional Multimodal Actors Dataset)	
28	
2	

4.3. IEMOCAP (Interactive emotional dyadic motion capture database)	29
4.4. Стратегия использования датасетов для обучения	30
1.	Заключение
34	
2. Библиографический	список
36	

1. Введение

Эмоции играют фундаментальную роль в человеческом общении, они влияют на принятие решений, социальные взаимодействия и общее психологическое благополучие. Способность классифицировать выражения лиц и эмоции становится все более важной задачей в развитии общения между человеком и компьютером (human-computer interaction, HCI), особенно в областях распознавания эмоций в разговорах (emotion recognition in conversations, ERC) и более современного мультимодального распознавания эмоций в разговорах (multimodal recognition in conversations, MERC).

Понимание текущего эмоционального состояния человека позволяет компьютерным системам получать больше информации о состоянии человека в конкретный момент времени и отвечать более естественным образом. В настоящее время это практически не применяется, но уже может быть использовано в:

- виртуальных ассистентах (Алиса, ChatGPT и т.д.) для того чтобы сделать общение с человеком более живым и естественным - формировать ответы с учетом текущего эмоционального состояния человека;
- системах мониторинга обслуживания клиентов и аналитике психологического состояния - эмоции человека могут показать его реальное отношение к каким-то действиям;
- образовании - определение вовлеченности студентов, усталости и скуки, автоматическая адаптация сложности материала;

- контроль состояния водителя автомобиля / автобуса / поезда / самолета - с предупреждением в случае сонливости, злости, отвлеченности;
- компьютерные игры с адаптацией под текущее состояние игрока.

В настоящее время такие механизмы уже применяются в современных системах, но ограниченно и совсем не на максимуме своих возможностей. Зачастую это происходит из-за высокой стоимости использования таких систем или недостаточно высокого качества классификации. В данной курсовой работе будет представлена новая мультимодальная архитектура, позволяющая снизить потребление вычислительных ресурсов с сохранением высокого качества классификации.

Таким образом, востребованность и актуальность темы данной работы обусловлены потребностями современных компаний в создании эффективных и экономичных систем определения эмоций. В условиях стремительного развития технологий искусственного интеллекта и расширения областей его применения особую значимость приобретает разработка именно оптимизированных методов распознавания эмоций.

2. Постановка задачи

В работе будут подробно рассмотрены современные подходы к классификации эмоции по речи, по выражению лиц, а также к мультимодальной классификации. Для лучшего понимания будут использоваться не только лучшие современные подходы, но и базовые, считающиеся фундаментальными в этих сферах.

Ключевым препятствием для внедрения мультимодальных систем распознавания эмоций в реальные приложения является их вычислительная сложность [12]. Современные модели, как правило, строятся по принципу параллельной обработки обоих потоков данных: видео и аудио обрабатываются одновременно тяжелыми нейросетевыми бэкбонами, что приводит к высокому энергопотреблению, долгой работе моделей и делает практически невозможным их использование на мобильных устройствах, во встраиваемых системах или в сервисах с ограниченным бюджетом. Эта проблема активно осознается научным сообществом: в последние годы появились работы: направленные на создание легких моделей для устройств с ограниченными вычислительными ресурсами, например на основе MobileNetV3 [13] [14]. В контексте мультимодального анализа все чаще обсуждаются подходы с динамической активацией наиболее информативных модальностей или экспертные сети для повышения эффективности [15] [16].

В данной работе предлагается архитектурное решение, органично вписывающееся в эту тенденцию: двухстадийная система распознавания эмоций. Основная идея заключается в использовании легкого аудиогейта, который на входе бинарно решает «нейтральная» эмоция или «не нейтральная», и только в случае обнаружения не нейтральных эмоций запускается ресурсоемкая

видеомодель, определяющая один из шести – восьми классов эмоций (в зависимости от датасета). Такой подход отличается от классических мультимодальных архитектур, которые в большинстве случаев ориентированы на параллельный анализ всех модальностей для каждого фрагмента. Предлагаемый каскад позволяет достичь компромисса между качеством распознавания и вычислительной эффективностью.

Таким образом **актуальность исследования обусловлена** четырьмя ключевыми факторами:

1. Практической потребностью в легких, энерго- и ресурсо-эффективных системах распознавания эмоций для мобильных, встраиваемых и периферийных платформ, где современные MER архитектуры неприменимы.
2. Отсутствием в литературе каскадных мультимодальных систем с аудиогейтом специально ориентированным на проверку речи на нейтральность. Хотя работы по динамическому стробированию появляются, они преимущественно фокусируются на взвешивании уже обработанных признаков, а не на раннем решении об активации целой ветви обработки [15].
3. Необходимостью в прозрачной методологии оценки, исключающей утечку информации о дикторе при сохранении баланса классов в выборке, что позволит получать результаты, адекватно отражающие работу системы в реальных условиях общения с незнакомыми людьми.
4. Возможностью значительного сокращения вычислительных затрат без потери качества распознавания за счет активации видео модели только при необходимости, что открывает перспективы для масштабирования

и практического внедрения мультимодальных систем в тех областях, где ранее они считались слишком ресурсозатратными.

Предлагаемая работа вносит вклад в решение этих проблем, а полученные результаты могут быть использованы как в академических исследованиях, так и в прикладных разработках в области человеко-компьютерного взаимодействия.

Новизна данного исследования состоит в разработке новой двухстадийной эффективной, малоресурсозатратной архитектуры для задачи MER, которая использует легкий бинарный аудио классификатор для определения нейтральности речи и, в случае эмоциональной речи включается видео модель для классификации конкретной эмоции.

Целью данного исследования является разработка, реализация и экспериментальная оценка и замер качества двухэтапной мультимодальной системы распознавания эмоций, которая уменьшает затраты вычислительных ресурсов по сравнению с традиционными синхронными архитектурами без значимого ухудшения точности классификации на стандартных датасетах (RAVDESS [2], CREMA-D [3]), а также финальном бенчмарке (IEMOCAP [4]).

Ключевая гипотеза этого проекта состоит в том, что в реальном диалоге подавляющая доля кадров эмоционально нейтральна. Следовательно, применение легкого аудиогейта, быстро выявляющего нейтральные фрагменты, позволяет избежать использование тяжелых видеомоделей для этих кадров, значительно сокращая среднее время обработки без критической потери качества распознавания.

Задачами исследования являются:

1. Анализ предметной области: изучение подходов к распознаванию эмоций по речи (SER), по выражениям лиц (FER), по обеим модальностям (MER).
2. Выявление возможности оптимизации современных архитектур за счет последовательной обработки аудио и видео. Определение базовых моделей для сравнения с нашей архитектурой.
3. Подготовка данных. Анализ датасетов, выбор подходящих для нашей задачи, предобработка.
4. Разработка аудиогейта. Реализовать и сравнить несколько подходов для выявления лучшего, сравнение по трем параметрам: качество, скорость работы и вес модели.
5. Построение классификатора по видео. Определить модели для выявления признаков, а также модели-классификаторы получившихся признаков. Выбрать несколько лучших на текущий момент подходов, сравнить их с более легковесными, провести сравнение по аналогичным параметрам, как в пункте 4.
6. Сборка двухэтапного пайплайна. Объединение аудиогейта и классификатора по видео в одну архитектуру.
7. Написание бейзлайнов для сравнения нашей архитектуры с текущими лучшими. Экспериментальная оценка качества, времени работы и затраченной памяти на итоговом бенчмарке.
8. Реализация прототипа реального времени. Разработка демонстрационного скрипта, обрабатывающего поток с веб-камеры и микрофона в реальном времени. Практический пример работы итоговой архитектуры.

Решение данных задач позволит проверить сформулированную гипотезу и создать ресурсоэффективную архитектуру распознавания эмоций с аудиогейтом.

3. Аналитический обзор литературы

3.1. Ранние исследования в области распознавания эмоций

Исследования в области распознавания эмоций берут свое начало в работах по психологии и эффективным вычислениям. Фундаментальной основой для большинства современных систем стали работы Пола Экмана и Уоллеса Фризена, которые в середине 1970-х годов эмпирически обосновали теорию универсальности мимических выражений эмоций. Эта теория говорит о том, что независимо от культурного происхождения и воспитания, люди выражают шесть базовых эмоций сходным образом: счастье, грусть, гнев, страх, удивление и отвращение [17]. Пол Экман и Уоллес Фризен смогли не только определить 6 классов эмоций, но также они предложили детальную систему для классифицирования лицевых выражений (Facial Action Coding System, FACS), которая позволяет описывать мимические изменения через действия лицевых мышц [18]. Эта система до сих пор остается золотым стандартом для аннотирования выражений лиц в компьютерном зрении.

Первые попытки автоматизировать распознавание эмоций опирались на классические методы машинного обучения и ручной подбор признаков. В работе Ioannou и др. 2005 года [19] использовалась neurofuzzy network (нейро-нечеткая сеть) для классификации эмоций по изображениям лиц (Facial Emotion Recognition, FER). На первом этапе детекция лица выполнялась с помощью метода опорных векторов (SVM), затем из выделенной области лица извлекались геометрические признаки (положение бровей, глаз, уголков губ). Полученный вектор признаков подавался на вход neurofuzzy сети, сочетающей преимущества нейронных сетей и нечеткой логики. Эксперименты показали, что такой гибридный подход может превосходить чистые статистические методы, однако

он оставался чувствительным к условиям освещения и поворотам головы, а также требовал тщательной ручной настройки детектора лицевых признаков.

Параллельно с компьютерным зрением развивалась область распознавания эмоций по голосу (Speech Emotion Recognition, SER). Ключевой идеей было выделение просодических и спектральных характеристик речевого сигнала, которые коррелируют с эмоциями говорящего. Наиболее популярным набором признаков стали мел-частотные кепстральные коэффициенты (MFCC), которые компактно представляют спектральную огибающую звука [20]. Кроме MFCC, использовались также следующие признаки: основная частота голоса (F0), энергия, длительность пауз, скорость речи. Классическими классификаторами выступали скрытые марковские модели (Hidden Markov Model, HMM), методы опорных векторов (SVM) и гауссовские смеси (Gaussian Mixture Model, GMM). Однако универсальные системы SER сильно уступали человеку по точности, особенно в условиях фонового шума или при распознавании эмоций незнакомых дикторов.

С развитием Deep Learning (DL) ситуация в обеих областях: FER и SER, кардинально изменилась. Появилась возможность автоматически извлекать иерархические признаки из сырых данных, что устранило необходимость в ручном проектировании признаков. В компьютерном зрении стали доминировать сверточные нейронные сети (CNN), такие как VGG, ResNet и более легкие архитектуры (MobileNet, EfficientNet). В обработке речи – рекуррентные сети (LSTM, GRU) и трансформеры (Wav2Vec 2.0, HuBERT). Однако, проблема распознавания эмоций в реальных сценариях, когда одновременно присутствуют и мимика, и голос, и они могут быть частично избыточны или противоречивы, оставалась открытой. Именно это привело к формированию направления мультимодального распознавания эмоций

(Multimodal Emotion Recognition, MER), в котором информация из двух и более каналов (аудио, видео, текст) объединяется для повышения точности, надежности и устойчивости.

3.2. Методы распознавания эмоций по речевому сигналу (SER)

Задача распознавания эмоций по речи (Speech Emotion Recognition, SER) заключается в автоматическом определении эмоционального состояния говорящего по акустическим характеристикам речевого сигнала. В отличие от задач распознавания речи (ASR), где основное внимание уделяется лингвистическому содержанию, SER ориентирована на паралингвистические компоненты – интонацию, тембр, энергию и паузальную структуру. Исторически SER развивалась в двух параллельных направлениях: 1) методы, основанные на ручном проектировании акустических признаков с последующей классификацией с помощью моделей машинного обучения, и 2) методы глубокого обучения, которые автоматически извлекают иерархические представления из сырого сигнала или его спектрального представления. В данном разделе рассматриваются фундаментальные подходы первой группы, которые, несмотря на появление более сложных нейросетевых архитектур, продолжают использоваться в задачах, критичных к вычислительным ресурсам и интерпретируемости.

3.2.1. Фундаментальные подходы: MFCC, метод опорных векторов (SVM) и лог-мел-спектограммы

Классические методы SER строятся на двухэтапной схеме: извлечение признаков, а затем применение классификатора для определения эмоции по вектору признаков.

Мел-частотные кепстральные коэффициенты (MFCC). Наиболее широко используемым представлением речевого сигнала в задачах SER являются MFCC [20]. Данные коэффициенты моделируют нелинейность слухового восприятия человека путем преобразования частотной шкалы в мел-шкалу:

$$\text{mel}(f) = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right), \text{ где } f - \text{частота в Гц}$$

Процедура вычисления MFCC включает следующие шаги: сегментация сигнала на перекрывающиеся кадры (обычно 25 мс с шагом 10 мс), применение оконной функции (Ханна или Хэмминга), вычисление кратковременного преобразования Фурье (STFT), фильтрация спектра с треугольными мел-фильтрами, логарифмирование энергий фильтров и дискретное косинусное преобразование (DCT). В результате каждого кадра получается вектор из 12-40 коэффициентов, к которым часто добавляют дельта- и дельта-дельта-характеристики. Для представления целого высказывания векторы кадров агрегируются (среднее, стандартное отклонение, асимметрия, эксцесс) либо подаются в классификатор, способный работать с последовательностями.

Лог-мел-спектограммы (Log-Mel Spectrogram). Альтернативным представлением, также широко используемым в SER, является лог-мел-спектограмма. В отличие от MFCC, данный формат сохраняет больше спектральной информации за счет отказа от дискретного косинусного преобразования. Лог-мел-спектограмма представляет собой двумерный массив, где по оси времени отложены кадры, по оси частот – мел-фильтры (обычно от 64 до 128), а значение в каждой ячейке – логарифм энергии соответствующего мел-фильтра. Такое представление может быть подано на вход сверточной

нейронной сети, которая извлекает релевантные признаки. В данной работе для построения лог-мел-спектограмм используется библиотека librosa [22].

Метод опорных векторов (SVM). После извлечения признаков (агрегированных MFCC) требуется классификатор, способный разделить эмоциональные классы в многомерном пространстве. Одним из наиболее эффективных и широко применяемых методов является метод опорных векторов (Support Vector Machine, SVM) [23]. SVM строит разделяющую гиперплоскость, максимизирующую зазор между ближайшими точками разных классов. Для линейно неразделимых данных используется kernel trick: исходное пространство признаков отображается в пространство более высокой размерности с помощью ядерной функции. В задачах SER наиболее часто применяется радиальное базисное ядро (Radial Basis Function, RBF):

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

SVM демонстрирует высокую обобщающую способность на небольших размеченных наборах данных, устойчив к переобучению при правильном подборе гиперпараметров, а также обеспечивает быстрое выполнение на этапе инференса.

3.2.2. Трансформерные энкодеры Wav2Vec 2.0 и DistilHuBERT

Следующим значимым этапом в развитии SER после классических методов стало применение предобученных самонаблюдаемых (Self-Supervised Learning, SSL) моделей. В отличие от традиционных подходов, требующих ручного проектирования признаков, SSL-модели обучаются на больших объемах неразмеченных аудиоданных для извлечения универсальных речевых представлений, которые затем могут быть адаптированы под конкретную задачу

с помощью минимального количества размеченных примеров. Среди таких моделей наибольшее распространение получили Wav2Vec 2.0 и его последующая эффективная версия DistilHuBERT, используемые в данной работе в качестве одного из сравниваемых методов для аудиогейта.

Wav2Vec 2.0 был предложен в 2020 году исследователями из Meta Ai [24]. Архитектура модели включает три основных компонента: многоканальную сверточную сеть (feature encoder), преобразующую сырую звуковую волну в латентные представления; модуль квантизации, дискредитирующий полученные представления; и трансформный контекстуальный кодировщик, который обрабатывает замаскированные латентные представления и извлекает контекстно-зависимые эмбединги. Обучение модели происходит в рамках контрастивной задачи: для каждого замаскированного временного отрезка модель должна идентифицировать соответствующее ему истинное квантизованное представление среди набора дистракторов. Такая схема обучения позволяет Wav2Vec 2.0 эффективно использовать большие объемы неразмеченных аудиоданных и достигать высоких результатов на различных речевых задачах.

Применительно к SER модель Wav2Vec 2.0 может использоваться двумя основными способами. Первый подход – извлечение признаков: замороженная предобученная модель Wav2Vec 2.0 прогоняет входной аудиосигнал и выдает последовательность эмбедингов, которые усредняются по времени и подаются в небольшую обучаемую голову (линейный слой или многослойный перцептрон) для классификации эмоций. Именно этот подход реализован в данной работе с использованием модели *facebook/wav2vec2-base* в качестве экстрактора признаков, поверх которой обучается двухслойный MLP-классификатор для бинарного определения «нейтрально / не нейтрально». Преимуществами такого

подхода являются компактность обучаемой части (всего несколько миллионов параметров вместо 95 млн. у полной модели) и высокая скорость инференса, что критично для задачи данного исследования.

Результаты многочисленных исследований демонстрируют эффективность Wav2Vec 2.0 в задачах SER. В работе, посвященной сравнению SSL-моделей на корпусах IEMOCAP, RAVDESS, EMODB, метод экстракции признаков на основе Wav2Vec 2.0 с последующей классификацией с помощью логистической регрессии достигает среднего значения полноты 87.01% на RAVDESS при кросс-валидации [27]. При этом в большинстве работ отмечается, что даже простая экстракция признаков с последующей линейной классификацией дает результаты, сравнимые с полной тонкой настройкой, при значительно меньших вычислительных затратах, что подтверждает обоснованность подхода, используемого в данном исследовании.

DistilHuBERT представляет собой дистиллированную (уменьшенную) версию модели HuBERT (Hidden-Unit BERT) [25], архитектурно близкой к Wav2Vec 2.0. Основное отличие от первой модели заключается в способе целевой функции: вместо контрастивной потери HuBERT использует кластеризацию латентных представлений для генерации целевых меток и решает задачу предсказания замаскированных фрагментов, аналогично masked language modeling в BERT. DistilHuBERT, в свою очередь, предложен как метод сжатия исходной модели HuBERT путем послойной дистилляции представлений в многофункциональной обучающей схеме [26]. Это позволяет сократить размер модели на 75% (с 95 млн до примерно 24 млн параметров) и ускорить инференс в 3.7 раза при минимальной потере точности на десяти различных задачах распознавания речи.

В контексте SER легкость DistilHuBERT делает его особенно привлекательным для мобильных и встраиваемых приложений. В работе [28] была проведена валидация DistilHuBERT на нескольких стандартных наборах данных (IEMOCAP, CREMA-D). Предложенный подход с 8 битной квантизацией модели (метод уменьшения размера модели) достиг 61.4% невзвешенной точности на IEMOCAP при размере модели всего 23 МБ, что составляет 91% от производительности полноразмерного бейзлайна. При этом добавление CREMA-D в обучающую выборку повысило взвешенную точность на 1.2% и макро F1 метрику на 1.4% [28]. Эти результаты подтверждают, что DistilHuBERT обеспечивает компромисс между точностью и вычислительной эффективностью, который особенно важен в задачах потокового распознавания на устройствах с ограниченными ресурсами.

В рамках данной работы DistilHuBERT сравнивается с другими методами для задачи бинарной классификации «нейтрально / не нейтрально». Модель используется в режиме замороженного экстрактора признаков: предобученная версия *ntu-spml/distilhubert* преобразует входной аудиосигнал в последовательность эмбеддингов, которые затем усредняются по времени и подаются в линейный классификатор. Такой подход позволяет оценить качество представлений, извлеченных дистиллированной моделью, в сравнении с более тяжелыми моделями и традиционными методами, и определить, насколько целесообразно применение DistilHuBERT в роли аудиогейта в каскадной системе распознавания эмоций.

3.2.3. Сверточные нейронные сети на основе спектральных представлений

Трансформерные энкодеры, такие как Wav2Vec 2.0 и DistilHuBERT, обеспечивают высокую точность распознавания эмоций за счет предобучения на огромных корпусах речи, однако их применение в сценариях с жесткими ограничениями по вычислительным ресурсам (мобильные устройства, встраиваемые системы, потоковая обработка) может быть затруднено из-за большого размера модели и требований к аппаратному ускорению. Альтернативой выступают легкие сверточные нейронные сети (Convolutional Neural Networks, CNN), которые могут быть обучены с нуля на размеченных датасетах среднего объема, и демонстрируют компромисс между точностью, скоростью инференса и размером модели, конечно, немного уступая в качестве тяжеловесным трансформерам.

Принципы работы CNN для SER. В отличие от трансформеров, работающих с последовательностями эмбеддингов, CNN принимают на вход двумерное представление сигнала – чаще всего лог-мел-спектрограмму. Как описано в разделе 3.2.1, лог-мел-спектрограмма имеет размерность (n_mels , n_time), где n_mels – число мел-фильтров (обычно 64-128), а n_time – число временных кадров. Сверточные слои с ядрами 3×3 или 5×5 скользят по частоте и времени, извлекая локальные паттерны – например, изменения энергии в определенных частотных диапазонах, переходные процессы, модуляции. Совокупность таких паттернов, пропущенная через последовательность сверточных, пуллинговых и полносвязных слоев, формирует вектор признаков, который затем классифицируется.

Обзор существующих CNN-архитектур для SER. Многочисленные исследования подтверждают эффективность CNN на лог-мел-спектрограммах. В работе [29] на датасете RAVDESS сравнили различные представления (MFCC, лог-мел-спектрограммы, спектрограммы) с 4-слойной CNN. Авторы показали, что наибольшая точность (68% на 14 классах, включая пол и эмоции) достигается именно на лог-мел-спектрограмма, причем выбор признаков оказывает большее влияние на результат, чем глубина сети. В другой работе [30] была предложена компактная CNN из трех сверточных слоев, которая на IEMOCAP достигла точности 65.8% при классификации четырех эмоций (нейтральная, счастье, грусть, гнев).

Более поздние исследования развивают идею легких CNN с использованием современных техник регуляризации. В работе [31] была применена глубокая сеть CNN (четыре сверточных блока) на лог-мел-спектрограммах с размерностью 128x186 (частота x время) и была достигнута точность 86.5% на датасете RAVDESS на 8 эмоциях. Однако такая сеть уже имела около 4 миллионов параметров, что снижало ее преимущество в скорости. Также была разработана специальная сверхлегкая CNN (560 тыс. параметров) для SER на RAVDESS, добившись точности 81.12% на 8 классах эмоций [32]. Авторы показали, что дальнейшее уменьшение числа параметров приводит к падению точности на 15%, но даже такая ультралегкая сеть остается работоспособной для бинарных задач.

3.3. Методы распознавания эмоций по выражению лица (FER)

Распознавание эмоций по выражению лица (Facial Emotion Recognition, FER) является одной из наиболее активно развивающихся областей компьютерного зрения, что обусловлено высокой информативностью мимики

как канала невербальной коммуникации. В отличие от речевого сигнала, который может быть зашумлен или фрагментарен, выражение лица в моменты эмоционального переживания зачастую предоставляет более прямой и однозначный сигнал о текущем состоянии человека. Задача FER включает три основных этапа: детекция лица на изображении или на кадре видео, извлечение признаков из области лица, и классификация эмоции на основе выделенных признаков.

Исторически, ранние системы FER опирались на классические методы машинного обучения. На этапе детекции лица широко применялись каскады Хаара, предложенные в 2001 году [33]. Данный метод использует набор прямоугольных признаков, вычисляемых с помощью интегрального представления изображения, и каскад классификаторов на основе AdaBoost для быстрого отсеивания областей без лица. Несмотря на высокую скорость работы, каскады Хаара демонстрируют низкую точность при поворотах головы, изменении освещения и других окклюзиях. В качестве альтернативы использовался метод HOG (Histogram of Oriented Gradients) в комбинации с линейным SVM, а также MTCNN (Multi-Task Cascaded Convolutional Networks), обеспечивающий более высокую точность за счет трехстадийной каскадной архитектуры.

С развитием глубокого обучения стандарты в области FER кардинально изменились. Сверточные нейронные сети позволили автоматически извлекать иерархические признаки непосредственно из пиксельного представления области лица, исключив необходимость в ручном проектировании геометрических и текстурных дескрипторов. На смену тяжелым архитектурам, таким как VGG, ResNet и Inception, пришли легкие модели, оптимизированные для работы на мобильных и встраиваемых устройствах (MobileNet, EfficientNet,

ShuffleNet). Параллельно с этим значительный прогресс был достигнут в области детекции лиц, где появились высокоточные и быстрые решения, способные работать в реальном времени.

3.3.1. Детекция лиц MediaPipe BlazeFace

Первый и обязательный этап любой системы распознавания эмоций по выражению лиц – локализация области лица в кадре. Точность детекции напрямую влияет на последующее извлечение признаков и итоговую классификацию: ошибка определения лица приводит к потере релевантной мимической информации или включению в анализ фоновых областей. В задачах реального времени, где каждый кадр должен быть обработан за миллисекунды, к детектору предъявляются дополнительные требования по скорости работы и компактности модели.

Media Pipe BlazeFace – легкий детектор лиц, разработанный командой Google для работы на мобильных GPU [34]. Архитектура модели основана на Single Shot Detector (SSD) с бэкбоном MobileNetV2; ключевым решением является использование глубоких разделимых сверток, что позволяет сократить число параметров до 2.7 млн. Модель предсказывает ограничивающие рамки и шесть ключевых точек лица, доступна в двух вариантах: *short_range* и *full_range*. Производительность BlazeFace на мобильных GPU превышает 200 кадров в секунду, на CPU – не менее 30 кадров в секунду. Размер INT8 версии – несколько сотен килобайт.

Альтернативные детекторы:

- Каскады Хаара [33] и HOG + SVM [35] проигрывают по точности BlazeFace при поворотах головы и окклюзиях;

- MTCNN [36] существенно медленнее и не подходит для мобильных устройств;
- RetinaFace [37] точен, но слишком тяжелый для нашей задачи
- YOLOv8 Nano [38] и MobileNet SSD [39] не предсказывают ключевые точки лица и имеют большой размер модели.

Таким образом, Media Pipe BlazeFace обеспечивает наилучший баланс скорости, точности и компактности для потоковой системы.

3.3.2. Легкие бэкбоны для видеок кадров: MobileNetV3-Small и EmotiEffNet

После определения границ области лица на вход системы подается кроп лица, из которого необходимо извлечь пространственные признаки, релевантные для распознавания эмоций. В современных FER системах эту роль выполняют сверточные нейронные сети, выступающие в качестве бэкбона – модели, преобразующей изображение лица в вектор числовых признаков. В данной работе сравниваются два подхода: MobileNetV3-Small – универсальная легковесная архитектура, оптимизированная для мобильных устройств, и EmotiEffNet – специализированная модель, предобученная на крупном датасете AffectNet для задачи распознавания эмоций.

MobileNetV3-Small – третье поколение семейства MobileNet, разработанное Google с использованием комбинации методов аппаратного осознанного поиска архитектуры (NetAdapt) и дополнительных улучшений, таких как squeeze-and-excitation модули и новая нелинейная функция активации hard-swish [40]. Модель имеет 1.3 млн параметров и характеризуется вычислительной сложностью 0.19 GMac (Giga Multiply-Accumulate operations), что делает ее в несколько раз легче и быстрее предшественников. За счет использования глубоких разделимых сверток и инвертированных линейных

бутылочных слоев MobileNetV3-Small обеспечивает высокую эффективность инференса на устройствах с ограниченными ресурсами.

В задачах FER MobileNetV3-Small демонстрирует конкурентоспособные результаты. В работе [41] модифицированная версия MobileNetV3 достигла точности 87.5% на датасете FERPlus и 86.6% на RAF-DB, при этом размер модели составил всего 15.9 МБ. Наибольшее преимущество модели проявляется на устройствах с ограниченными ресурсами, где она одновременно обеспечивает и высокую скорость, и приемлимую точность. Для сравнения: MobileNetV3-Large имеет порядка 5.4 млн. параметров (в MobileNetV3-Small – 2.9 млн. параметров), при этом выигрыш в точности составляет лишь 3-4 процентных пункта при существенно большем объеме вычислений.

EmotiEffNet представляет собой семейство предобученных сверточных сетей на базе EfficientNet-B0, специально настроенных для решения задач распознавания эмоций. Эффективность EmotiEffNet достигается за счет двухэтапной стратегии предобучения: сеть сначала обучается на крупном датасете VGGFace2 для задачи определения лица, а затем дообучается на AffectNet с фокусом на эмоциональные категории. Такая схема позволяет модели наследовать способность различать тонкие лицевые особенности от VGGFace2, а затем адаптировать эти знания к пространству эмоций. В работе А.В. Савченко [42], представлено семейство EmotiEffNets, предназначенных для распознавания выражений лица, предсказания валентности и возбуждения, а также детекции лицевых действий. Эти модели показали эффективность на международных соревнованиях, в частности соревнования ABAW (Affective & Behavior Analysis in-the-wild).

3.3.3. Темпоральные агрегаторы для последовательности кадров: BiGRU, BiLSTM, TCN

Извлечение пространственных признаков из отдельных кадров (с помощью бэкбонов, рассмотренных в прошлом параграфе) дает статическое представление мимики. Однако эмоциональное состояние человека разворачивается во времени: удивление может смениться на радость, грусть – нейтральным состоянием, а интенсивность эмоции может нарастать или затухать на протяжении высказывания. Учет этих временных зависимостей требует агрегации пространственных признаков по некоторой последовательности кадров, что достигается с помощью темпоральных агрегаторов. Рассмотрим два класса темпоральных агрегаторов: двунаправленные рекуррентные сети и временные сверточные сети. Выбор этих архитектур обусловлен их различными компромиссами между учетом контекста, параллелизуемостью и вычислительной эффективностью.

Двунаправленные рекуррентные сети (BiLSTM и BiGRU). Базовыми рекуррентными архитектурами для последовательных данных являются долгая краткосрочная память (LSTM) и управляемый рекуррентный блок (GRU) [43] [44] [45]. Оба подхода решают проблему затухающих градиентов стандартных RNN за счет вентильных механизмов, регулирующих поток информации. Однако в задаче распознавания эмоций текущая мимика зависит не только от предыдущих кадров, но и от последующих – человек может проявлять эмоцию, затем возвращаться к нейтральному состоянию, и этот возврат важен для контекста. **Двунаправленные версии (BiLSTM, BiGRU)** обрабатывают последовательность в обоих направлениях: прямой слой захватывает зависимости от прошлого к будущему, обратный – от будущего к прошлому, а

финальное представление формируется конкатенацией скрытых состояний обоих слоев.

3.4. Мультимодальное распознавание эмоций (MER)

3.4.1. Классические стратегии слияния анализа модальностей

3.4.2. Современные мультимодальные архитектуры для IEMOCAP: SCME+GF и MM-NodeFormer

Ранние исследования были сфокусированы на одномодальных подходах (определение эмоций только по речи / только по выражению лица).

Первый вид: Speech emotion recognition (SER) [7] заключается в выделении признаков из речи человека, с помощью, например лог-мел спектограмм или мел-частотных коэффициентов (MFCC) и использование классификационных моделей, чтобы определить и выучить общие паттерны эмоций.

Второй вид: Facial expression emotion recognition (FER) [8] состоит в использовании техник компьютерного зрения (CV), для отслеживания изменений мышц лица. В фундаментальной работе Ekman и Friesen [9] все

мышцы лица были разделены на три основные группы, наиболее важные для задачи FER: брови и лоб, глаза и веки, а также нижняя часть лица.

Однако, одномодальные системы ограничены по двум параметрам: количеству информации, которую можно получить из одной модальности и подверженности влиянию окружающих факторов (шум, недостаток света и т.д.). Это приводит к следующему этапу развития систем классификации эмоций: мультимодальные системы.

Мультимодальные системы определения эмоций (MER) [10] являются объединением систем SER, FER, а также не описанной ранее системы определения эмоций по тексту (расшифровке речи человека) для более надежной и качественной классификации. Один из примеров MER архитектуры, основанный на графовых нейросетях [11] показал, что данный подход способен показывать высокие метрики качества, однако требует большого количества вычислительных ресурсов. Именно в этом и заключается основная проблема использования MER систем в приложениях, которые обрабатывают данные в реальном времени.

3.5. Обзор существующих алгоритмов распознавания эмоций

Задача классификации выражений лиц с детектированием эмоций в речи подразумевает определение эмоции по двум модальностям: голосу и выражению лица человека. Рассмотрим уже существующие подходы по данным темам.

4. Обзор датасетов для задачи мультимодальной классификации эмоций

Для обучения моделей, а также для корректной валидации результатов необходимо подобрать датасеты. Наша архитектура подразумевает использование датасетов для двух задач: классификация нейтральности по речи, и определение эмоции по выражению лица.

Для более качественного, эффективного и сбалансированного обучения мы будем комбинировать датасеты при обучении, то есть использовать сразу несколько для обучения каждой модели. Это позволит модели обучиться на различных данных, не зависящих от конкретного языка датасета, национальности авторов или других уникальных признаков датасета.

Важно также различать датасеты, которые мы будем использовать для предобучения наших моделей и датасеты, на которых будем измерять качество, так как если для обеих целей использовать одни и те же датасеты, то в результаты мы получим завышенные результаты из-за “утечки таргета” (Target leakage).

В данной работе для построения эффективной мультимодальной системы распознавания эмоций были использованы три датасета: RAVDESS, CREMA-D и IEMOCAP. Первые два использовались для предварительного обучения аудио и видео моделей, а IEMOCAP - в качестве целевого датасета для тонкой настройки и финального замера качества архитектуры. Данные три датасета были выбраны, так как они широко используются в работах по классификации эмоций, содержат чистые аудио и хорошо различимые видео данные, а также содержат сразу обе модальности.

4.1. RAVDESS (Ryerson Audio-Visual Database of Emotional Speech and Song)

Первый датасет, который я использовал - **RAVDESS** [2]. В нем содержатся студийные записи разговоров актеров. Всего: 7356 аудиовизуальных записей, записанных 24 профессиональными актерами, как мужчинами, так и женщинами. Все фрагменты записаны с высокой частотой дискретизации (48 кГц). Язык датасета - английский.

Датасет содержит 8 классов эмоций: нейтральная, спокойная, радость, грусть, страх, гнев, отвращение и удивление. А также 5 категорий для вокального исполнения, которые не использовались в данной работе. Каждая запись маркируется уровнем интенсивности эмоции: нормальный или высокий. Каждое видео содержит ровно одну эмоцию.

Для нашего исследования использовались только речевые аудио и видео фрагменты (пение не использовалось). Аудиодорожки были приведены к моноформату с частотой 16 кГц - для большей универсальности и применимости модели к другим датасетам с частотой 16 кГц, а также для повышения производительности модели.

RAVDESS был выбран в качестве основного датасета для предобучения видео модели, поскольку содержит хорошо размеченные, синхронизированные аудио и видеозаписи с хорошо видимыми выражениями лиц.

4.2. CREMA-D (Crowd-sourced Emotional Multimodal Actors Dataset)

CREMA-D [3] содержит 7442 видео, записанных 48 мужчинами и 43 женщинами. В отличие от RAVDESS это добровольцы, а не профессиональные

актеры, из-за чего эмоции менее наигранные. Также среди участников были различные этнические и возрастные группы.

Использование датасета CREMA-D в дополнение к RAVDESS обеспечивает большее разнообразие лицевых особенностей и обучение на более естественных эмоциях. Каждый клип также содержит произнесение одной фразы с одной из шести эмоциональных окрасок: нейтральная, радость, грусть, гнев, страх, отвращение. Как можно заметить, эмоции совпадают с первым датасетом, за исключением двух отсутствующих: спокойная и удивленная - некоторый дисбаланс классов важно будет учитывать при обучении.

Запись датасета также велась в студийных условиях с частотой дискретизации 16 кГц для аудио и разрешением видео 640x480 пикселей.

CREMA-D использовался совместно с RAVDESS для предварительного обучения аудио классификатора. Объединение данных привело к повышению обобщающей способности аудиогейта перед итоговым замером качества на IEMOCAP.

4.3. IEMOCAP (Interactive emotional dyadic motion capture database)

IEMOCAP [4] считается одним из фундаментальных наборов данных для классификации эмоций в диалоговой речи. В нем содержатся около 12 часов аудиовизуальных записей разговоров между 10 актерами (5 мужчин и 5 женщин), разбитых на 5 сессий. Каждая такая сессия включает в себя диалог по заранее написанному сценарию, а также спонтанные импровизации на определенную тему. Категории эмоций проставлены для отдельных высказываний – каждому такому фрагменту соответствует одна эмоция (гнев,

радость, грусть, нейтральность, волнение, усталость, восхищение, страх и «другая» эмоция).

Существует принципиальное отличие от RAVDESS и CREMA-D – в данном датасете спонтанный, диалоговый характер речи и мимики, более приближенный к реальному общению людей. Эмоции здесь менее утрированы, часто появляются между состояниями в пределах одного высказывания. Кроме того, видео содержат естественные окклюзии, различные варианты освещения и повороты головы, характерные для реальных условий общения. Из-за этого IEMOCAP более сложный датасет для нашей задачи, но одновременно с этим является более репрезентативным бенчмарком для оценки качества мультимодальных систем распознавания эмоций.

В данном исследовании IEMOCAP выступает в качестве целевого датасета. Модели, предварительно обученные на RAVDESS и CREMA-D, дообучаются на сессиях 1-4 с валидацией на сессии 5. Модели классифицируют аудио и видео по 8 классам эмоций. «Другая» эмоция была исключена из датасета из-за крайне малого количества примеров, а также отсутствия в датасетах предобучения.

4.4. Стратегия использования датасетов для обучения

RAVDESS и CREMA-D являются «лабораторными» датасетами с качественными записями и хорошо выраженными эмоциями, тогда как IEMOCAP представляет собой существенно более сложный и реалистичный набор данных. Такой контраст создает серьезный доменный сдвиг между предобучением и целевой задачей. Данная проблема решается применением аугментаций как к видео: уменьшение яркости, обрезание видео, так и к аудио: уменьшение громкости, добавление помех.

Многочисленные исследования демонстрируют, что предварительное обучение на крупных датасетах актерской речи с последующей тонкой настройкой на IEMOCAP позволяет получить достаточно хорошие веса моделей, релевантные для задачи классификации нейтральных и эмоциональных состояний, а также сократить объем данных, необходимых для адаптации к спонтанной речи [4], [5].

Именно поэтому в нашем пайплайне компоненты обучаются в два этапа: сначала аудио-модель (классификатор нейтральная или не нейтральная речь) обучается на RAVDESS + CREMA-D с аугментациями, а видео-модель – на видеофрагментах RAVDESS, опять же с аугментациями; затем полученные веса загружаются, и вся итоговая архитектура дообучается на IEMOCAP с замороженным визуальным энкодером.

Таким образом, выбранный набор датасетов и стратегия обучения позволяют:

- Использовать высококачественные наборы данных для формирования базового представления моделей
- А также адаптировать модель к сложным, естественным условиям диалогового взаимодействия.

5. Методология предлагаемой системы

6. Экспериментальная оценка и результаты

7. Заключение

1. Заключение

Результатами данной курсовой работы стали:

- Подробное изучение существующих подходов к рендерингу изображений, как они устроены изнутри, а также методы их оптимизации и дальнейшего развития;
- Была написана собственная программа для рендеринга изображений на C++ с нуля, с возможностью дополнять ее новыми функциями, а также продолжать работать над ней, как над серьезным проектом;
- Было проведено исследование и поиск алгоритмов для генерации случайных чисел, которые могли бы поспособствовать уменьшению времени рендеринга изображений в хорошем качестве;
- Были выбраны и реализованы на языке C++ 4 метода генерации случайных чисел: Halton Sampler, Halton RandomDigit Sampler, Halton Owen Sampler, Blue Noise Sampler. Они были добавлены в программу рендеринга изображений и с их помощью были срендерены изображения, необходимые для сравнения;
- Было проведено сравнение и анализ написанных методов генерации случайных чисел с использованием современных метрик, использующихся в настоящих проектах по 3D графике;
- Были выделены алгоритмы, которые показывают наилучшие результаты за наименьшее время: Blue Noise Sampler, Halton RandomDigit Sampler.

Все материалы и результаты, которые были получены в ходе данной курсовой работы имеют большой практический смысл и потенциал. На примере

простой программы для рендеринга было показано, что с помощью изменения подхода к генерации случайных чисел в алгоритме рендеринга могут быть получены хорошие результаты за меньшее время. Все результаты могут быть полезны для всех, кто занимается рендерингом изображений и графикой, так как способны значительно ускорить рендеринг изображений хорошего качества.

А также знания и навыки, которые лично я получил в ходе написания данной курсовой работы оказались очень полезными, а их уровень близок к современному уровню развития графических приложений и алгоритмов рендеринга. Проект, который был написан в ходе данной курсовой работы, однозначно продолжит развиваться и расширяться.

Git-репозиторий курсовой работы и проекта доступен по ссылке:

<https://github.com/Kaparya/PathTracing>

2. Библиографический список

1. Burkhardt, Felix & Paeschke, Astrid & Rolfes, M. & Sendlmeier, Walter & Weiss, Benjamin. (2005). A database of German emotional speech. 9th European Conference on Speech Communication and Technology. 5. 1517-1520. 10.21437/Interspeech.2005-446.
2. Livingstone SR, Russo FA. The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in North American English. PLoS One. 2018 May 16;13(5):e0196391. doi: 10.1371/journal.pone.0196391. PMID: 29768426; PMCID: PMC5955500.
3. Cao H, Cooper DG, Keutmann MK, Gur RC, Nenkova A, Verma R. CREMA-D: Crowd-sourced Emotional Multimodal Actors Dataset. IEEE Trans Affect Comput. 2014 Oct-Dec;5(4):377-390. doi: 10.1109/TAFFC.2014.2336244. PMID: 25653738; PMCID: PMC4313618.
4. C. Busso, M. Bulut, C. Lee, A. Kazemzadeh, E. Mower, S. Kim, J. Chang, S. Lee, and S. Narayanan, "IEMOCAP: Interactive emotional dyadic motion capture database," Journal of Language Resources and Evaluation, vol. 42, no. 4, pp. 335-359, December 2008
5. Latif, Siddique & Rana, Rajib & Younis, Shahzad & Qadir, Junaid & Epps, Julien. (2018). Cross Corpus Speech Emotion Classification - An Effective Transfer Learning Technique. 10.48550/arXiv.1801.06353.
6. Fu H, Zhuang Z, Wang Y, Huang C, Duan W. Cross-Corpus Speech Emotion Recognition Based on Multi-Task Learning and Subdomain Adaptation. Entropy (Basel). 2023 Jan 7;25(1):124. doi: 10.3390/e25010124. PMID: 36673265; PMCID: PMC9858266.

7. Khalil, R. A., & Jones, E., & Babar, M., & Jan, T., & Zafar, M., & Alhussain, T. (2019). Speech Emotion Recognition Using Deep Learning Techniques: A Review. IEEE Access. PP. 1-1. 10.1109/ACCESS.2019.2936124.
8. Huang, Z., & Chiang, C., & Chen, J., & Chen, Yi-Chian & Chung, H., & Cai, Y., & Hsu, H. (2023). A study on computer vision for facial emotion recognition. Scientific Reports. 13. 10.1038/s41598-023-35446-4.
9. Ekman, P., & Friesen, W. V. (1975). Unmasking the Face: A guide to recognizing emotions from facial clues. Englewood Cliffs, NJ: Prentice-Hall.
10. Zhang, S., & Yang, Y., & Chen, C., & Zhang, X., & Leng, Q., & Zhao, X. (2024). Deep Learning-based Multimodal Emotion Recognition from Audio, Visual, and Text Modalities: A Systematic Review of Recent Advancements and Future Prospects. Expert Systems with Applications. 237. 121692.10.1016/j.eswa.2023.121692.
11. Hu, D., & Hou, X., & Wei, L., & Jiang, L., & Mo, Y. (2022). MM-DFN: Multimodal Dynamic Fusion Network for Emotion Recognition in Conversations. 7037-7041. 10.1109/ICASSP43922.2022.9747397.
12. Nhut Minh Nguyen, Thanh Trung Nguyen, Phuong-Nam Tran, Chee Peng Lim, Nhat Truong Pham, Duc Ngoc Minh Dang, Multimodal fusion in speech emotion recognition: A comprehensive review of methods and technologies, Engineering Applications of Artificial Intelligence, Volume 163, Part 1, 2026, 112624, ISSN 0952-1976, <https://doi.org/10.1016/j.engappai.2025.112624>.
13. Savchenko, A.V., Savchenko, L.V. Audio-Visual Continuous Recognition of Emotional State in a Multi-User System Based on Personalized Representation of Facial Expressions and Voice. Pattern Recognit. Image Anal. 32, 665–671 (2022). <https://doi.org/10.1134/S1054661822030397>
14. Yang X, Lan Z, Wang N, Li J, Wang Y, Meng Y. LiteFer: An Approach Based on MobileViT Expression Recognition. Sensors (Basel). 2024 Sep 37

- 10;24(18):5868. doi: 10.3390/s24185868. PMID: 39338612; PMCID: PMC11435806.
15. Musheng Chen, Qiang Wen, Xiaohong Qiu, Junhua Wu, Wenqing Fu, MDGET-MER: Multi-Level Dynamic Gating and Emotion Transfer for Multi-Modal Emotion Recognition, *Computers, Materials and Continua*, Volume 86, Issue 3, 2026, ISSN 1546-2218, <https://doi.org/10.32604/cmc.2025.071207>.
 16. Mengara Mengara, A. G., & Moon, Y.-k. (2025). CAG-MoE: Multimodal Emotion Recognition with Cross-Attention Gated Mixture of Experts. *Mathematics*, 13(12), 1907. <https://doi.org/10.3390/math13121907>.
 17. Ekman, P., & Friesen, W. V. (1975). *Unmasking the Face: A guide to recognizing emotions from facial clues*. Englewood Cliffs, NJ: Prentice-Hall.
 18. Ekman, P. and Friesen, W.V. (1978) *Facial Action Coding System: A Technique for the Measurement of Facial Movement*. Consulting Psychologists Press, Palo Alto, CA. <https://doi.org/10.1037/t27734-000>.
 19. Ioannou, S., & Raouzaïou, A., & Tzouvaras, V., & Mailis, T., & Karpouzis, K., & Kollias, S. (2005). Emotion recognition through facial expression analysis based on a neurofuzzy network. *Neural Networks*. 18. 423-435.
 20. Abdul, Z., & Al-Talabani, A.. (2022). Mel Frequency Cepstral Coefficient and its Applications: A Review. *IEEE Access*. PP. 1-1. 10.1109/ACCESS.2022.3223444.
 21. Eyben, F., & Wöllmer, M., & Schuller, B. (2010). openSMILE -- The Munich Versatile and Fast Open-Source Audio Feature Extractor. *MM'10 - Proceedings of the ACM Multimedia 2010 International Conference*. 1459-1462. 10.1145/1873951.1874246.
 22. McFee, B., Raffel, C., Liang, D., Ellis, D. P., McVicar, M., Battenberg, E., & Nieto, O. (2015). *librosa: Audio and music signal analysis in Python*. In

- Proceedings of the 14th Python in Science Conference (SciPy 2015) (pp. 18–25). <https://doi.org/10.25080/Majora-7b98e3ed-003>.
23. Hearst, M. A., Dumais, S. T., Osuna, E., Platt, J., & Scholkopf, B. (1998). Support vector machines. *IEEE Intelligent Systems and Their Applications*, 13(4), 18–28. <https://doi.org/10.1109/5254.708428>.
24. Baeovski, A., Zhou, H., Mohamed, A., & Auli, M. (2020). wav2vec 2.0: A framework for self-supervised learning of speech representations. *Advances in Neural Information Processing Systems*, 33, 12449–12460. <https://arxiv.org/abs/2006.11477>.
25. Wei-Ning Hsu, Benjamin Bolte, Yao-Hung Hubert Tsai, Kushal Lakhotia, Ruslan Salakhutdinov, and Abdelrahman Mohamed. 2021. HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units. *IEEE/ACM Trans. Audio, Speech and Lang. Proc.* 29 (2021), 3451–3460. <https://doi.org/10.1109/TASLP.2021.3122291>.
26. Chang, Heng-Jui & Yang, Shu-Wen & Lee, Hung-yi. (2021). DistilHuBERT: Speech Representation Learning by Layer-wise Distillation of Hidden-unit BERT. 10.48550/arXiv.2110.01900.
27. Gavali, M. P., & Verma, A. (2026). A novel fusion framework of SSL models and acoustic features for robust speech emotion recognition across languages. *Multimedia Tools and Applications*, 85, Article 352. <https://doi.org/10.1007/s11042-026-21508-y>.
28. Ismail, S. M. (2025). Mobile-efficient speech emotion recognition using DistilHuBERT: A cross-corpus validation study. arXiv preprint, arXiv:2512.23435. <https://arxiv.org/abs/2512.23435>.
29. Venkataramanan, K., & Rajamohan, H. R. (2019). Emotion recognition from speech. arXiv preprint, arXiv:1912.10458. <https://arxiv.org/abs/1912.10458>.

30. Satt, A., Rozenberg, S., & Hoory, R. (2017). Efficient emotion recognition from speech using deep learning on spectrograms. In Proceedings of Interspeech 2017 (pp. 1081–1085). ISCA. <https://doi.org/10.21437/Interspeech.2017-30>.
31. Mao, Q., Dong, M., Huang, Z., & Zhan, Y. (2019). Learning salient features for speech emotion recognition using convolutional neural networks. IEEE Transactions on Multimedia, 16(8), 2203–2213. <https://doi.org/10.1109/TMM.2014.2360798>.
32. Boonkla, S., et al. (2019). A light-weight deep convolutional neural network for speech emotion recognition using mel-spectrograms. In *2019 14th International Joint Symposium on Artificial Intelligence and Natural Language Processing (iSAI-NLP)* (pp. 1–4). IEEE. <https://doi.org/10.1109/iSAI-NLP48611.2019.9045511>.
33. Viola, P., & Jones, M. (2001). Rapid object detection using a boosted cascade of simple features. Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR 2001), 1, I–I. <https://doi.org/10.1109/CVPR.2001.990517>.
34. Bazarevsky, Valentin & Kartynnik, Yury & Vakunov, Andrey & Raveendran, Karthik & Grundmann, Matthias. (2019). BlazeFace: Sub-millisecond Neural Face Detection on Mobile GPUs. 10.48550/arXiv.1907.05047.
35. N. Dalal and B. Triggs, "Histograms of oriented gradients for human detection," 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05), San Diego, CA, USA, 2005, pp. 886-893 vol. 1, doi: 10.1109/CVPR.2005.177.
36. K. Zhang, Z. Zhang, Z. Li and Y. Qiao, "Joint Face Detection and Alignment Using Multitask Cascaded Convolutional Networks," in IEEE Signal Processing Letters, vol. 23, no. 10, pp. 1499-1503, Oct. 2016, doi: 10.1109/LSP.2016.2603342.

37. Deng, Jiankang & Guo, Jia & Zhou, Yuxiang & Yu, Jinke & Kotsia, Irene & Zafeiriou, Stefanos. (2019). RetinaFace: Single-stage Dense Face Localisation in the Wild. 10.48550/arXiv.1905.00641.
38. Jocher, G., Chaurasia, A., & Qiu, J. (2023). Ultralytics YOLOv8 (Version 8.0.0) [Computer software]. <https://github.com/ultralytics/ultralytics>
39. Liu, Wei & Erhan, Dumitru & Szegedy, Christian & Reed, Scott & Fu, Cheng-Yang & Berg, Alexander. (2016). SSD: Single Shot MultiBox Detector. 9905. 21-37. 10.1007/978-3-319-46448-0_2.
40. A. Howard et al., "Searching for MobileNetV3," 2019 IEEE/CVF International Conference on Computer Vision (ICCV), Seoul, Korea (South), 2019, pp. 1314-1324, doi: 10.1109/ICCV.2019.00140.
41. Wang, F., Li, X., & Zhang, Y. (2023). A lightweight method for face expression recognition based on improved MobileNetV3. IET Image Processing. <https://doi.org/10.1049/ipr2.12860>
42. A. V. Savchenko, "EmotiEffNets for Facial Processing in Video-based Valence-Arousal Prediction, Expression Classification and Action Unit Detection," 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Vancouver, BC, Canada, 2023, pp. 5716-5724, doi: 10.1109/CVPRW59228.2023.00606.
43. Graves, Alex & Schmidhuber, Jürgen. (2005). Framewise phoneme classification with bidirectional LSTM and other neural network architectures. Neural networks: the official journal of the International Neural Network Society. 18. 602-10. 10.1016/j.neunet.2005.06.042.
44. Cho, Kyunghyun & Merrienboer, Bart & Bahdanau, Dzmitry & Schwenk, Holger & Gulcehre, Caglar & Bougares, Fethi. (2014). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. 10.3115/v1/D14-1179.

45. Chung, Junyoung & Gulcehre, Caglar & Cho, KyungHyun. (2014). Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling.
- 46.