



Факультет информатики, математики и
компьютерных наук

Программная Инженерия

Нижний Новгород
2026

Классификация выражений лиц с детектированием эмоций в речи

Научный руководитель:

к.т.н., доцент, кафедра информационных систем
и технологий НИУ ВШЭ – Нижний Новгород
Савченко Людмила Васильевна


Рецензент:

приглашенный преподаватель базовой кафедры
группы компаний «MERA»
Лемайкина Елена Александровна


Выполнил студент группы 22ПИ-1:
Канделов Дамир Русланович

Эмоции в человеко-машинном взаимодействии

Понимание эмоционального состояния человека позволяет компьютерным системам получать больше информации о состоянии человека, а также отвечать более естественным образом. Это может быть полезно в:



Виртуальные ассистенты



Мониторинг обслуживания
клиентов



Контроль состояния
водителя

Актуальность

Текущие архитектуры для распознавания эмоций тяжелые, ресурсозатратные или имеют низкие метрики качества, что приводит к высокой стоимости использования таких систем. В данной работе я представляю новую, более эффективную и менее ресурсозатратную *каскадную* архитектуру.

- Практическая потребность
- Отсутствие в литературе каскадных MER систем с аудиогейтом
- Необходимость в прозрачной методологии оценки качества
- Возможность значительного сокращения вычислительных затрат без потери качества



Цель работы

Разработка и экспериментальная оценка двухстадийной мультимодальной системы распознавания эмоций, снижающей вычислительные затраты без значимой потери точности классификации.

Задачи

1. Анализ подходов к распознаванию эмоций по речи (SER), выражениям лиц (FER) и по обеим модальностям (MER)
2. Поиск возможностей оптимизации за счёт последовательной обработки аудио и видео
3. Подготовка данных: анализ, выбор и предобработка датасетов
4. Разработка аудиогейта и сравнение подходов по качеству, скорости и весу моделей
5. Построение видео-классификатора: выбор экстрактора признаков и модели-классификатора.
6. Сборка двухстадийного пайплайна: объединение аудиогейта и классификатора по аудио и видео в одну архитектуру
7. Бенчмарк для сравнения нашей архитектуры по: качеству, времени и памяти против лучших современных моделей
8. Реализация прототипа реального времени (веб-камера и микрофон)



Аналитический обзор литературы

Эволюция подходов к распознаванию эмоций



Вывод: точные мультимодальные модели вычислительно тяжелы — отсюда потребность в лёгких, каскадных решениях для устройств с ограниченными ресурсами.



Исследование предметной области

Виды определения эмоций по различным модальностям

Speech Emotion Recognition (SER)

Определение эмоций по речи

- Классика: MFCC + SVM, лог-мел спектрограммы
- Трансформеры: Wav2Vec 2.0, DistilHuBERT
- CNN на спектральных представлениях

Facial expression Emotion Recognition (FER)

Определение эмоций по выражению лиц

- Детекция лиц: MediaPipe BlazeFace
- Лёгкие бэкбоны: MobileNetV3, EmotiEffNet
- Темпоральные агрегаторы: BiGRU, BiLSTM, TCN

Multimodal Emotion Recognition (MER)

Определение эмоций по двум и более модальностям

- Стратегии слияния модальностей (early / late / hybrid)
- Современные архитектуры для IEMOCAP
- Тренд: лёгкие и динамические модели



Датасеты и аугментация

Используемые датасеты

1. Ryerson Audio-Visual Database of Emotional Speech and Song (**RAVDESS**)

- 1440 аудиовизуальных записей
- 24 профессиональных актера
- 8 эмоций
- Источник для видео-модели и гейта

2. Crowd-sourced Emotional Multimodal Actors Dataset (**CREMA-D**)

- 7442 видео
- 91 актёр, 48 мужчин и 43 женщины, добровольцы
- 6 эмоций
- Расширяет аудио-данные для гейта

3. Interactive emotional dyadic motion capture database (**IEMOCAP**)

- 12 часов записанных диалогов (5 сессий)
- Спонтанные импровизации, а также диалоги по заранее написанному сценарию
- 10 актеров: 5 мужчин и 5 женщин
- 4 класса: neutral, happy, sad, angry

Офлайн-аугментации

Аудио:


- **AddGaussianSNR** — гауссовский шум, SNR 5–25 дБ
- **Shift** — временной сдвиг ± 1 с
- **Gain** — громкость $-9...+6$ дБ
- **TimeStretch** — растяжение/сжатие $\times 0,9-1,1$
- **PitchShift** — сдвиг тона ± 2 полутона

Видео:

- **RandomResizedCrop** — случайная обрезка, масштаб 0,85–1,0
- **HFlip** — зеркальное отражение
- **ColorJitter** — яркость / контраст / насыщенность
- **GaussianBlur** — размытие по Гауссу
- **RandomErasing** — случайное стирание (cutout)

Общая архитектура предлагаемого решения

- Двухстадийная каскадная архитектура с ранним решением об активации видео ветви
- Лёгкий бинарный классификатор на входе фильтрует нейтральную речь
- Обработка видео и бимодальный классификатор запускаются только для эмоциональной речи
- Возврат метки «нейтрально» без запуска детектора лиц и видео-ветви






Предлагаемая архитектура



Выбор аудиогейта

Сравнивались 4 бинарных аудио классификатора «нейтрально / не нейтрально».

- **MeiCNN** — лог-мел спектограмма + сверточная нейронная сеть; лучший баланс, самый лёгкий (8 МБ) и быстрый (3,4 мс)
- **DistilHuBERT + Linear** — замороженный SSL-энкодер; самое высокое качество (0,904), но 90 МБ
- **Wav2Vec 2.0 + MLP** — замороженный wav2vec2; низкий recall (0,51), 360 МБ, медленный
- **MFCC + SVM** — классический бейзлайн; заметно слабее, низкие метрики качества



Метрики сравнения аудио моделей (RAVDESS + CREMA-D)

Выбран **MeiCNN** — лучший баланс качества и стоимости (0,827 асс / 0,734 F1; 3,4 мс; 8,1 МБ).

Выбор видео-модели




Сравнивались 6 конфигураций «бэкбон × агрегатор» на RAVDESS. Выбран **EmotiEffNet + BiLSTM** (0,683 acc / 0,671 F1).

Бэкбоны (извлечение признаков лица)

- **EmotiEffNet** — EfficientNet-B0, дообучен на AffectNet; точнее всех
- **MobileNetV3-Small** — лёгкий мобильный бэкбон; заметно слабее


Модели классификаторы эмоций (16 кадров)

- **BiLSTM** — двунаправленный LSTM; выбран в каскад
- **BiGRU** — облегчённый аналог; качество сопоставимо
- **TCN** — временные свёртки; ниже по качеству



Метрики сравнения видео моделей (RAVDESS)

Итоговая архитектура системы




Архитектура предлагаемой системы

MelCNN-гейт отсеивает нейтральные реплики; при эмоциональной речи активируется бимодальная голова BiLSTMBimodal. Лог-мел спектрограмма переиспользуется гейтом и аудио-веткой.

Бимодальная голова

Аудио- и видео-признаки извлекаются отдельно, конкатенируются в общий вектор и подаются в линейный классификатор на 4 класса. Аудио-ветка повторяет MelCNN, видео-ветка — EmotiEffNet + BiLSTM.




BiLSTMBimodal



Матрицы ошибок на IEMOCAP

Наша модель уверенно распознаёт neutral (0,71) и angry (0,62); основная ошибка — путаница happy ↔ angry (excited объединён с happy). Трансформерные конкуренты лучше на happy, но слабее на neutral.




Матрица ошибок нашей архитектуры (IEMOCAP)



Эффективность и итоговое сравнение

Предложенная модель достигает следующих метрик качества: UAR 0,509 и Macro-F1 0,494 при размере всего 37,3 МБ и времени 216 мс. Конкуренты на Wav2Vec2 — ~379 МБ и ~610 мс при более низком качестве.

ИЕМОСАР benchmark — сводное сравнение (E2E)



Результаты бенчмарка на датасете ИЕМОСАР



Прототип реального времени

Прототип повторяет логику финальной модели и работает в три параллельных потока:

Аудио-поток

- Непрерывно опрашивает микрофон
- Silero VAD сегментирует речь на отдельные фразы
- Накопление в буфере

Видео-поток

- Читает кадры с веб-камеры в фоне
- Кольцевой буфер ~3 секунды
- Готов к выборке 16 кадров

Поток инференса

- Запускается при завершении фразы
- Каскадный инференс (гейт → голова)
- Флаг processing против гонок

Производительность: нейтральные фразы — менее 10 мс, эмоциональные — 60–110 мс на Apple M1 Pro (MPS), без потери плавности интерфейса.

Ограничения: нет очереди фраз; возможное расхождение аудио- и видео-окон; обработка одного лица; упрощённый fallback детекции; чувствительность к освещению.



Заключение

Проанализированы современные подходы SER, FER и MER; выявлено их ключевое ограничение — высокая вычислительная сложность при параллельной обработке модальностей.

Построен единый воспроизводимый LOSO-бенчмарк на IEMOCAP: UAR 0,5094 — лучший результат среди 6 моделей.

Разработана оригинальная двухстадийная каскадная архитектура с лёгким аудиогейтом MelCNN, отсеивающим нейтральные реплики.

Реализован потоковый real-time прототип: нейтральные фразы обрабатываются менее чем за 10 мс, эмоциональные — за 60–110 мс.

Реализовано переиспользование одной лог-мел спектрограммы в гейте и аудио-ветви — отказ от тяжёлых энкодеров, итоговый размер 37 МБ.

Практическая ценность результатов. Код доступен на GitHub:
github.com/Kaparya/Classification-of-Facial-Expressions



Спасибо за внимание!

